ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ
ВЫСШАЯ ШКОЛА ЭКОНОМИКИ

ФАКУЛЬТЕТ СОЦИОЛОГИИ

КАФЕДРА СБОРА И АНАЛИЗА СОЦИОЛОГИЧЕСКОЙ ИНФОРМАЦИИ

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА

ПРОСТОЙ И МНОЖЕСТВЕННЫЙ АНАЛИЗ СООТВЕТСТВИЙ КАК МЕТОД РАЗВЕДОЧНОГО АНАЛИЗА ДАННЫХ

Выполнил:

Студент 523 гр.

Шафир Марк Александрович

НАУЧНЫЙ РУКОВОДИТЕЛЬ:

Кутлалиев Асхат Хасянович

МОСКВА 2006

СОДЕРЖАНИЕ

ВВЕДЕНИЕ 3

ГЛАВА 1. ПРЕДПОСЫЛКИ АНАЛИЗА СООТВЕТСТВИЙ 8

1.1. Суть анализа соответствий 8
2.2. История анализа соответствий 11
2.3. Анализ соответствий в французской социологической школе 13
2.4. Анализ соответствий в ряду других методов 16
2.5. Анализ соответствий в отечественной литературе и исследовательской практике 18

ГЛАВА 2. ОСНОВЫ ПРОСТОГО АНАЛИЗА СООТВЕТСТВИЙ 20

2.1. Профили 21
2.2. Массы 24
2.3. Расстояния 25
2.4. Инерция 28
2.5. Профили и вершины 30
2.6. Снижение размерности 32
2.7. Декомпозиция (разложение) инерции 34
2.8. Координаты и графическое представление точек: симметричные и асимметричные карты 41
2.9. Показатели качества решения: абсолютные и относительные вклады 47
2.10 Практические рекомендации 54

ГЛАВА 3. АНАЛИЗ МНОГОМЕРНЫХ ДАННЫХ И МНОЖЕСТВЕННЫЙ АНАЛИЗ СООТВЕТСТВИЙ 58

3.1. Анализ таблиц множественных ответов 58
3.2. Интерпретация трехмерного решения 67
3.3. Использование дополнительных точек 72
3.4. Анализ «составленных» таблиц 75
3.5. Множественный анализ соответствий 82

ГЛАВА 4. СОВМЕСТНОЕ ИСПОЛЬЗОВАНИЕ АНАЛИЗА СООТВЕТСТВИЙ И КЛАСТЕРНОГО АНАЛИЗА 90

ВЫВОДЫ И НАПРАВЛЕНИЯ ДАЛЬНЕЙШЕЙ РАБОТЫ 96

ПРИЛОЖЕНИЕ А. ЧИСЛОВЫЕ СТАТИСТИКИ ДЛЯ ПРИМЕРОВ, НЕ РАЗОБРАННЫХ В ТЕКСТЕ 98

ПРИЛОЖЕНИЕ В. АНАЛИЗ СООТВЕТСТВИЙ В SPSS: КОМАНДНЫЙ СИНТАКСИС 109

ПРИЛОЖЕНИЕ С. ОПИСАНИЕ ОСНОВНЫХ ПСИХОГРАФИЧЕСКИХ ТИПОВ ПО МЕТОДИКЕ RULS 112

БИБЛИОГРАФИЯ 117

Введение

В последние годы в социологических и, особенно, маркетинговых исследованиях все чаще используется анализ соответствий. Анализ соответствий является многомерным методом, позволяющим исследовать данные таблиц сопряженности путем графического представления строк и столбцов таблицы в качестве точек в пространстве низкой размерности. Как правило, данные, собираемые в ходе социологических и маркетинговых исследований в подавляющем большинстве случаев являются категориальными, – т.е. измеренными по порядковой или номинальной шкале. Поскольку наиболее простая и часто встречаемая форм представления таких данных – это построение таблиц сопряженности (так, по некоторым экспертным оценкам, до 80% маркетингового анализа осуществляется с помощью таблиц сопряженности) [Hoffman and Franke, 1986] анализ соответствий представляется ценным инструментом понимания и объяснения информации, содержащейся в этих таблицах.

За последние два десятилетия резко возросло количество публикаций, посвященных анализу соответствий, носящих как теоретическую, так и прикладную направленность. Широкому распространению анализа соответствий способствовал и тот факт, что в конце 80-х – начале 90-х гг. XX века данный метод был реализован в ряде популярных статистических пакетов, таких как SAS [SAS Institute, 1989], SPSS [SPSS Inc., 1990], STATISTICA [StatSoft, Inc., 2001]. Однако в современной отечественной литературе анализ соответствий не имеет адекватного отражения, хотя довольно часто применяется в практике маркетинговых исследований. Существует ряд работ, ориентированных в большей степени на технику, теорию метода, но большинство их них доступно для понимания весьма ограниченному кругу специалистов, хорошо знакомых с методами математической статистики, в то время как для значительной части пользователей-социологов и исследователей рынка такие сугубо теоретические описания имеют невысокую практическую ценность. Таким образом, налицо разрыв между теоретической стороной метода и его эмпирической стороной. Настоящая работа призвана способствовать сокращению этого разрыва благодаря тому, что в ней, с одной стороны, подробно рассматривается математический аппарат метода, впрочем, с минимальными техническими подробностями, и, с другой стороны, используются многочисленные примеры из различных областей социологических и маркетинговых исследований. Данная работа может представлять интерес как для специалистов по обработке данных, так и для социологов-исследователей: внимание первых привлечет, прежде всего, ряд приемов и техник анализа данных; внимание вторых – иллюстрации того, как анализ соответствий может быть привязан к решению реальных социологических и маркетинговых задач.

Анализ соответствий относится к методам предварительного, или разведочного (exploritary) анализа данных. Данный класс методов предназначен в первую очередь для исследования структуры данных, а не для проверки статистических гипотез или установления причинно-следственных связей.

Разведочные методы не опираются на вероятностные предположения о природе данных, и, в отличие от классических методов математической статистики дают результаты, относящиеся к выборке, а не к генеральной совокупности. Их можно эффективно использовать как на предварительном этапе изучения данных (для выявления аномальных наблюдений и возможных кластеров), так и для интерпретации результатов моделирования [Адамов, 1991]. Таким образом, разведочные методы призваны порождать гипотезы о распределении и взаимосвязях данных, после чего – на следующем этапе – полученные гипотезы могут тестироваться подтверждающим методами.

Для того чтобы эффективно исследовать структуру данных, разведочный метод должен быть максимально гибким и иметь как можно меньше ограничений и требований к исходным данным. Анализ соответствий не предъявляет практически никаких требований к данным; он может быть применен к любой прямоугольной матрице. Фактически, единственным ограничением является неотрицательность чисел в ячейках матрицы [Nishisato, 1980]. Это является особенно важным при анализе социометрических показателей, для которых классические методы анализа применимы с очень существенными оговорками [Кутлалиев, Попов, 2005].

В анализе соответствий процесс тестирования гипотез, использующийся в классических методах математической статистики, замещается интерпретацией графического представления данных, – так называемых «карт соответствия» (correspondence map). Такой способ описания данных через визуализацию опирается на особую исследовательскую стратегию, или даже, точнее сказать, особый тип мышления, характерный, прежде всего, для французских социологов и специалистов по математической статистике. Иллюстрацией этого философского подхода служит знаменитый афоризм Ж.-П. Бензекри, одного из основателей метода: «модель должна вытекать из данных, а не наоборот» [Benzecri *et al.*, 1973]. Бензекри подчеркивает важность видения данных такими, какие они есть, в противовес подгонке данных под заранее заданные модели. В целом, эта позиция достаточно точно выражает саму суть разведочного анализа данных.

Существует два подхода к анализу соответствий: простой анализ соответствий (simple correspondence analysis, CA) и множественный анализ соответствий (multiple correspondence analysis, MCA). «Входом» для простого анализа соответствий, как правило, служит частотная матрица одной или нескольких таблиц сопряженности. При этом часто можно выделить «описываемую» переменную (variable to be described) и одну или несколько «описывающих» переменных (describing variables)[1]. Пусть, к примеру, у нас есть таблица сопряженности двух переменных: «предпочитаемый жанр телевизионных передач» (описываемая переменная) с категориями «сериалы», «художественные фильмы», «ток-шоу» и др., и переменной «возраст» (описывающая переменная), представленной несколькими интервалами. В подобных случаях для определения наличия статистической связи обычно используется тест хи-квадрат (или другие меры связи для номинальных переменных), результатом которого может быть вывод о том, что, например, «существует значимая статистическая связь между возрастом и предпочитаемым жанром телевизионных передач». При этом ни силу, ни

[1] Термины «описываемые» и «описывающие» переменные по своей сути близки традиционному понятию зависимых и независимых переменных. Однако в контексте анализа соответствий отношения зависимости, строго говоря, неприменимы, поскольку метод не предназначен для поиска причинно-следственных связей. Поэтому нами, вслед за М. Гринакром и Ж. Блазиусом [Greenacre, Blasius, 1994] сознательно используется более мягкие концепты «описываемых» и «описывающих» переменных.

природу связи с помощью критерия хи-квадрат мы определить не можем.

Анализ соответствий позволяет исследовать как силу, так и природу связей между категориями в строках и столбцах таблицы. В результате применения анализа соответствий к нашему случаю мы получаем возможность визуализировать данные на карте, где жанры передач (строки таблицы) и возрастные группы (столбцы таблицы) будут представлены точками в совместном пространстве. Благодаря этому мы сможем более наглядно изучить структуру связей между переменными и получить выводы следующего характера: например, «для старших возрастных групп характерным является предпочтение сериалов, в то время как ток-шоу в большей степени ассоциируется с молодежью». Более того, анализ соответствий дает возможность анализировать несколько кросс-таблиц с одной и той же описываемой переменной, если их предварительно «составить» (concatenate) в одну, то есть расположить друг под другом в соответствии с порядком категорий описываемой переменной. Так, в нашем примере мы могли бы добавить к группе описывающих переменным еще и «пол», «образование», «доход», и др. В результате, на одной карте одновременно могут быть представлены взаимосвязи между несколькими описывающими и описываемыми переменными.

Множественный анализ соответствий используется тогда, когда имеется более двух переменных, причем все они имеют одинаковый статус, то есть не подразделяются на описываемые и описывающие. Данная ситуация напоминает метод главных компонент, в котором структура связей между переменными исследуется путем поиска латентных факторов (измерений). Собственно, множественный анализ соответствий представляет собой применение алгоритма простого анализа соответствий к матрице сочетаний переменных, состоящей из всех их возможных попарных пересечений. Такая матрица носит название матрицы Бёрта и является, в сущности, аналогом ковариационной матрицы [Greenacre, Blasius, 1994, p.IX].

Кроме того, есть еще одно существенное отличие простого анализа соответствий от множественного: с помощью последнего можно анализировать данные на уровне респондентов. В этом случае строками «входной» матрицы служат сами респонденты, а столбцами – категории интересующих нас переменных [Greenacre, 1994, p.151]. В такой матрице, называемой «индикаторной матрицей» (indicator matrix), каждая строка описывает определенного респондента, благодаря чему становится возможным интерпретировать положение отдельных респондентов на карте и сравнивать их друг с другом. Это свойство множественного анализа соответствий, с нашей точки зрения, делает его весьма привлекательным для использования в сочетании с кластерным анализом. Во-первых, одновременный анализ нескольких переменных и совместное их отображение в пространстве низкой размерности позволяет выделить категории, по которым наблюдаются наиболее существенные различия, что дает возможность выбрать из большого числа переменных несколько «самых сильных» и затем кластеризовать по ним респондентов. Во-вторых, помещая на карту отдельных респондентов, мы можем изучать их скопления и делать выводы о количестве и форме возможных кластеров. Именно эти соображения и легли в основу настоящей работы.

В качестве причин актуальности предлагаемой работы можно отметить следующие:

1) в ней более подробно, чем это делалось ранее в отечественных работах, рассматривается алгоритм анализа соответствий по классической схеме Гринакра [Greenacre, 1993], причем

значительное внимание уделяется практическому применению и интерпретации результатов метода;

2) разбирается множественный анализ соответствий, который в отечественной литературе не отражен совсем;

3) основная задача, при которой анализ соответствий используется в маркетинговых исследованиях – это анализ имиджа марок (соответствие марок товара ряду «имиджевых» характеристик). В данной же работе демонстрируется более широкие возможности применения метода в маркетинговых и социологических исследованиях;

4) несмотря на широту имеющихся методов и программ, в современной отечественной исследовательской практике относительно слабо продвинут предварительный анализ данных. Между тем, специфика социологических данных (неоднородность, зависимость наблюдений друг от друга и от времени, обилие качественных признаков [Адамов, 1991]) в первую очередь требует его применения. Анализ соответствий, в особенности множественный, представляется ценным и эффективным инструментом разведочного анализа данных.

5) рассматриваются практически не описанные в литературе возможности и ситуации совместного использования анализа соответствий и кластерного анализа с целью наиболее полного описания данных, выявления возможных кластеров и «выбросов»;

6) изложение достаточно простое; механизм анализа соответствий разбирается очень подробно, «на пальцах», с использованием примеров из различных областей социологических и маркетинговых исследований.

Таким образом, объектом настоящей работы является анализ соответствий. Предметом – возможности его использования на этапе предварительного анализа данных, в частности, в сочетании с кластерным анализом.

Основные цели работы – (1) дать представление исследователю об относительно слабо представленном в отечественной литературе методе анализа соответствий, причем как о его математическом аппарате и базовых концептах, так и о практическом применении и интерпретации; и (2) раскрыть некоторые возможности совместного использования анализа соответствий и кластерного анализа на этапе разведочного анализа данных.

Для реализации данных целей необходимо решение следующих задач:

1) прежде всего, дать общее представление об анализе соответствий, его логике, истории развития и общем методологическом подходе, в основе которого лежит особый тип мышления, характерный для французской социологической школы;

2) выделить и описать базовые концепты метода, и подробно разобрать на простом примере его алгоритм, представив его как последовательную цепочку шагов;

3) обобщить метод простого анализа соответствий на многомерный случай и рассмотреть множественный анализ соответствий;

4) представить некоторые способы совместного использования анализа соответствий и кластерного анализа;

Сообразно задачам строится и структура работы. Так, в Главе 1 дается самое общее представление о методе на наглядном примере, без каких бы то ни было технических подробностей. Представляются основные этапы становления и развития анализа соответствий, перечисляются

ключевые работы, выделяются и сравниваются различные подходы и точки зрения на метод, рассматривается современный этап развития, – в том числе в отечественной науке и исследовательской практике, – а также новые тенденции.

Глава 2 посвящена простому анализу соответствий. На примере небольшой таблицы сопряженности разбираются базовые концепты метода: профили, массы, расстояния, инерция. Механизм метода представляется в виде цепочки из 34 последовательных шагов, начиная с вычисления маргинальных сумм и преобразования исходной таблицы в матрицу относительных частот, заканчивая реконструированием исходных данных из модели, полученной в итоге. Поскольку большинство читателей, вероятно, для выполнения анализа соответствий будет пользоваться компьютерными программами, данная глава может быть полезной как для понимания результатов, выдаваемых этими программами, так и для разработки и коррекции собственных программ или макросов.

Глава 3 обобщает метод анализа соответствий на многомерный случай. Вначале подробно рассматривается анализ таблиц множественных ответов, многомерных таблиц «составленных» таблиц. Затем вводится понятие множественного анализа соответствий и рассматриваются два способа задания исходных данных: матрица Бёрта и индикаторная мартица. Разбираются причины низких значений объясненной инерции в множественном анализе соответствий и представляется способ борьбы с этой проблемой.

Наконец, в Главе 4 на конкретной социологической задаче построения социального пространства разбираются ситуации совместного использования методов: определение переменных для кластерного анализа, поиск латентных измерений, визуализация расположения отдельных респондентов в пространстве с целью определить возможное число и форму кластеров, интерпретация кластеров и поиск переменных, по которым полученные кластеры сильнее всего различаются.

Глава 1.
Предпосылки анализа соответствий

Основная цель анализа соответствий состоит в том, чтобы перейти от исходной матрицы данных к новой, более простой матрице, потеряв при этом как можно меньше информации. Кроме того, анализ соответствий позволяет представить полученные результаты графически, что существенно облегчает интерпретацию решения. Таким образом, задача анализа соответствий напоминает задачу метода главных компонент: и в том, и в другом методе находится некое n-мерное пространство, которое наилучшим образом описывает исходные данные, а затем полученные оси вращаются для того, чтобы перераспределить общую дисперсию между всеми найденными факторами таким образом, чтобы первый фактор объяснял наибольшую долю различий; второй – меньше, третий – еще меньше, и т.д. Так, А. Кутлалиев и А. Попов определяют анализ соответствий как особый случай анализа главных компонент строк и столбцов матрицы, который используется в основном для анализа категориальных переменных, в то время как метод главных компонент – для анализа непрерывных величин [Кутлалиев, Попов, 2005, с.301-302].

С другой стороны, ряд авторов подчеркивают родство анализа соответствий с анализом канонических корреляций [см. напр. Clausen, 1994, p.1; Heiser, Meulman, 1994, p.208]. Если последний обычно применяется для выявления связи между двумя наборами непрерывных числовых переменных, то первый изначально был разработан для анализа двух дискретных переменных. Наконец, Ж. Блазиус даже предлагает рассматривать анализ соответствий как особый вид многомерного шкалирования, где для вычисления близостей между объектами используется хи-квадрат расстояние, и каждый объект взвешивается пропорционально его массе [Blasius, 1994].

Действительно, анализ соответствий имеет ряд сходств с каждым из перечисленных методов. Он может использоваться и как метод анализа взаимосвязи между категориальными переменными; и как метод снижения размерности и поиска латентных факторов; и как метод измерения близости между объектами и построения пространства восприятия.

1.1. Суть анализа соответствий

В анализе соответствий категории двух или более исследуемых дискретных переменных представляются в виде точек в пространстве низкой размерности. При этом категории, имеющие сходные распределения, будут представлены точками, лежащими близко друг к другу; и, напротив, категории с сильно различающимися распределениями, породят далеко лежащие друг от друга точки. Поясним это на примере.

В табл. 1.1. собраны данные об использовании различных источников информации при

принятии решения о покупке различных товаров и услуг; данные были получены в рамках регулярного синдикативного исследования TGI-Россия, проводимого компанией КОМКОН[2]. Применяя к этой таблице анализ соответствий, мы получаем геометрическое решение – карту соответствий, изображенную на рис. 1.1. Результат интерпретируется в терминах взаимного расположения точек на карте. Общее число измерений в решении на единицу меньше, чем число категорий у переменной наименьшей размерности (в нашем примере переменная «источник информации» имеет 12 категорий, а переменная «категория товара/услуги, имеет 13 категорий; и, следовательно, итоговая размерность пространства составит 12 – 1 = 11 измерений). Однако, как правило, при практическом использовании анализа соответствий выбирается двумерное решение, являющееся наиболее наглядным и не слишком сложным для интерпретации. Визуализация и интерпретация уже хотя бы трех осей значительно затрудняется (некоторые способы визуализации решений в случае более двух размерностей описываются в работе Ж. Рована [Rovan, 1994]).

Двумерная карта, представленная на рис. 1.1, показывает взаимосвязь источников информации с категориями товаров и услуг. Механизм анализа соответствий будет подробно разобран в Главе 2, а пока мы можем интерпретировать результаты следующим образом. Горизонтальная ось отделяет услуги (на левом полюсе оси находятся досуг, отпуск, банковские и

ТАБЛИЦА 1.1.
Использование различных источников информации при принятии решения о покупках; абсолютные частоты

Категория товара/услуги	***Советы родных, друзей и знакомых***	***Радио***	***Газеты***	***Журналы***	***Телевидение***	***Листовки и брошюры в почтовом ящике***	***Тематические издания, справочники, каталоги***	***Уличная и транспортная реклама***	***Выставки, презентации***	***Интернет***	***Информация на местах продаж (оформление витрин и прилавков)***	***Консультации продавцов***
При покупке продуктов питания, безалкогольных напитков	8272	493	515	510	1526	303	441	353	727	349	2401	3637
При выборе алкогольных напитков	7691	301	267	317	708	178	329	243	591	194	1661	3052
При выборе табачных изделий	2833	169	169	166	313	110	139	208	176	107	626	719
При выборе одежды, обуви	8197	429	485	745	827	363	562	341	650	342	2400	3748
При выборе услуг и товаров по уходу за детьми	5659	290	347	554	588	215	506	224	354	233	1299	2350
При выборе бытовой техники	9045	535	684	914	1345	520	1262	372	784	584	2268	4718
При планировании покупки компьютера, аксессуаров или программного обеспечения	4582	219	320	630	458	245	1081	142	417	745	1230	2893
При выборе автомобиля или мотоцикла	3891	201	299	532	372	129	726	141	376	316	729	1513
При обращении за банковскими или страховыми услугами	6357	419	626	386	638	224	633	177	233	361	948	1527
При планировании отпуска, путешествия	7659	408	555	629	715	288	812	191	305	483	671	1159
При планировании вечера	8051	1014	1069	802	1336	386	494	702	420	448	819	908
При ухаживании за домашними животными	6517	584	852	1142	1278	321	1622	228	511	401	1133	2942
При планировании улучшения домашнего интерьера, ремонта, покупки стройматериалов	7236	438	744	1385	1464	407	1536	302	477	351	1612	3175

Источник: COMCON, TGI-Россия, I полугодие 2005 г., города с населением 100 тыс. чел. и более

[2] Подробное описание исследования TGI-Россия можно найти на сайте группы компаний КОМКОН: http://www.comcon-2.com/default.asp?trID=57

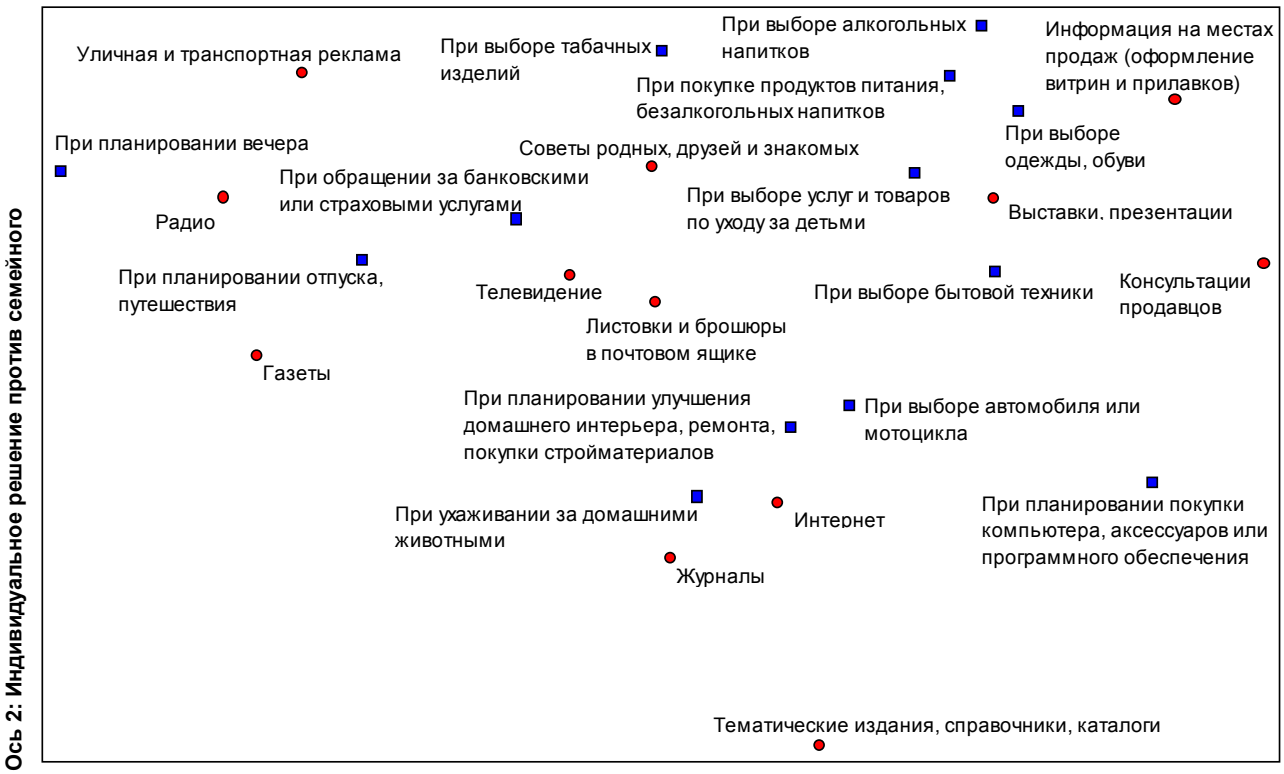


Рис.1.1. Результаты анализа соответствий для Таблицы 1.1. (карта соответствий). Источники информации и категории товаров/услуг представлены точками в двумерном пространстве.

страховые услуги) от товаров (на правом полюсе – компьютер, бытовая техника, одежда), а вертикальная ось отделяет индивидуальное принятие решения (алкогольные напитки и табачные изделия, расположенные на крайнем верхнем полюсе, выбираются сугубо индивидуально) от коллективного, семейного (на крайнем нижнем полюсе – уход за домашними животными, улучшение интерьера, ремонт, покупка компьютера). Расположение точек в пространстве, образованном этими двумя осями, указывает на то, что при выборе индивидуальных услуг и способов проведения досуга характерно использовать информацию, получаемую с помощью радио и уличной и транспортной рекламы; в то время как при выборе услуг для всей семьи (уход за домашними животными, улучшение домашнего интерьера, ремонт) чаще используют тематические издания, справочники, каталоги, журналы и интернет. С другой стороны, оформление витрин и прилавков (информация на местах продаж) чаще всего служит основным источником информации при покупке товаров индивидуального потребления с низкой вовлеченностью («импульсные» товары, одежда, обувь). При выборе товаров с высокой вовлеченностью, когда решение принимается не столько индивидуально, сколько коллективно, всей семьей (бытовая техника, компьютер) характерно получать консультации у продавцов, использовать информацию из тематических изданий, справочников, каталогов.

Полученные выводы, в общем-то, являются достаточно тривиальными; однако приведенный пример дает возможность понять основное свойство анализа соответствий – визуализацию связей между категориями в таблицах сопряженности – на интуитивном уровне.

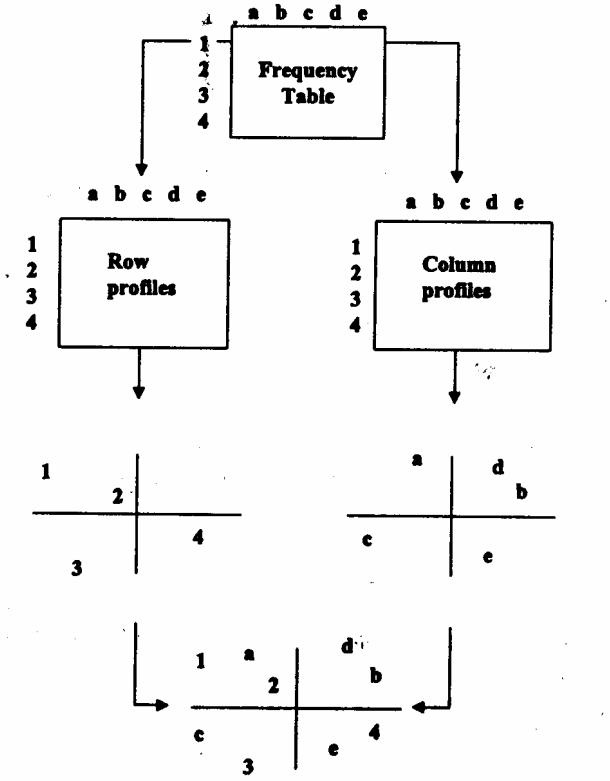


Рис.1.2. Стадии анализа соответствий. Источник: [Greenacre, 1981]

Вкратце, процесс анализа, который детально разбирается в следующей граве, схематически можно обрисовать следующим образом (см. рис. 1.2.). Анализ проводится в две стадии: сначала для набора категорий одной переменной, потом для набора категорий второй переменной; после чего результаты обеих стадий совмещаются. В свою очередь, каждую из этих стадий можно разбить на три этапа. Вначале рассчитываются профили категорий (относительные частоты) и их массы (маргинальные пропорции). Затем вычисляются расстояния между точками. На третьем шаге находятся оси n-мерного пространства, наилучшим образом описывающие облако точек. Полученная конфигурация затем вращается для того, чтобы оси лежали как можно ближе к точкам.

2.2. ИСТОРИЯ АНАЛИЗА СООТВЕТСТВИЙ

Название анализа соответствий происходит от французского “analyse des correspondences”. Современный анализ соответствий был разработан во Франции в конце 1960-х – начале 1970-х годов [Benzerci, 1973; Lebart, Morineau, Tabard, 1977]. При этом схожие методы независимо друг от друга развивались во многих странах и были известны под названиями: оптимальное шкалирование, взаимное усреднение, оптимальная оцифровка, квантификационный метод, анализ однородности [StatSoft, Inc., 2001].

История анализа соответствий сопряжена с развитием французской социологической школы и

французского анализа данных (French data analysis, FDA), который фактически является синонимом анализа соответствий [The BMS, 1994]. Так, Г. Рунэ [Rouanet, 1988] выделят три периода развития современных французских методов анализа данных: выделение французского анализа данных в самостоятельное направление 1963-1973 гг., его обособление в 1973-1981 гг., и постепенное распространение за границами Франции с 1981 г.

Первый период

Согласно Г. Рунэ, теория и практика анализа соответствий начинается с работ Ж.-П. Бензекри в 1963-1964 гг. и защиты докторской диссертации Б. Кордье в 1965 г. [Codrier, 1965]. Метод начал понемногу применяться в различных областях исследований, и некоторые из этих ранних примеров практического приложения анализа соответствий были позже описаны Бензекри и его коллегами [Benzecri *et al.*, 1973]. С разработкой дополнительных приемов – интерпретацией абсолютных и относительных вкладов (см. Главу 2), появлением множественного анализа соответствий (см. Главу 3), и др., – возникла целая методология комплексного анализа многомерных данных, получаемых в ходе эмпирических исследований, которая довольно быстро получила широкое распространение среди французских социологов, в том числе П. Бурдье. Фактически, к середине 70-х гг., вокруг Бензекри и его коллег возникла новая школа анализа данных. В 1971 вышла первая книга, посвященная анализу соответствий [Lebart, Fenelon, 1971], вслед за которой в 1973 появился фундаментальный трактат Бензекри [Benzecri *et al.*, 1973]. Однако в течение всего этого периода основной реакцией на французский анализ данных со стороны англо-говорящих социологов и специалистов по математической статистике было вежливое игнорирование.

Как отмечают К. Ван Метер и его соавторы [The BMS, 1994], основным препятствием, мешавшим распространению анализа соответствий за пределами Франции, был языковой барьер. Лишь незначительная часть англо-говорящих социологов и исследователей знала французский, в то время как сами французы не предпринимали никаких попыток перевести хотя бы базовые работы на английский.

Второй период

В течение второго периода, выделяемого Рунэ (с 1973 по 1981 гг.), анализ соответствий приобретает огромную популярность во Франции. Появляются многочисленные книги, публикации и диссертации, а также бесчисленное множество статей в самых различных областях социологических, маркетинговых, эконометрических и медицинских исследований. Анализ соответствий становится основным методом анализа данных; в ведущих университетах, готовящих социологов и специалистов по статистике, анализ соответствий включается в основную программу; появляется ряд спецкурсов [The BMS, 1994].

Между тем, в англоязычной литературе анализ соответствий все еще не был отражен, и языковой барьер остался основной проблемой. Так, анализ соответствий не был упомянут в популярных руководствах по многомерному анализу данных С. Хабермана [Haberman, 1978] и

У. Бишопа [Bishop *et al., 1975*]. Однако, как это часто бывает при противостоянии двух научных парадигм, с широким распространением анализа соответствий игнорирование сменилось постепенным взаимопроникновением [The BMS, 1994].

Третий период

Третий период, выделенный Рунэ (с 1981 г. и до настоящего времени), ознаменовался приходом на французский рынок популярных американских статистических пакетов, таких как SPSS, SAS, BDMP и др. Параллельно, интерес к французскому анализу данных возникает, наконец, за пределами Франции. Работы [Nishisato, 1980], [Greenacre, 1981, 1984], [Lebart, Morineau and Warwick, 1984] и др. содержат подробное описание анализа соответствий, однако все они подходят к методу скорее с технической, математической стороны. Более практически-ориентированные работы появились несколько позже: [Weller and Romney, 1990], [Greenacre, 1993]; одновременно ведущие журналы опубликовали в упрощенном изложении отдельные главы и статьи из вышедших ранее работ, в том числе [Greenacre, 1981, 1984] и [Hoffman and Franke, 1986]. Это стало своеобразным прорывом в истории анализа соответствий, который стал широко распространяться среди американских ученых и студентов [по Clausen, 1998]. В 1984 г. известный психолог и социолог Ф. Янг включил в свою фундаментальную статью по методам шкалирования [Young, 1984] отдельный раздел, посвященный анализу соответствий. В 1987 г. Гудман [Goodman, 1987] показал взаимосвязь логлинейного анализа, латент-структурного анализа и анализа соответствий, предложив использовать их комбинацию для получения возможной количественной информации, содержащейся в категориальных данных.

Огромную роль в преодолении разрыва между французской и англо-говорящей школами анализа данных сыграли представители первой, и, в особенности, М. Гринакр, бывший студент Ж.-П. Бензекри. Его колоссальные усилия способствовали выходу анализа соответствий на международную арену.

2.3. АНАЛИЗ СООТВЕТСТВИЙ В ФРАНЦУЗСКОЙ СОЦИОЛОГИЧЕСКОЙ ШКОЛЕ

Поскольку первоначально анализ соответствий развивался в русле французской школы анализа данных, нам представляется крайне важным коснуться, хотя бы поверхностно, той методологической парадигмы, которая лежит в ее основе. Это необходимо для понимания как сути самого метода, так и причин того противостояния между французской и англосаксонской (Anglo-Saxon, термин из [The BMS, 1994, p.134]) традициями анализа данных, которое сложилось в 70-е гг. XX века, и, в общем-то, не потеряло своей актуальности до сих пор.

Французский анализ данных

Возможно, наиболее полное и точное описание французского подхода к анализу данных вообще и к анализу соответствий в частности описывается в масштабном труде М. Шильц, посвященном

сравнению различных статистических методов в применении к социологическим данным [Shiltz, 1990]. Как утверждается в этой работе, исследователь, изучая конкретную социальную проблему, как правило, пытается измерить как можно больше показателей, наиболее полно, по его мнению, описывающих исследуемую реальность. Из-за этого анкеты могут быть достаточно большими, и содержать как релевантные вопросы, так и вопросы, слабо связанные с основной проблемой. Данные, собираемые в ходе социологических исследований, часто представляются в виде многомерных таблиц, где объекты (респонденты, временные периоды, географические единицы) пересекаются с категориями нескольких дискретных переменных (пол, возраст, образование, статус занятости, и т.д.).

При анализе многомерных, и, к тому же, зачастую «грязных» (в смысле качества полевых работ, несовершенства исследовательского инструментария, большого числа пропущенных ответов, и др.) социологических данных, с которыми исследователю, как правило, приходится работать, классические инструменты математической статистики редко когда оказываются эффективными. Эти инструменты были разработаны в рамках дедуктивного, причинно-следственного естественнонаучного подхода; или в рамках «производственной статистики», где основным вопросом является контроль качества продукции (решается, считать ли произведенную деталь бракованной, или нет) [The BMS, 1994, p.132]. Эти методы в первую очередь предназначены для тестирования статистических гипотез, и они практически не уделяют внимания таким задачам, как комплексное изучение структуры массива данных, описание данных, возможность посмотреть на данные под новым углом зрения; в то время как перечисленные задачи часто являются весьма и весьма актуальными в социологических исследованиях. Более того, классические методы математической статистики накладывают ряд ограничений на исходные данные: нормальность распределения, независимость наблюдений, и т.д. Между тем, специфика социологических данных такова, что применительно к ним эти ограничения практически никогда не выполняются полностью.

В этих условиях преимущества анализа соответствий, не налагающего никаких ограничений на данные, очевидны. Фактически, анализ соответствий стал популярным во Франции в противовес классическим методам математической статистики, распространенным в англоязычном научном сообществе. В качестве основных свойств анализа соответствий, делающих его крайне актуальным, французские исследователи чаще всего называют то, что он может работать с очень большими массивами данных и позволяет получить достаточно ясное представление о структуре данных [The BMS, 1994, p.133].

Философия метода: Ж.-П. Бензекри

Ярче всего французская методологическая парадигма представлена в работах Ж.-П. Бензекри. В одной из своих статей [Benzecri, 1973] он утверждает, что социологическая наука подвергается серьезной опасности из-за присущего большому числу исследователей идеализма, который заставляет их подгонять реальные факты под некоторые априорные представления. В противовес этой тенденции, Бензекри предлагает новый метод анализа данных, в котором априорные соображения и заранее заданные гипотезы заменяются статистически определяемыми показателями,

полученными на богатом эмпирическом материале. Этими «статистически определяемыми показателями» являются оси (факторы[3]) анализа соответствий. Именно благодаря этим факторам, по мнению Бензекри, исследователи получают возможность раскрыть сущность вещей, созданную Богом. На эту тему Бензекри даже опубликовал статью в французском католическом журнале *"La Pensee Catholique"* в 1969 г. [Benzecri, 1969].

Этот философский и, в какой-то степени, религиозный подход имел важное практическое значение. Так, для Бензекри особую важность приобретали даже не столько сами исходные данные, сколько именно получаемые в результате факторы (оси), отражающие, по его мнению, существо реальности. Как правило, исследователю действительно бывает удобнее работать с факторами, чем с исходными данными, но скорее по математико-статистическим причинам (факторы, или, точнее, координаты объектов по выбранным осям, обычно представляют собой непрерывные числовые переменные; кроме того, в большинстве случаев, их существенно меньше, чем исходных переменных). Для Бензекри же причины, прежде всего, философские и даже религиозные, с которыми, конечно, исследователь не обязан соглашаться.

Исследование социального пространства: П. Бурдье

Несомненно, еще одной причиной повышения интереса к анализу соответствий как во Франции, так и за ее пределами, служит популярность работ П. Бурдье, который использовал этот метод в целом ряде своих теоретических работ [см., прежде всего, Burdieu, 1984]. Так, например, с помощью анализа соответствий Бурдье исследовал феномен, который впоследствии был им назван «социальным пространством» (social space). Различные социально-профессиональные группы и определенный набор ценностей были представлены в пространстве трех главных осей. Первые две оси он определил как «объем капитала» и «структура капитала», а третья ось представляла собой ось времени. При этом термин «капитал» использовался Бурдье для обозначения всей совокупности ресурсов и возможностей, которыми обладает индивид, – включая экономический, социальный и культурный капитал [Burdieu, 1984].

Используя анализ соответствий, Бурдье показал связь между определенными типами «вкусов» (tastes), или «стилей жизни» (life-styles), и социальным статусом индивида. Благодаря тому, что теоретические выводы Бурдье иллюстрировал реальными эмпирическими данными, его аргументы приобрели достаточно убедительную силу; что способствовало дальнейшему распространению анализа соответствий в исследовательской практике, в особенности, при изучении проблем социальной стратификации [Wuggening, Mnich, 1994], социальной мобильности [Blasius, 1994], социальной укорененности экономических действий [Martens, 1994].

Идея построения некого пространства признаков, в котором располагаются определенные объекты, является крайне привлекательной для маркетинговых исследований. Анализ соответствий является ключевым инструментом построения карт восприятия бренда, определения рыночных ниш

[3] Бензекри использует термин "Correspondence analysis factors", который дословно переводится как "факторы". Фактически, оси, получаемые в результате применения анализа соответствий, есть не что иное, как латентные факторы; которые, как и в методе главных компонент, вычисляются с помощью сингулярного разложения.

продукта, оценки конкурентных преимуществ марки товара. Хорошими примерами использования анализа соответствий в маркетинговых исследованиях являются работы Шнельдерса и Штокманс [Sneldres, Stokmans, 1994], М. Бендиксена [Bendixen 1996], К. Роджерса [Rogers, 1996].

2.4. АНАЛИЗ СООТВЕТСТВИЙ В РЯДУ ДРУГИХ МЕТОДОВ

В 60-х гг. XX века были сделаны важные достижения в анализе количественных данных, в том числе развитие инструментов линейного моделирования [Goodman, 1969] и анализа соответствий. Так, в анализе данных фактически возникло два противоположных подхода [Shiltz, 1991].

Две научно-исследовательские парадигмы – два подхода к анализу данных

Первый подход основывается на принципах классических методов проверки статистических гипотез, появившихся в начале XX века применительно к анализу не столько социологической информации, сколько информации, полученной в ходе экспериментов. Эта англосаксонская исследовательская традиция требует, прежде всего, разработать модель, а затем попытаться «подогнать» под нее имеющиеся данные [The BMS, 1994, p.134]. Модели логлинейного анализа, логистической регрессии, летент-структурного анализа возникли как раз в рамках этого подхода.

Второй подход, французский анализ данных, ориентирован в большей степени на описание данных, чем на построение моделей. Он представлен, прежде всего, анализом соответствий; хотя, например, другие описательные методы, такие как кластерный анализ и многомерное шкалирование, также достаточно широко распространены среди французских исследователей.

По мнению К. Ван Метера и его соавторов [The BMS, 1994], способ формулировки вопросов в анкете во многом определяется тем, в рамках какой из двух методологических стратегий работает исследователь. Так, англосаксонская традиция нацелена на подтверждение или опровержение заранее сформулированных содержательных гипотез с помощью эмпирических наблюдений. Однако проблема здесь может заключаться в том, что среди огромного числа измеряемых в ходе исследований показателей нелегко бывает выбрать небольшое число самых эффективных переменных, которые бы наилучшим образом подходили для использования в модели. С другой стороны, вторая, французская традиция, нацелена на поиск каких-либо закономерностей и взаимозависимостей, характерных не для всей выборки в целом, а для ее определенных подгрупп; и на графическое представление этих закономерностей. Однако французские исследователи уделяют достаточно мало внимания формальным критериям установления статистической связи между переменными [The BMS, 1991, p.134].

И у той, и у другой исследовательской методологии есть как свои преимущества, так и недостатки. Так, применение строгих подтверждающих методов к «грязному» массиву социологических данным может привести к неверным выводам. В то же время, анализ соответствий, работая с теми же данными, оперирует отдельными категориями переменной, а не всей переменной целиком, как делают подтверждающие методы; и поэтому он является более гибким. К примеру, нам,

вероятно, интереснее узнать, как категории «бедные» и «богатые» (частные значения переменной «доход») связаны с рядом категорий других переменных; чем рассматривать влияние переменной «доход» в целом на другие переменные во всей их полноте.

В целом, критика анализа соответствий сводится к тому, что трактовка его результатов неоднозначна, и разные исследователи могут сделать разные выводы, глядя на одну и ту же карту соответствий. Кроме того, анализ соответствий не позволяют разрабатывать модели изучаемого явления; с его помощью нельзя доказать или опровергнуть априорные гипотезы.

Совместное использование методов анализа

На наш взгляд, два обозначенных методологических подхода могут быть не только противопоставлены друг другу, но и использованы в сочетании, с целью максимально полно проанализировать имеющиеся данные. Так, анализ соответствий может использоваться вначале для описания большого массива данных, получения упрощенной картины в пространстве низкой размерности, выявления ключевых взаимосвязей; а также на начальных этапах разработки модели и поиска наиболее релевантных ей переменных, и формулировки предварительных гипотез. Затем для проверки этих гипотез может быть использован, например, лог-линейный анализ. Подобная схема действий описывается в книге Ш.-Э. Клозена [Clausen 1998]. Возможна и обратная последовательность применения методов: так, целый ряд голландских исследователей предлагают вначале построить логлинейную модель, а затем применить анализ соответствий для изучения остатков модели [van der Heijden, Mooijaart, Takane, 1994].

Еще одна крайне любопытная, – хотя и, по мнению некоторых критиков [The BMS, 1994], недостаточно обоснованная теоретически, – процедура совместного использования разведочных и подтверждающих методов предлагается М. Ле Гуеном и С. Жаффрэ: так называемый метод «декомпозиции дисперсии» [Le Guen, Jaffre, 1988]. Вначале к массиву данных применяется анализ соответствий и кластерный анализ. Полученные кластеры затем отображаются на карте соответствий, образованной двумя первыми осями, с целью визуализировать ключевые различия между кластерами. Далее внутри кластеров рассчитывается дисперсия каждой переменной, и также отображается в виде точки на карте соответствий. После этого точки, отражающие дисперсию переменных, соединяются линией для каждого кластера, в результате чего образуются близкие по форме фигуры. Степень схожести этих фигур говорит об однородности полученных кластеров.

Анализ однородности (homogeneity analysis) как особый подход к анализу соответствий, (реализованный в модуле SPSS Categories до 13-й версии включительно), рассматривается в статье У. Хайзера и Ж. Мелман [Heiser, Meulman, 1994]. Термин «анализ однородности» используется авторами для обозначения целой группы методов, предназначенных для исследования распределения переменных и их нелинейных взаимодействий; причем в анализе могут использоваться как категориальные, так и числовые (интервальные) переменные. Набор переменных определяется авторами как однородный, если переменные имеют общий «центр», т.е. остаются инвариантными к группе допустимых преобразований. Потеря однородности определяется как отклонение оптимально преобразованных переменных от их «центра». Несмотря на то, базовые

предпосылки анализа однородности и множественного анализа соответствий различаются, эти два метода дают одинаковый результат [Heiser, Meulman, 1994].

Ряд авторов ставят под сомнение утверждение Ж.-П. Бензекри о том, что анализ соответствий полностью лишен каких бы то ни было элементов моделирования (mode-free method) [van der Heijden, Mooijaart, Takane, 1994; Bochenholt, Takane, 1994]. Так, в статье [van der Heijden, Mooijaart, Takane, 1994] анализ соответствий определяется как модель, представляющая собой нелинейную проекцию данных в пространство некоторых параметров. Эта нелинейная проекция может быть оптимизирована как методом наименьших квадратов, так и методом максимального правдоподобия. Авторы не только подробно разбирают последний способ оптимизации решения анализа соответствий с помощью функции максимального правдоподобия, не применявшийся до этого никем, но также рассматривают некоторые сходства анализа соответствий и логлинейного анализа и латент-структурного анализа.

Сфера применения анализа соответствий все больше и больше расширяется; круг задач, для решения которых он используется, постоянно растет. Так, в большом числе работ описываются возможности применения анализа соответствий при изучении динамики социальных явлений. См. например, работы [Martens, 1994; Thiessen, Rohlinger, Blasius, 1994; Muller-Schneider, 1994]. А, например, Г. Гиглер и Г. Кляйн даже предлагают применяют анализ соответствий для контент-анализа текстов [Giegler, Klein, 1994], причем преимущества такого подхода выглядят в авторском изложении достаточно убедительно.

Сегодня в литературе можно найти немало примеров совместного использования различных методов анализа данных, и это дает основания полагать, что в будущем многомерные методы анализа данных чаще будут применяться в комплексе, как разведочные, так и подтверждающие.

2.5. АНАЛИЗ СООТВЕТСТВИЙ В ОТЕЧЕСТВЕННОЙ ЛИТЕРАТУРЕ И ИССЛЕДОВАТЕЛЬСКОЙ ПРАКТИКЕ

Анализ соответствий достаточно активно используется в современной российской исследовательской практике. Сегодня практически каждая уважающая себя компания, занимающаяся маркетинговыми исследованиями, имеет в своем арсенале методик анализ соответствий, чаще всего применяющийся при изучении имиджа марок продукта. Тем не менее, в отечественной литературе анализ соответствий отражен весьма слабо, если не сказать – практически вообще не отражен.

Одной из первых отечественных работ, где упоминается анализ соответствий, была статья С. Адамова, посвященная описанию пакета прикладных программ «САНИ», который реализует этот метод наряду с другими техниками обработки нечисловой информации [Адамов, 1991]. В ней не рассматривается математический аппарат метода, зато приводится пример использования множественного анализа соответствий при изучении проблем динамики социальной мобильности мужчин и женщин; демонстрируется преимущества графического решения задачи, осуществляется подробная содержательная интерпретация полученных факторов (осей).

Математический аппарат анализа соответствий, впрочем, так же как и примеры его использования, описываются в работе Ю. Клишиной [Клишина, 1991]. Клишина предлагает выделять

два подхода к простому анализу соответствий. При первом подходе устанавливается взаимное соответствие градаций пары признаков; при втором – объекты и категории неколичественных признаков представляются в виде точек на плоскости, что позволяет выделить аномальные наблюдения и возможные группировки, строить гипотезы о взаимосвязях. Примером первого подхода является задача, рассмотренная еще в [Nishisato, 1980]: три преподавателя оцениваются студентами по шкале «хороший», «средний», «плохой»; после чего мнения студентов обобщаются, с помощью анализа соответствий выводятся числовые выражения для этих вариантов, а затем на их основе считаются средние баллы значения для каждого преподавателя. Таким образом, значения и первого, и второго признака можно представить в виде точек на числовой прямой и рассмотреть их взаимное расположение. Для иллюстрации второго подхода Клишина использует данные исследования по изучению ценностных ориентаций молодежи, где анализ соответствий применяется для определения положения ценностей в пространстве, образованном рангами последних.

На наш взгляд, подобное разделение анализа соответствий на два различных подхода не совсем оправдано, так как в обоих случаях используется одна и та же процедура, с той лишь разницей, что в первом примере объекты располагались на прямой (одномерный анализ соответствий), а во втором – на плоскости (двумерный анализ соответствий). Иначе говоря, первый подход есть частный случай второго: в итоговом решении выбирается не две оси, а только одна. Нужно сказать, что первый подход применим далеко не всегда, а только в том случае, если из двумерного решения видна нецелесообразность второй оси. По нашему опыту, необходимым, но не достаточным условием для этого, как правило, является «вытягивание» категорий обоих наборов переменных вдоль главной оси.

Наконец, следует отметить уже упоминавшуюся выше книгу А. Кутлалиева и А. Попова [Кутлалиев, Попов, 2005], где анализ соответствий рассматривается в качестве метода построения карт восприятия, наряду с методом главных компонент и многомерным шкалированием. Авторы разбирают базовые понятия анализа соответствий, излагают основные принципы интерпретации результатов, приводят пример из области маркетинговых исследований, а также рассматривают возможность использования анализа соответствий для изучения динамики восприятия марок.

Основные принципы и понятия анализа соответствий описываются также в электронном учебнике STATSOFT, доступном в сети интернет [StatSoft, Inc., 2001]. На сегодняшний день это чуть ли не единственный русскоязычный источник, в котором рассматриваются некоторые вычислительные аспекты множественного анализа соответствий, которые, заметим, достаточно непросты. Тем не менее, одной только публикации в интернете, конечно же, не достаточно для освоения и понимания метода.

Как видно, число русскоязычных работ по анализу соответствий очень невелико. Мы надеемся, что в настоящей работе нам удастся прояснить как базовые понятия и вычислительные аспекты метода, так и принципы его интерпретации, а также ряд других приемов, не описанных доселе в отечественной литературе. Это, возможно, вызовет некоторый дискурс, что, в свою очередь, может породить хотя бы небольшой всплеск интереса к анализу соответствий на более глубоком уровне, нежели это было до сих пор.

Глава 2.
Основы простого анализа соответствий

В этой главе мы рассмотрим основные понятия и пошаговый механизм вычисления простого анализа соответствий. Наше изложение в целом следует логике подхода М. Гринакра, впрочем, с некоторыми изменениями и дополнениями. Более детальное описание метода и объяснение ряда понятий и процедур читатели могут найти в работах [Greenacre, 1993; Greenacre, 1994]. Механизм анализа соответствий будет показан на примере простой таблицы сопряженности, в то время как анализ более сложных матриц разбирается в Главе 3. Результаты вычислений каждого шага иллюстрируются на сквозном примере. В качестве исходных данных используется табл. 2.1., источником которой является американское исследование общественного мнения [Converse *et. al*., 1980]. В таблице представлено распределение ответов семи возрастных групп на вопрос «Как вы считаете, какими темпами идет развитие гражданских прав?» с вариантами «слишком быстро», «в самый раз», «слишком медленно», «затрудняюсь ответить».

Основные понятия анализа соответствий относятся скорее к области геометрии, чем статистики. Фактически, единственное статистическое понятие, к которому привязан анализ соответствий – это хи-квадрат Пирсона (χ^2). Величина хи-квадрат, как правило, вычисляется для выявления наличия статистической связи между переменными в таблице сопряженности. Далее мы покажем, как χ^2 может быть интерпретирован в терминах геометрических понятий анализа соответствий. В анализе соответствий три базовых понятия: профили (profiles), массы (masses), хи-квадрат расстояния (chi-squared distances), и мы представим их на примере табл. 2.1. В процессе изложения приводятся необходимые сведения из теории и вводятся соответствующие обозначения (как в скалярной, так и в матричной форме). Все вычислительные результаты были получены с применением пакета SAS [SAS Institute, 1990].

Как уже упоминалось выше, вначале анализ проводится в две стадии: отдельно для строк и

Таблица 2.1.
Исходные данные (абсолютные частоты)

Возрастная группа, лет	**Слишком быстро**	**В самый раз**	**Слишком медленно**	**Затрудняюсь ответить**
18-24	69	37	7	5
25-34	148	45	14	22
35-44	170	65	12	29
45-54	159	57	12	28
55-64	122	26	6	18
65-74	106	21	5	23
75+	40	7	1	14

столбцов таблицы, после чего на последнем этапе результаты этих стадий объединяются. В силу того, что в обеих стадиях процесс одинаков, мы сосредоточимся в основном на анализе строк, в то время как вычисления будут приведены и для строк, и для столбцов. В процессе чтения этой главы, вероятно, будет полезным возвращаться к рис.1.2., иллюстрирующему общую логику процесса анализа.

2.1. ПРОФИЛИ

Шаг 1. Итак, мы имеем таблицу сопряженности $\mathbf{N}$ $(I \times J)$. В нашем случае I = 7, J = 4. При работе с таблицами сопряженности представляется малоэффективным сравнивать абсолютные частоты в ячейках. Каждая строка и столбец таблицы содержат разное число респондентов, часто называемое *базой*. Для того чтобы получить возможность сравнения, обычно частоты в таблице приводятся к общей базе в 100% путем вычисления процентов по строкам или по столбцам.

Шаг 2. Вычисляем маргинальные суммы по строкам матрицы $\mathbf{N}$: $n_{1+}, n_{2+}, \ldots n_{I+}$. Например, $n_{1+} = \sum_j n_{1j} =$ = 118 (см. табл. 2.2.).

ТАБЛИЦА 2.2.
МАРГИНАЛЬНЫЕ СУММЫ ПО СТРОКАМ

18-24	118
25-34	229
35-44	276
45-54	256
55-64	172
65-74	155
75+	62

Шаг 3. Вычисляем маргинальные суммы по столбцам матрицы $\mathbf{N}$: $n_{+1}, n_{+2}, \ldots n_{+J}$. Например, n_{+2} = = $\sum_i n_{i2}$ = 814 (см. табл. 2.3.).

ТАБЛИЦА 2.3.
МАРГИНАЛЬНЫЕ СУММЫ ПО СТОЛБЦАМ

Слишком быстро	**В самый раз**	**Слишком медленно**	**Затрудняюсь ответить**
814	258	57	139

Шаг 4. Сумма маргиналов равна объему выборки, $n = \sum_i n_{ij} =$ 1268.

Шаг 5. Матрица соответствий (correspondence matrix) $\mathbf{P}$ определяется как исходная таблица $\mathbf{N}$, поделенная на сумму маргиналов n, $\mathbf{P} = (1/n)\mathbf{N}$; например, p_{24} = 22/1268 = 0.0174 (см. табл. 2.4.).

ТАБЛИЦА 2.4.
МАТРИЦА СООТВЕТСТВИЙ (CORRESPONDENCE MATRIX)

Возрастная группа	Слишком быстро	В самый раз	Слишком медленно	Затрудняюсь ответить
18-24	0,0544	0,0292	0,0055	0,0039
25-34	0,1167	0,0355	0,0110	0,0174
35-44	0,1341	0,0513	0,0095	0,0229
45-54	0,1254	0,0450	0,0095	0,0221
55-64	0,0962	0,0205	0,0047	0,0142
65-74	0,0836	0,0166	0,0039	0,0181
75+	0,0315	0,0055	0,0008	0,0110

Работая с данными табл. 2.1., мы можем рассчитать как доли ответов в каждой возрастной группе, так и доли возрастных групп в каждом из вариантов ответа. Исходя из содержательных соображений, нам, вероятно, более интересен первый вариант, т.е. проценты по строкам. Так, 68 из 118, или 58,5%, респондентов, принадлежащих к возрастной группе 18-24 лет, дали ответ «слишком быстро»; в то время как в группе «75+» такой же ответ дали 40 из 62 респондентов, что составляет 65,4%. Полученные относительные частоты дают возможность проводить сравнение между возрастными группами. Собственно, *профиль* представляет собой набор относительных частот (долей; процентов), вычисленных для конкретной строки или столбца.

Так, например, профиль первой возрастной группы можно записать в виде последовательности долей (0,585 0,341 0,590 0,420), или, иначе, в процентной форме, (58,5% 34,1% 5,9 4,2%). В табл. 2.5. приводятся профили строк (а в табл.2.6. – профили столбцов). Последний ряд в табл. 2.5. называется *средним профилем строк*, который вычисляется путем деления маргинальных сумм по столбцам (814 258 57 139) на общую сумму маргиналов таблицы (1268), что дает в итоге (64,2% 20,4% 4,5% 10,9%). Так, 64,2% всех опрошенных дали ответ «слишком быстро», и, таким образом, старшая возрастная группа «75+» оказывается наиболее близкой к среднему значению по выборке в целом (64,5% представителей этой группы дали ответ «слишком быстро»), в то время как соответствующая доля в самой молодой группе «16-24» существенно ниже среднего (58,5%).

Шаг 6. Профили строк – это строки исходной таблицы $\mathbf{N}$, поделенные на соответствующие им маргинальные суммы строк (см. табл. 2.5.).

ТАБЛИЦА 2.5.
ПРОФИЛИ СТРОК

Возрастная группа	Слишком быстро	В самый раз	Слишком медленно	Затрудняюсь ответить
18-24	0,5847	0,3136	0,0593	0,0424
25-34	0,6463	0,1965	0,0611	0,0961
35-44	0,6159	0,2355	0,0435	0,1051
45-54	0,6211	0,2227	0,0469	0,1094
55-64	0,7093	0,1512	0,0349	0,1047
65-74	0,6839	0,1355	0,0323	0,1484
75+	0,6452	0,1129	0,0161	0,2258
Средний профиль строк	0,6420	0,2035	0,0450	0,1096

Шаг 7. Профили столбцов – это столбцы исходной таблицы $\mathbf{N}$, поделенные на соответствующие им маргинальные суммы столбцов (см. табл. 2.6.).

ТАБЛИЦА 2.6.
ПРОФИЛИ СТОЛБЦОВ

Возрастная группа	Слишком быстро	В самый раз	Слишком медленно	Затрудняюсь ответить	Средний профиль столбцов
18-24	0,0848	0,1434	0,1228	0,0360	0,0931
25-34	0,1818	0,1744	0,2456	0,1583	0,1806
35-44	0,2088	0,2519	0,2105	0,2086	0,2177
45-54	0,1953	0,2209	0,2105	0,2014	0,2019
55-64	0,1499	0,1008	0,1053	0,1295	0,1356
65-74	0,1302	0,0814	0,0877	0,1655	0,1222
75+	0,0491	0,0271	0,0175	0,1007	0,0489

Фактически, профили являются примерами математических векторов. Вектор имеет геометрическую интерпретацию: он определяет точку в многомерном пространстве. К примеру, элементы первого профиля строк, 0,585; 0,341; 0,590; 0,420, могут использоваться в качестве координат некоторой точки в четырехмерном пространстве. Каждый конкретный профиль, таким образом, представляет определенную точку в этом пространстве. В подавляющем большинстве случаев это пространство имеет размерность больше трех, поэтому представить себе расположение точек в таком пространстве чрезвычайно сложно. Однако далее будет показано, что размерность пространства может быть снижена, и, таким образом, мы получаем возможность визуализировать профили в более удобном для восприятия виде, например, на плоскости (иначе говоря, в двумерном пространстве).

2.2. МАССЫ

Второе фундаментальное понятия анализа соответствий – это *масса* профиля. Фактически, каждый профиль представляет определенное количество респондентов. Например, профиль самой молодой возрастной группы (0,585 0,341 0,590 0,420) представлен 118 респондентами. Таким образом, ему приписывается вес, пропорциональный этим 118 респондентам. Точно также профилю самой старшей возрастной группы (0,645 0,113 0,016 0,226) приписывается вес, пропорциональный 62 респондентам, т.е. почти в два раза меньший, чем молодой группе. Поскольку сам профиль не несет информации о том, какое количество респондентов он представляет, подобное взвешивание необходимо нам для того, чтобы учесть важность каждого профиля в последующем анализе.

Шаг 8. Массы строк $r_1, r_2, \ldots, r_I$ получаются делением маргинальных сумм по строкам на сумму маргиналов (объем выборки); $r_i = n_{i+}/n$. Так, например, r_2 = 229/1268 = 0,1806. Вектор, содержащий массы строк обозначается буквой **r** (см. табл. 2.7.).

ТАБЛИЦА 2.7.
МАССЫ СТРОК

18-24	0,0931
25-34	0,1806
35-44	0,2177
45-54	0,2019
55-64	0,1356
65-74	0,1222
75+	0,0489

Таким образом, профили строк теперь можно эквивалентно определить в матричной форме. Матрица профилей строк получается путем деления строк матрицы соответствий **P** на массы строк, что можно записать в виде $\mathbf{D}_r^{-1}\mathbf{P}$, где $\mathbf{D}_r$ – диагональная матрица масс строк. Например, p_{11}/r_1=0,0544/0,0931 = 0,5847 (см. табл. 2.5.).

Шаг 9. Массы столбцов $c_1, c_2, \ldots, c_J$ получаются делением маргинальных сумм по столбцам на сумму маргиналов (объем выборки); $c_j = n_{+j}/n$. Так, например, c_4 = 139/1268 = 0,1096. Вектор, содержащий массы строк обозначается буквой **c** (см. табл. 2.8.).

ТАБЛИЦА 2.8.
МАССЫ СТОЛБЦОВ

Слишком быстро	В самый раз	Слишком медленно	Затрудняюсь ответить
0,6420	0,2035	0,0450	0,1096

Таким образом, профили столбцов теперь можно эквивалентно определить в матричной форме. Матрица профилей столбцов получается путем деления строк матрицы соответствий **P** на массы столбцов, $\mathbf{PD}_c^{-1}$, где $\mathbf{D}_c$ – диагональная матрица масс столбцов. Например, p_{11}/c_1 = = 0,0544/0,6420 = 0,0848 (см. табл. 2.6.).

Средний профиль, представленный последней строкой в табл. 2.5., который есть не что иное как профиль маргинальных сумм по столбцам, является, таким образом, взвешенным средним профилей остальных строк, где веса – это соответствующие массы из табл. 2.7. Другими словами, средний профиль можно рассматривать как некую точку, лежащую в центре облака точек, представленных остальными профилями. Так, если какой-либо профиль сильно отличается от среднего, то соответствующая ему точка будет находиться далеко от центра, и наоборот. Соответственно, если все категории будут иметь схожие со средним профили, они будут располагаться близко к центру, или вообще совпадут с ним.

При этом стоит отметить, что массы строк совпадают со средним профилем столбцов; и наоборот, массы столбцов совпадают со средним профилем строк.

2.3. РАССТОЯНИЯ

В нашем примере мы рассматривали профили строк как векторы, определяющие положение точек в четырехмерном пространстве. Так, профиль самой молодой возрастной группы соответствует точке, имеющей координату 0,585 по первой оси; координату 0,314 по второй оси; координату 0,059 по третьей оси и 0,042 по четвертой. Профиль же самой старшей возрастной группы соответствует точке с координатами 0,645 по первой оси; 0,113 по второй; 0,016 по третьей и 0,226 по четвертой. Подключив воображение, мы, вероятно, можем интуитивно представить себе, как могли бы располагаться эти точки в четырехмерном пространстве, и каково было бы расстояние между ними. Вообще, для вычисления расстояния между двумя точками существует привычная всем формула Евклида, сутью которого является понимание кратчайшего расстояния как прямой:

$$s\,(i,\,i') = \sqrt{\sum_j (a_{ij} - a_{i'j})^2} \qquad (2.1)$$

Согласно этой формуле, расстояние между самой молодой и самой старшей возрастными группами будет равно квадратному корню из суммы квадратов разностей между элементами соответствующих профилей:

$$\sqrt{(0{,}585-0{,}645)^2+(0{,}314-0{,}113)^2+(0{,}059-0{,}016)^2+(0{,}042-0{,}226)^2} = 0{,}282$$

Однако в анализе соответствий используется *взвешенный* аналог евклидова расстояния, где *весом*

служит величина, обратная соответствующему элементу среднего профилю. Здесь взвешивание относится к осям (измерениям) пространства, а не к самим профилям, как в разделе 2.2. На практике подобное взвешивание выражается в том, что более редкие варианты ответа будут входить в формулу с большим весом, в то время как более часто встречающиеся категории – с меньшим весом. Такое «уравновешивание» достигается благодаря тому, что при вычислении расстояния каждый квадрат разности делится на соответствующий элемент среднего профиля:

$$d(i,i') = \sqrt{\sum_j \frac{(a_{ij} - a_{i'j})^2}{a_{+j}}}, \qquad (2.2)$$

где $d\ (i, i')$ взвешенное евклидово расстояние между точками i и i'; a_{ij} – элементы профилей строк; a_{+j} – элементы среднего профиля строк (или масса столбца) [Clausen 1998]. То же верно и для столбцов.

Таким образом, в нашем примере взвешенное евклидово расстояние между самой молодой и самой старшей возрастными группами будет равно

$$\sqrt{\frac{(0{,}585-0{,}645)^2}{0.642} + \frac{(0{,}314-0{,}113)^2}{0.203} + \frac{(0{,}059-0{,}016)^2}{0.045} + \frac{(0{,}042-0{,}226)^2}{0.110}} = 0{,}743.$$

По аналогии с критерием хи-квадрат, где вычисляются квадраты разностей наблюдаемых и ожидаемых, или средних, значений, это расстояние также называют *хи-квадрат расстоянием*.

Шаг 10. Профили строк можно представить в качестве векторов, имеющих столько координат, сколько есть столбцов таблицы (в нашем случае их 4). Хи-квадрат расстояние между профилем строки i и профилем строки i' равно

$$\sqrt{\sum_j \left(\frac{p_{ij}}{r_i} - \frac{p_{i'j}}{r_{i'}} \right)^2 / c_j}$$

Необходимо понимать, что в данном случае мы рассчитываем расстояния между двумя профилями строк; но никак не между профилем строки и профилем столбца. Расстояния между всеми парами профилей строк приведены в табл. 2.9.

ТАБЛИЦА 2.9.
РАССТОЯНИЯ МЕЖДУ ПРОФИЛЯМИ СТРОК

Возрастная группа	18-24	25-34	35-44	45-54	55-64	65-74	75+
18-24	0,0000	0,3156	0,2700	0,2951	0,4499	0,5985	0,7430
25-34	0,3156	0,0000	0,1288	0,1024	0,1797	0,2530	0,4827
35-44	0,2700	0,1288	0,0000	0,0358	0,2240	0,2762	0,4742
45-54	0,2951	0,1024	0,0358	0,0000	0,2016	0,2495	0,4525
55-64	0,4499	0,1797	0,2240	0,2016	0,0000	0,1408	0,3941
65-74	0,5985	0,2530	0,2762	0,2495	0,1408	0,0000	0,2255
75+	0,7430	0,4827	0,4742	0,4525	0,3941	0,2255	0,0000

Шаг 11. Профили столбцов можно представить в качестве векторов, имеющих столько координат, сколько есть строк таблицы (в нашем случае их 7). Хи-квадрат расстояние между профилем столбца j и профилем столбца j' равно

$$\sqrt{\sum_i \left(\frac{p_{ij}}{c_j} - \frac{p_{ij'}}{c_{j'}} \right)^2 / r_i}$$

Необходимо понимать, что в данном случае мы рассчитываем расстояния между двумя профилями столбцов; но никак не между профилем столбца и профилем строки. Расстояния между всеми парами профилей столбцов приведены в табл. 2.9.

ТАБЛИЦА 2.10.
РАССТОЯНИЯ МЕЖДУ ПРОФИЛЯМИ СТОЛБЦОВ

Категория ответа	Слишком быстро	В самый раз	Слишком медленно	Затрудняюсь ответить
Слишком быстро	0,0000	0,3102	0,2985	0,3106
В самый раз	0,3102	0,0000	0,2083	0,5573
Слишком медленно	0,2985	0,2083	0,0000	0,5648
Затрудняюсь ответить	0,3106	0,5573	0,5648	0,0000

М. Гринакр [Greenacre, 1994] отмечает несколько причин выбора именно хи-квадрат расстояния в анализе соответствий. С теоретической точки зрения, деление каждого квадрата разности на ожидаемую частоту служит способом стандартизации, который компенсирует большие отклонения в ячейках с большой частотой и меньшие отклонения в ячейках с маленькой частотой. На практике это означает, что если подобной стандартизации не делалось бы, то различия между большими пропорциями входили в формулу с большим весом и доминировали бы в вычислении расстояния, в то время как различия между меньшими пропорциями, которые с содержательной точки зрения могут быть даже более существенными, терялись бы. Таким образом, процесс взвешивания при вычислении функции расстояния, выравнивает различные базы разных вариантов ответа.

Кроме того, из использования хи-квадрат расстояния вытекает целый ряд привлекательных

свойств анализа соответствий: разложение величины хи-квадрат и совместное отображение строк и столбцов таблицы в общем пространстве, которые будут рассмотрены далее в этой главе.

2.4. ИНЕРЦИЯ

Понятие «*инерция*», или, точнее «*момент инерции*», заимствовано из механики. Так, у каждого физического объекта есть центр тяжести. Каждый элемент этого объекта имеет определенную массу (*r*) и находится на определенном расстоянии (*d*) от центра тяжести. Моментом инерции каждого элемента объекта является масса элемента, умноженная на квадрат его расстояния до центра тяжести; а моментом инерции всего объекта является сумма моментов инерции всех элементов объекта [Кутлалиев, Попов, 2005, стр.303]:

$$\sum_{1} r \times d^2 \qquad (2.3)$$

Наглядный пример инерционной системы дается А. Кутлалиевым и А. Поповым [Кутлалиев, Попов, 2005, стр.303]; мы приводим его на рис. 2.1. и комментируем в авторской интерпретации. Авторы предлагают представить, что точки являются грузиками на стержнях, вращающимися вокруг общего центра тяжести. Так, точки 4, 8, 10, 13, 15 оказывают большое влияние на поведение системы, поскольку имеют сравнительно бóльшую массу и расположены далеко от центра тяжести. Точки же 5,

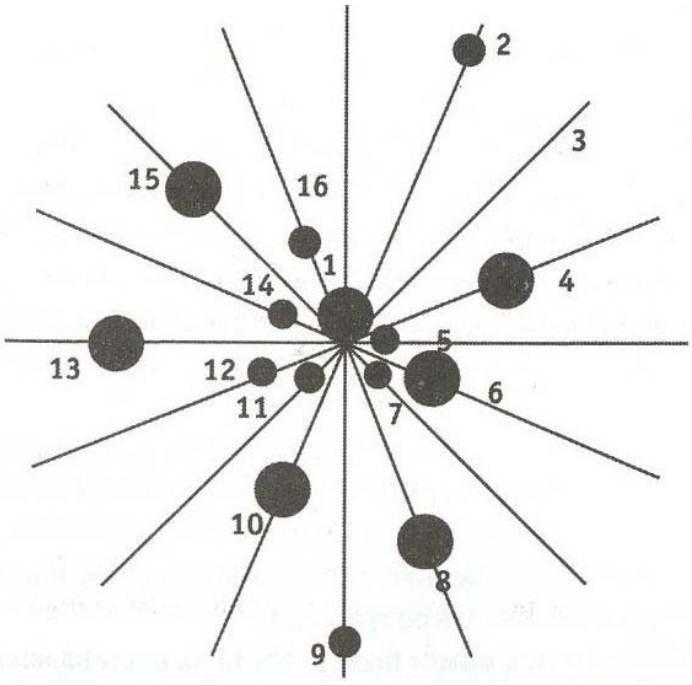


Рис.2.1. Пример инерционной системы. Источник: [Кутлалиев, Попов, 2005, стр.303]

7, 12, 14 имеют небольшую массу и располагаются ближе к центру тяжести; так что их момент инерции и вклад в поведение всей системы мал. При этом поведение точек 1 и 2 менее очевидно. Хотя точка 1 имеет бóльшую массу, она расположена очень близко к центру тяжести, но зато точка 2 с меньшей массой расположена значительно дальше от центра тяжести; при этом необходимо помнить, что расстояние включено в формулу в квадрате [Кутлалиев, Попов, 2005, стр.304].

В нашем случае имеется набор профилей, сумма масс которых равняется 1, есть центр тяжести (средний профиль), называемый также *центроидом* (centroid), а также существует мера расстояния между профилями (хи-квадрат расстояние). Таким образом, у нас есть все составляющие для того, чтобы рассчитать момент инерции системы профилей. Каждый профиль будет вносить определенный вклад в общий момент инерции. Например, вклад в общую инерцию, вносимый профилем самой молодой возрастной группы, равняется

$$0{,}093 \times \left(\frac{(0{,}585 - 0{,}642)^2}{0.642} + \frac{(0{,}314 - 0{,}203)^2}{0{,}203} + \frac{(0{,}059 - 0{,}045)^2}{0{,}045} + \frac{(0{,}042 - 0{,}110)^2}{0{,}110} \right) = 0{,}0103,$$

что фактически есть масса (0,093), умноженная на квадрат расстояния между профилем первой строки и центроидом (средним профилем строк). Полученное значение 0,0109 – это величина инерции первой строки. Прибавив к этому значению инерции остальных строк, мы получим общую инерцию. Геометрически инерция интерпретируется как мера разброса профилей в многомерном пространстве. Чем больше инерция, тем более профили будут удалены друг от друга.

С другой стороны, мы можем рассчитать общую инерцию иным способом – в терминах всех взвешенных квадратов расстояний между парами профилей. Например, в разделе 2.3. мы выяснили, что хи-квадрат расстояние между самой младшей и самой старшей возрастными группами составляет 0,743. Обозначим его как d_{17}, где индексы говорят о том, что рассматриваются первая и седьмая строка. Эти две возрастные группы имеют массы 0,0931 и 0,0489 соответственно. Обозначим их r_1 и r_7. Умножая эти две массы на квадрат расстояния между первой и седьмой строкой, мы получаем значение $r_1 r_7 d_{17}^2$ = 0,0931 × 0,0489 × (0,743)^2 = 0,00252. Подобные вычисления могут быть произведены для всех (7 × 6)/2 = 21 пар профилей. Суммируя эти результаты значения, мы также получим общую инерцию семи профилей. Этот способ иллюстрирует понятие инерции как меры разброса профилей: чем больше расстояния между профилями, тем большими будут вклады взвешенных квадратов расстояний в общую инерцию (значения инерции строк и столбцов приведены в табл. 2.22 и 2.28 соответственно).

На рис. 2.2. показаны четыре различные ситуации, в которых значение инерции последовательно возрастает. В каждом из примеров таблица сопряженности состоит из пяти строк и трех столбцов, и нас интересует пространственное расположение пяти профилей строк. В первом случае профили очень схожи, что выражается в сгущении соответствующих профилям точек в центре и низким значением инерции, равным 0,0076. С увеличением различий между профилями во втором и третьем случаях, точки все больше отдаляются друг от друга, а значение инерции возрастает до 0,1101 и 0,5923 соответственно. Наконец, в ситуации, когда точки разносятся по противоположным

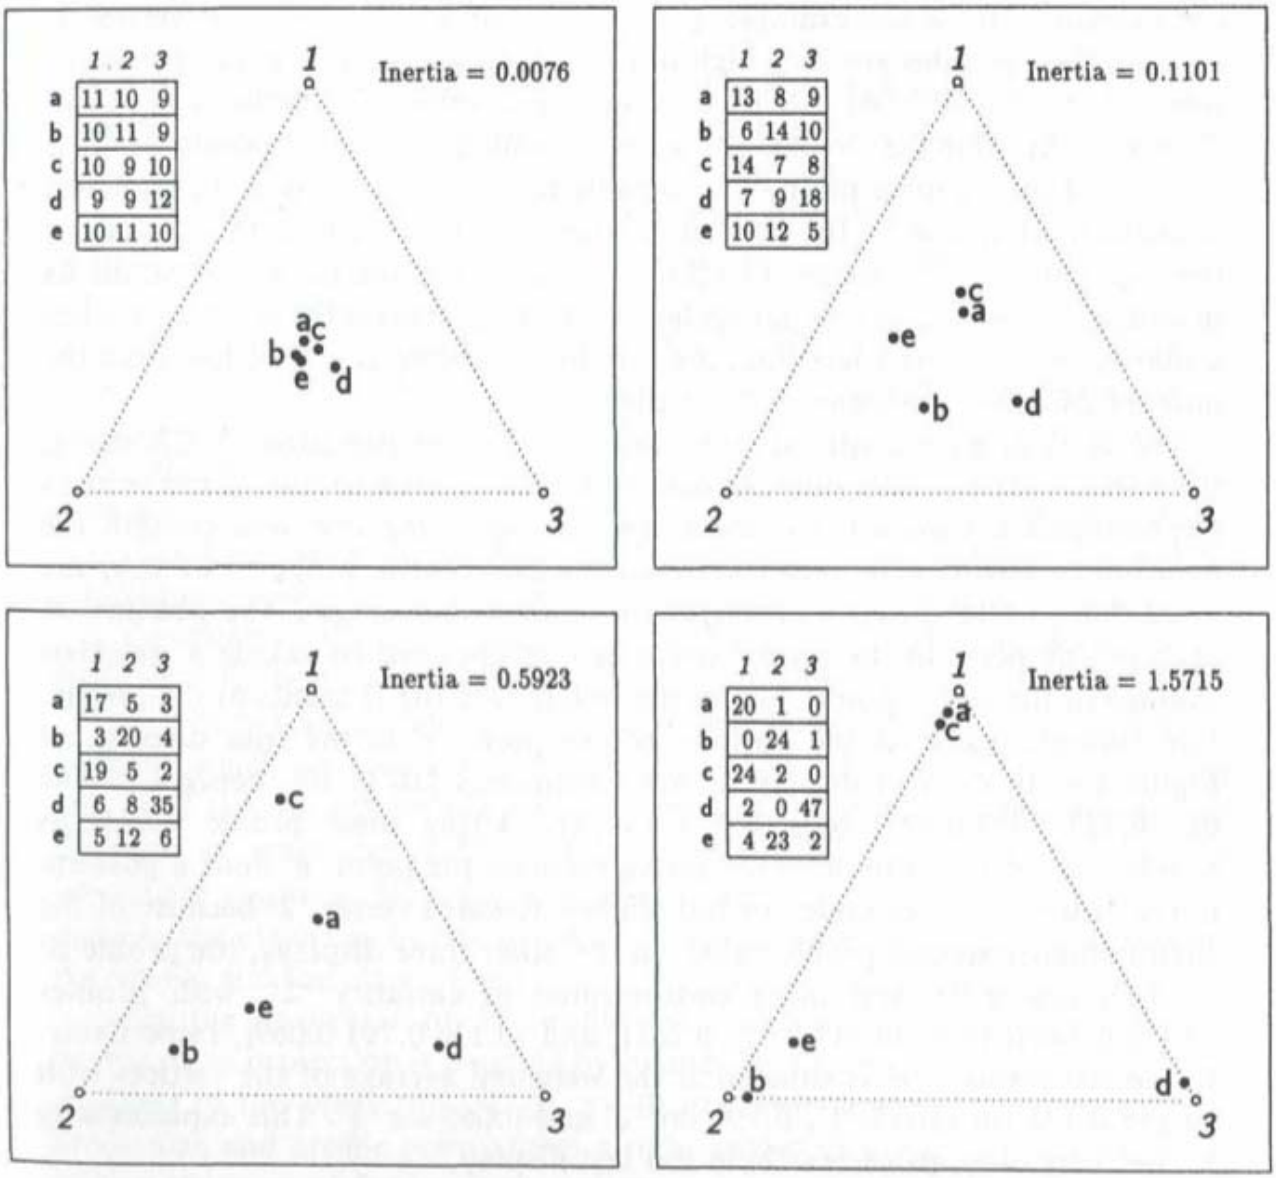


Рис.2.2. Четыре таблицы размера 5 × 3 с возрастающим значением инерции; и графическое представление профилей строк в качестве точек и столбцов в качестве вершин. Источник: [Greenacre, 1994, p.13]

полюсам, различия между профилями достигают максимума, как в последней ситуации на рис. 2.2. Здесь строка «a» практически полностью ассоциируется со столбцом «1», строка «b» – со столбцом «2», «c» – с «1», «d» – с «3», и «e» – с «2». Значение инерции в этом последнем случае равняется 1,5715.

2.5. ПРОФИЛИ И ВЕРШИНЫ

В каждой из ситуаций, изображенных на рис. 2.2., три точки, отмеченные «1», «2» и «3», образуют треугольник. Эти точки, называемые также вершинами, представляют некие фиктивные профили

строк, выглядящие следующим образом: (1 0 0), (0 1 0), (0 0 1), где все значения сосредотачиваются только в одной категории. В последнем случае рис. 2.2., профили «b» и «c» лежат очень близко к вершине «2», потому что их профили имеют высокое значение по второй категории, а по остальным близки к нулю: например, профиль строки «b» равен (0 0,96 0,04). В этих довольно простых примерах треугольники, образованные вершинами, ограничивают пространство, в котором располагаются точки профилей. Последние не могут лежать вне пределов пространства треугольника. Самые большие различия между профилями достигаются тогда, когда соответствующие им точки лежат точно в вершинах треугольника. В этой ситуации инерция достигнет своего максимального значения: в данном примере оно равно 2. В общем случае, максимальное значение инерции на единицу меньше, чем число столбцов или строк – в зависимости от того, которое из двух меньше.

Вершины играют особую роль при интерпретации карт соответствий. Так, чем ближе точка профиля, представляющая, например, строку таблицы, располагается к вершине, представляющей столбец, тем сильнее связаны данная строка и столбец. Подобное свойство часто называют *барицентрическим* (barycentre) свойством анализа соответствий, где понятие барицентра (т.е. центра тяжести) используется в смысле взвешенного среднего. Позиция каждой точки профиля в пространстве вершин может быть определена как взвешенное среднее точек вершин, где весами будут являться элементы соответствующего профиля. Например, рассмотрим расположение точки «e» в каждом из четырех случаев, представленных на рис. 2.2. В первом случае строка «e» имеет частотное распределение (10 11 10), откуда ее профиль равен (0,323 0,355 0,323) (например, 0,323 = 10/31). Используя элементы этого профиля в качестве весов трех соответствующих вершин, мы видим, что точка «e» попадает в центр треугольника, но немного смещается в направлении вершины «2», поскольку второй элемент ее профиля имеет чуть большее значение, чем первый и третий элементы. Во второй, третьей и четвертой ситуациях рис. 2.2., профиль «e» все больше и больше приближается к вершине «2», и его значения равны (0,370 0,444 0,185), (0,210 0,522 0,261) и (0,138 0,793 0,069) соответственно. В последнем случае, например, профиль «e» является взвешенным средним вершин, где вершина «1» берется с весом 0,138; вершина «2» – с весом 0,793; и вершина «3» – с весом 0,069. Таким образом, наибольший вес соответствует второй вершине, что и объясняет, почему точка «e» лежит ближе всего к вершине «2».

Пространственное расположение профилей на рис. 2.2. достаточно очевидно, поскольку профили строк состоят только из трех элементов. Анализ таблиц больших размерностей основывается на той же идее распределения профилей, имеющих некоторые массы, в пространстве, определяемом функцией хи-квадрат расстояния; с той разницей, что число измерений намного больше, вследствие чего визуализация подобного пространства становится уже значительно более сложной задачей. Вершины, или некие фиктивные профили, у которых только один элемент равняется 1, а остальные 0, по-прежнему задают границы пространства. Однако такие трудно вообразимые пространства высоких размерностей, в общем-то, бесполезны в практическом смысле, и нам следует найти способ представления больших таблиц в более простом пространстве низкой размерности, желательно в двумерном. Таким образом, мы подходим к следующей важнейшей цели анализа соответствий – снижению размерности пространства.

2.6. СНИЖЕНИЕ РАЗМЕРНОСТИ

Представить себе расположение точек в пространстве выше третьей размерности, – задача не из легких. Тем не менее, нетрудно предположить ситуацию, когда точки будут лежать близко к некой прямой или плоскости. Вспомним задачу регрессионного анализа, в котором ищется прямая, – или, в случае более высокой размерности пространства, плоскость, – наилучшим образом описывающая облако точек. Качество подгонки модели определяется коэффициентом детерминации R^2. В силу специфики опросных данных неизбежно наличие так называемого «белого шума»[4] (white noise), из-за которого значения R^2, превышающие хотя бы 0,5 обычно считаются уже волне удовлетворительным. Коэффициент детерминации является совокупным (omnibus) показателем качества решения всей модели, не отражающим качество представленности отдельных точек.

В анализе соответствий мы, в общем-то, находимся в аналогичной ситуации, в том плане, что мы ищем пространство низкой размерности, обычно плоскость, которое бы наиболее точно отражало хи-квадрат расстояния между точками. Фактически, эта задача эквивалентна задаче поиска плоскости, которая в некотором смысле ближе одновременно ко всем точкам. Близость определяется методом взвешенных наименьших квадратов, что будет показано нами ниже[5].

В разделе 2.4. мы определили, что инерция профиля строки равна произведению массы профиля r_i и квадрата расстояния d_i^2 между профилем строки и средним профилем, где расстояние определяется как хи-квадрат расстояние. Таким образом, для каждой данной плоскости расстояние между точкой профиля и плоскостью является наименьшим хи-квадрат расстоянием между профилем и плоскостью [Greenacre, 1994, p.15]. Точка, лежащая на плоскости, и наиболее близкая к профилю, называется *проекцией* профиля на плоскость. Обозначим расстояние между профилем и его проекцией на плоскость как e_i, а расстояние на плоскости от проекции профиля до центроида – как $\hat{d}$ (см. рис. 2.3.). Профиль, его проекция на плоскость и центроид, лежащий на плоскости, образуют прямоугольный треугольник, для которого справедлива теорема Пифагора:

$$d_i^2 = \hat{d}_i^2 + e_i^2$$

Таким образом, общая инерция может быть разложена на две составляющих:

$$\sum_i r_i d_i^2 = \sum r_i \hat{d}_i^2 + \sum_i r_i e_i^2 \ , \qquad (2.4)$$

что вербально можно сформулировать в виде

[4] В русскоязычном социологическом жаргоне данное понятие чаще всего обозначается словом «мусор».
[5] Ряд авторов предлагают также использовать для оптимизации решения анализа соответствий не метод наименьших квадратов, а метод максимального правдоподобия. См. например, [van der Heijden, Mooijaart, Takane, 1994]

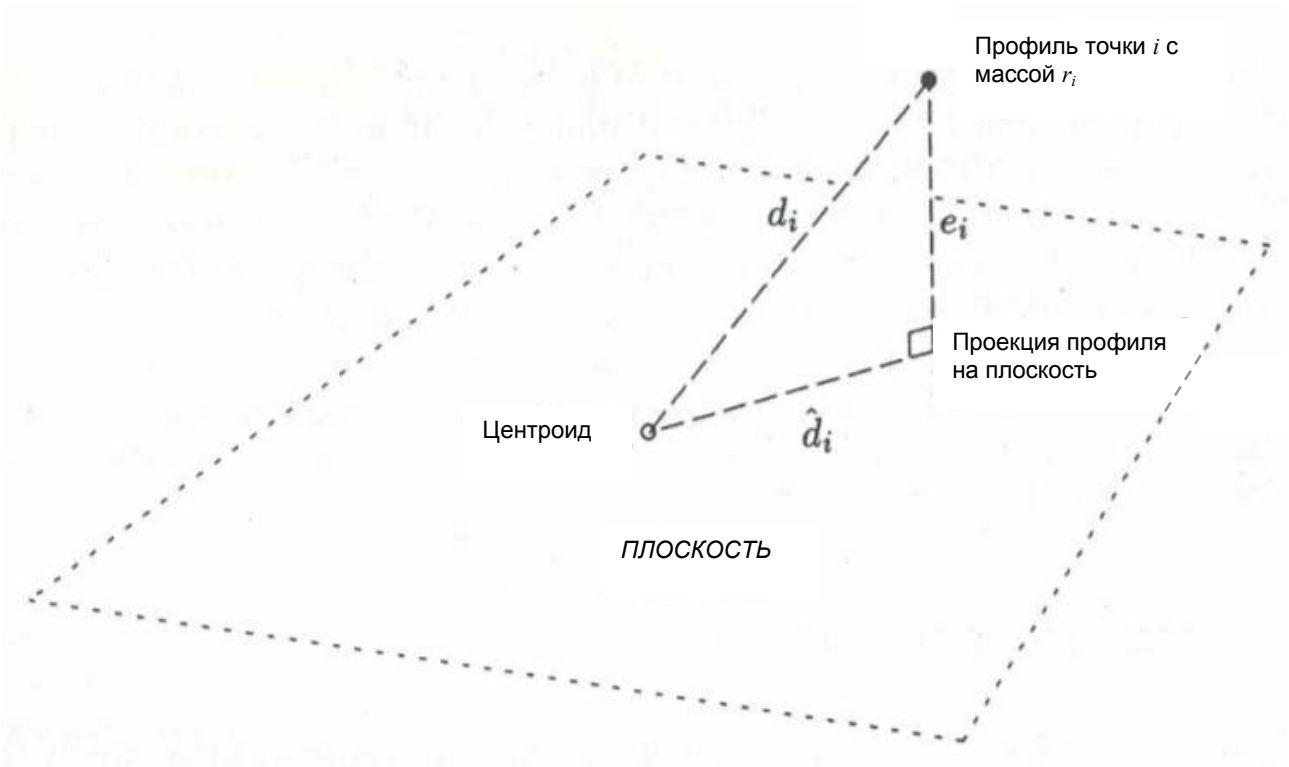


Рис.2.3. Проекция профиля точки на плоскость с изображенным на ней центроидом: расстояния между профилем точки, его проекцией и центроидом образуют прямоугольный треугольник.
Источник: [Greenacre, 1994, p.16].

общая инерция = инерция на плоскости + остаточная инерция

В анализе соответствий близость профиля точки и плоскости измеряется взвешенной суммой квадратов расстояний между точками и плоскостью, т.е. остаточной инерцией $\sum_i r_i e_i^2$, и цель анализа сводится к нахождению плоскости, которая минимизирует эту величину. С другой стороны, формула (2.2.) показывает, что минимизация остаточной инерции эквивалентна максимизации величины $\sum r_i \hat{d}_i^2$, т.е. инерции на плоскости (или, в общем случае, в выбранном подпространстве низкой размерности). Смысл остаточной инерции в том, что эта величина показывает, какую долю различий мы потеряли переходе в двумерное пространство; и механизм анализа нацелен на нахождение такой плоскости, при которой потеря информации минимальна (или, можно сформулировать иначе: наоборот, той плоскости, которая сохраняет максимально возможную долю информации в двумерном пространстве).

Таким образом, двумерные карты, получаемые в анализе соответствий представляют собой наилучшую возможную аппроксимацию исходного расположения профилей точек. На двумерных картах у нас уже нет информации о расстоянии между профилями точек и плоскостью, но мерой качества решения может выступать процент инерции, объясненной двумя осями (или, в общем

случае, количеством выбранных осей в решении), точно также как в регрессионном анализе показателем качества является доля объясненной моделью дисперсии.

Снижение размерности пространства в анализе соответствий достигается с помощью метода сингулярного разложения, к рассмотрению которого мы и переходим.

2.7. ДЕКОМПОЗИЦИЯ (РАЗЛОЖЕНИЕ) ИНЕРЦИИ

Метод сингулярного разложения матриц (singular value decomposition, SVD) является обобщением хорошо известного метода разложения по собственным значениям (eigenvalue decomposition, EVD). Если последний применяется, как правило, для анализа квадратных симметричных матриц, – например, для разложения корреляционной матрицы в методе главных компонент, – то первый может использоваться для разложения любой прямоугольной матрицы [Eckart and Young, 1936], в силу чего представляется ценным инструментом применительно к многомерному анализу данных. Между анализом соответствий и методом главных компонент имеется довольно много сходств, и французские исследователи и математики даже часто называют анализ соответствий «факторным анализом соответствий» (*analyse factorielle des correspondences)* [Greenacre, Blasius, 1994]. Поэтому, прежде чем перейти к рассмотрению сингулярного разложения, использующегося в анализе соответствий, вначале коротко остановимся на основных принципах разложения по собственным значениям, использующегося в методе главных компонент.

Разложение по собственным значениям

Разложение симметричной матрицы $\mathbf{R}$ по собственным значениям выражается в виде $\mathbf{R}=\mathbf{B}\Lambda\mathbf{B}^{\mathrm{T}}$, где в столбцах $\mathbf{B}$ содержатся собственные векторы матрицы $\mathbf{R}$, а Λ представляет собой диагональную матрицу, содержащую собственные значения (eigenvalues) в убывающем порядке: $\lambda_1 > \lambda_2 > \ldots \lambda_m$. Собственные векторы нормализуются для того, чтобы их длина равнялась 1, и являются взаимно ортогональными, что означает, что $\mathbf{B}^{\mathrm{T}}\mathbf{B}=\mathbf{1}$. В случае метода главных компонент, $\mathbf{R}$ – это либо корреляционная, либо ковариационная матрица.

Основная идея метода главных компонент состоит в том, чтобы представить набор переменных в виде некой линейной комбинации меньшего числа общих факторов. На практике это выражается в том, что матрица данных размера $n \times m$ может быть представлена в виде

$$\mathbf{Z} = \mathbf{SL} \tag{2.5}$$

где $\mathbf{Z}$ – это матрица «объект-признак», содержащая центрированные (в случае ковариационной матрицы), или и центрированные и нормализованные, т.е. z-стандартизованные (в случае корреляционной матрицы) данные [Greenacre, Blasius, 1994, p.54]. Матрица $\mathbf{L}$ содержит факторные нагрузки (factor loadings), а матрица $\mathbf{S}$ – значения факторов (factor scores) для каждого объекта.

Уравнение (2.5.) является полным решением тогда, когда число факторов (т.е. число столбцов $\mathbf{L}$) совпадает с числом переменных, т.е. $\mathbf{Z}$ можно воспроизвести без ошибок. В случае же уменьшенного числа факторов, те измерения, которые несут самую маленькую дисперсию (т.е. последние строки $\mathbf{L}$ и последние столбцы $\mathbf{S}$), отбрасываются, что приводит к неизбежной потери части информации, вследствие чего результат является наилучшей аппроксимацией исходных данных в терминах метода наименьших квадратов. В отличие от этого, в подтверждающем факторном анализе, где происходит подобное (2.5.) снижение ранга матрицы, вводится также функция остатков, т.е. $\mathbf{Z} = \mathbf{SL} + \mathbf{U}$, на которую накладывается ряд дополнительных ограничений [см. Greenacre, 1993, 1994].

В пространстве сниженной размерности, – например, в двумерном, задействованы только первые две строки матрицы $\mathbf{L}$. Если для каждой переменной мы возьмем квадраты факторных нагрузок и просуммируем их по первым двум строкам, то мы получим показатель «общности» (communalities), который служит мерой качества представленности каждой из переменных в пространстве сниженной размерности. Таким образом, при интерпретации результатов метода главных компонент используются следующие показатели: собственные значения (или, точнее, проценты дисперсии, объясняемые собственными значениями), факторные нагрузки и общности. Как мы покажем далее в этой главе, все эти три показателя имеют аналоги в анализе соответствий.

Сингулярное разложение

Разложение по собственным значением применяется для квадратных матриц, в то время как сингулярное разложение может быть осуществлено для любой прямоугольной матрицы. Сингулярное разложение матрицы $\mathbf{A}$ размера $I \times J$ выражается в виде произведения

$$\mathbf{A} = \mathbf{U\Gamma V^T} \tag{2.6}$$

где матрица $\mathbf{\Gamma}$ – это диагональная матрица, содержащая K положительных чисел в убывающем порядке: $\gamma_1 \geq \gamma_2 \geq \ldots \geq \gamma_K > 0$; K – ранг матрицы $\mathbf{A}$; и столбцы матриц $\mathbf{U}$ и $\mathbf{V}$ являются ортонормальными, т.е. $\mathbf{U^TU} = \mathbf{V^TV} = \mathbf{1}$. Числа γ_1, γ_2 и т.д. называются сингулярными числами; K столбцов матрицы $\mathbf{U}$ называются «левыми сингулярными векторами», а K строк матрицы $\mathbf{V}$ называются «правыми сингулярными векторами» [Greenacre, Blasius, 1994, p.55]. Тесная связь между методами разложения по собственным значениям и сингулярного разложения выражается в следующих двух формулах, получаемых непосредственно из определения сингулярного разложения (2.6.):

$$\mathbf{A^TA} = \mathbf{V\Gamma^2V^T} \tag{2.7}$$

$$\mathbf{AA^T} = \mathbf{U\Gamma^2U^T} \tag{2.8}$$

Уравнение (2.7.) показывает, что правые сингулярные векторы матрицы $\mathbf{A}$ идентичны собственным

векторам матрицы $\mathbf{A}^T\mathbf{A}$, а сингулярные числа матрицы $\mathbf{A}$, γ^2_1, γ^2_2 , ... γ^2_K являются квадратными корнями собственных чисел $\mathbf{A}^T\mathbf{A}$. Уравнение (2.8.) показывает подобное соответствие между собственными числами и собственными векторами матрицы $\mathbf{A}\mathbf{A}^T$.

Смысл применения сингулярного разложения в анализе соответствий состоит в следующем. В общем случае, у нас имеется I точек в J-мерном пространстве; координаты точек находятся в строках матрицы $\mathbf{Y}$; каждая точка имеет массу w; функцией расстояния в этом пространстве является взвешенное евклидово расстояние, где каждое измерение (ось) имеет вес q. Обозначим за $\mathbf{D}_w$ и $\mathbf{D}_q$ диагональные матрицы масс точек и весов измерений соответственно; и пусть вектор $\boldsymbol{w}$ будет вектором масс точек; при этом мы предполагаем, что сумма масс точек равняется 1: $\sum_i w_i=1$, или, в матричной форме, $\mathbf{1}^T\mathbf{w}=\mathbf{1}$. Тогда, в общем виде, любая карта точек в пространстве низкой размерности может быть получена в результате применения сингулярного разложения к следующей матрице:

$$\mathbf{A} = \mathbf{D}_w^{1/2}(\mathbf{Y} - \mathbf{1}\bar{y}^T)\,\mathbf{D}_q^{1/2} \tag{2.9}$$

где $\bar{y}$ является центроидом строк матрицы $\mathbf{Y}$. Если мы запишем сингулярное разложение как ранее,

$$\mathbf{A} = \mathbf{U}\Gamma\mathbf{V}^T \tag{2.10}$$

то главные координаты (principal coordinates) точек строк, т.е. не что иное как проекции этих точек на главные оси, будут содержаться в следующей матрице:

$$\mathbf{F} = \mathbf{D}_w^{1/2}\mathbf{U}\Gamma \tag{2.11}$$

Так, первые две главные оси являются первыми двумя векторами столбцов матрицы $\mathbf{A}$. Этот результат, полученный в общем виде, доказывается и детально иллюстрируется в [Greenacre, 1994, chapter 2 and Appendix A].

Таким образом, в анализе соответствий мы имеем два частных случая полученного выше общего решения: «задачу строк» (row problem) и «задачу столбцов» (column problem), в которых мы хотим снизить размерность профилей строк и профилей столбцов соответственно; и где каждый набор точек имеет свой набор масс. Как будет показано далее, обе эти задачи сводятся к сингулярному разложению одной и той же матрицы так называемых «стандартизованных остатков» (standardized residuals) [Greenacre, Blasius, 1994, p.56].

Эквивалентность «задачи строк» и «задачи столбцов»

Определив выше основные понятия анализа соответствий – профили, массы, расстояния, и

производное от них понятие инерции – мы переходим к формулировке задач строк и столбцов. Рассмотрим, например, задачу строк. Так, мы имеем набор из I профилей, которые, согласно шагу 8, находятся в строках матрицы $\mathbf{D}_r^{-1}\mathbf{P}$ (см. раздел 2.2); соответствующий профилям набор масс $\mathbf{r}$, содержащийся в диагональной матрице $\mathbf{D}_r$; в пространстве, где расстояния заданы в диагональной матрице $\mathbf{D}_c^{-1}$. Далее находим центроид профилей строк, который есть не что иное, как $\mathbf{r}^{\mathrm{T}}\mathbf{D}_r^{-1}\mathbf{P} = \mathbf{1}^{\mathrm{T}}\mathbf{P} = = \mathbf{c}^{\mathrm{T}}$, т.е. вектор масс столбцов. Отсюда матрица $\mathbf{A}$ из (2.9) выглядит следующим образом:

$$\mathbf{A} = \mathbf{D}_r^{1/2}(\mathbf{D}_r^{-1}\mathbf{P} - \mathbf{1}\mathbf{c}^{\mathrm{T}})\,\mathbf{D}_c^{-1/2} \qquad (2.12)$$

что можно переписать в виде

$$\mathbf{A} = \mathbf{D}_r^{-1/2}\,(\mathbf{P} - \mathbf{r}\mathbf{c}^{\mathrm{T}})\,\mathbf{D}_c^{-1/2}$$

С другой стороны, у нас есть задача столбцов, где имеется набор из J профилей столбцов, которые, согласно шагу 9, находятся в столбцах матрицы $\mathbf{P}\mathbf{D}_c^{-1}$ (см. раздел 2.2); соответствующий профилям набор масс $\mathbf{c}$, содержащийся в диагональной матрице $\mathbf{D}_c$; в пространстве, где расстояния заданы в диагональной матрице $\mathbf{D}_r^{-1}$. Отличие от задачи строк здесь состоит в том, что профили находятся в столбцах таблицы, а не в строках, как подразумевается общей теорией, рассмотренной выше в разделах «Разложение по собственным значениям» и «Сингулярное разложение». Поэтому мы просто транспонируем матрицу $\mathbf{P}\mathbf{D}_c^{-1}$ и получаем $\mathbf{D}_c^{-1}\mathbf{P}^{\mathrm{T}}$. Центроид профилей столбцов – это не что иное, как $\mathbf{c}^{\mathrm{T}}\mathbf{D}_c^{-1}\ \mathbf{P}^{\mathrm{T}} = \mathbf{1}^{\mathrm{T}}\mathbf{P}^{\mathrm{T}} = \mathbf{r}^{\mathrm{T}}$, т.е. вектор масс строк. Отсюда матрица $\mathbf{A}$ из (2.9) выглядит следующим образом:

$$\begin{aligned}\mathbf{A} &= \mathbf{D}_c^{1/2}(\mathbf{D}_c^{-1}\mathbf{P}^{\mathrm{T}} - \mathbf{1}\mathbf{r}^{\mathrm{T}})\mathbf{D}_r^{-1/2} = \\ &= \mathbf{D}_c^{1/2}(\mathbf{P}^{\mathrm{T}} - \mathbf{c}\mathbf{r}^{\mathrm{T}})\mathbf{D}_r^{-1/2}\end{aligned} \qquad (2.13)$$

и, таким образом, является просто транспонированной матрицей, полученной выше для задачи строк. Отсюда следует, что и задача строк, и задача столбцов решаются путем сингулярного разложения одной и той же матрицы, называемой матрицей стандартизованных остатков (см. табл. 2.11):

$$\mathbf{A} = \mathbf{D}_r^{-1/2}\,(\mathbf{P} - \mathbf{r}\mathbf{c}^{\mathrm{T}})\,\mathbf{D}_c^{-1/2} \qquad (2.14)$$

Шаг 12. Матрица стандартизованных остатков $\mathbf{A}$ представляет собой таблицу размера $I \times J$ с элементами

$$a_{ij} = (p_{ij} - r_i c_j) / \sqrt{r_i c_j} \qquad (2.15)$$

Так, например, $a_{11} = (0.0544 - 0.0931 \times 0.6420) / \sqrt{0.0931 \times 0.6420} = -0.0218$

Таблица 2.11.
Стандартизованные остатки

Возрастная группа	Слишком быстро	В самый раз	Слишком медленно	Затрудняюсь ответить
18-24	-0,0218	0,0745	0,0207	-0,0620
25-34	0,0023	-0,0066	0,0324	-0,0174
35-44	-0,0151	0,0331	-0,0032	-0,0064
45-54	-0,0117	0,0191	0,0041	-0,0003
55-64	0,0310	-0,0427	-0,0175	-0,0055
65-74	0,0183	-0,0527	-0,0209	0,0409
75+	0,0009	-0,0444	-0,0301	0,0776

Посмотрим на формулу (2.15) более внимательно. В числителе стоит разность наблюдаемой относительной (т.е. выраженной в процентной форме) частоты p_{ij} в ячейке таблицы (ij) и ожидаемой относительной частоты $r_i c_j$, полученной как произведение соответствующих маргинальных относительных частот. Если мы умножим выражение в числителе на размер выборки n, то получим наблюдаемую частоту n_{ij} и ожидаемую частоту $(n_{i+}n_{+j}/n)$ соответственно.

Шаг 13. В таблицах 2.12., 2.13 и 2.14. мы приводим сингулярные числа, а также левые и правые сингулярные векторы, полученные в результате сингулярного разложения матрицы стандартизованных остатков $\mathbf{A}$:

$$\mathbf{A} = \mathbf{U\Gamma V^T}$$

Таблица 2.12.
Сингулярные числа (элементы матрицы $\mathbf{\Gamma}$)

0,1611
0,0617
0,0324
0,0000

Таблица 2.13.
Левые сингулярные векторы (элементы матрицы $\mathbf{U}$)

-0,6267	0,0888	-0,2293	-0,3051
-0,0937	-0,3761	0,7776	-0,1857
-0,1815	0,3513	-0,2252	-0,3450
-0,1059	0,2401	0,0882	0,0107
0,2331	-0,6108	-0,5227	0,1302
0,4470	-0,0937	-0,0611	-0,8462
0,5478	0,5364	0,0853	0,1420

Таблица 2.14.
Правые сингулярные векторы (элементы матрицы $\mathbf{V}$)

0,2067	-0,5036	-0,2485	0,8012
-0,6946	0,5269	-0,1910	0,4511
-0,2839	-0,2269	0,9072	0,2120
0,6279	0,646	0,2807	0,3311

Шаг 14. Если мы возведем в квадрат стандартизованные остатки (2.15), просуммируем их по всем $I \times J$ ячейкам таблицы, и умножим результат на размер выборки n, то получим величину хи-квадрат для этой таблицы сопряженности:

$$\chi^2 = n\sum_i\sum_j \frac{(p_{ij} - r_i c_j)^2}{r_i c_j} = 39{,}09$$

Таким образом, сингулярное разложение матрицы стандартизованных остатков $\mathbf{A}$ подразумевает декомпозицию статистики хи-квадрат, которая пропорциональна сумме квадратов элементов матрицы $\mathbf{A}$, т.е. следу матрицы $\mathbf{A}$.

Шаг 15. Из шага 14 следует, что статистика хи-квадрат может быть разложена на $I \times J$ компонент, имеющих вид

$$n \times \frac{(p_{ij} - r_i c_j)^2}{r_i c_j}$$

Так, например, для $I = J = 1$, получаем $1268 \times (0{,}0544 - 0{,}0931 \times 0{,}6420)^2 / (0{,}0931 \times 0{,}6420) =$
$= 1268 \times (-0{,}0218)^2 = 0{,}600$ (ср. a_{11} в табл. 2.11).

Те же самые значения получаются и в случае использования более привычных при вычислении статистики хи-квадрат понятий

$$\frac{(n_{ij} - n_{i+}n_{+j}/n)^2}{(n_{i+}n_{+j}/n)}$$

где $n_{i+}n_{+j}/n$ - ожидаемая частота. Например, для $I = J = 1$, получаем

$(69 - 118 \times 814 / 1268)^2 / (118 \times 814 / 1268) = 0{,}600$ (см. табл. 2.15).

ТАБЛИЦА 2.15.
КОМПОНЕНТЫ ХИ-КВАДРАТ

Возрастная группа	Слишком быстро	В самый раз	Слишком медленно	Затрудняюсь ответить
18-24	0,60	7,03	0,54	4,87
25-34	0,01	0,05	1,33	0,38
35-44	0,29	1,39	0,01	0,05
45-54	0,17	0,46	0,02	0,00
55-64	1,22	2,31	0,39	0,04
65-74	0,42	3,52	0,56	2,12
75+	0,00	2,50	1,15	7,36

Шаг 16. Сумма квадратов элементов матрицы $\mathbf{A}$ (табл. 2.11) дает нам величину общей инерции (total inertia) таблицы сопряженности:

$$\text{общая инерция} = \sum_i \sum_j \frac{(p_{ij} - r_i c_j)^2}{r_i c_j}$$

Таким образом, общая инерция есть величина хи-квадрат, деленная на размер выборки n.

$$\text{общая инерция} = \chi^2/n = 39{,}09/1268 = 0{,}0308$$

Значение общей инерции, равное 0,0308 довольно маленькое; другими словами, степень связи между строками и столбцами таблицы относительно слабая (см. рис. 2.2). Напомним, что в разделе 2.5. мы говорили о том, что максимальное значение инерции на единицу меньше, чем число столбцов или строк – в зависимости от того, которое из двух меньше; т.е. в нашем случае максимальное значение инерции могло бы равняться (*min* (7,4)) – 1 = 4 – 1 = 3.

Для того, чтобы корректно сравнивать значения хи-квадрат и общей инерции для таблиц разных размерностей и разных выборок, можно использовать хорошо известный коэффициент Крамера V:

$$V = \sqrt{\frac{\chi^2}{n(\min(I,J)-1)}}$$

где I – число строк, J – число столбцов.

2.8. КООРДИНАТЫ И ГРАФИЧЕСКОЕ ПРЕДСТАВЛЕНИЕ ТОЧЕК: СИММЕТРИЧНЫЕ И АСИММЕТРИЧНЫЕ КАРТЫ

Шаг 17. Число измерений в решении равно $K = min(I - 1, J - 1)$; в нашем случае $K = min$ (6, 3) = 3. Квадраты сингулярных чисел матрицы $\mathbf{A}$ (табл. 2.11), которые есть не что иное как собственные числа матриц $\mathbf{A^TA}$ или $\mathbf{AA^T}$ также разлагают общую инерцию на составные части. Последние обозначаются $\lambda_1, \lambda_2, \ldots \lambda_K$ и называются главными инерциями осей (principal inertia). По аналогии с методом главных компонент, главные инерции осей часто выражают в процентах от общей инерции: так, например, первая главная инерция равняется 0,02597, что составляет 82,4% общей инерции, равной 0,03083 (см. табл. 3.14).

ТАБЛИЦА 2.16.
ГЛАВНАЯ ИНЕРЦИЯ ОСЕЙ (СОБСТВЕННЫЕ ЗНАЧЕНИЯ)

	Главная инерция	**Объясненная инерция (%)**
Ось 1	0,0260	84,2
Ось 2	0,0038	12,4
Ось 3	0,0011	3,4
Ось 4	0,0000	0,0

Шаг 18. Главные координаты (principal coordinates) строк получаются применением (2.11) к задаче строк, т.е.:

$$\mathbf{F} = \mathbf{D}_r^{-1/2}\mathbf{U\Gamma}$$

или, в скалярных обозначениях,

$$f_{ik} = u_{ik}\gamma_k / \sqrt{r_i}$$

Например, $f_{11} = -0{,}6267 \times 0{,}1611 / \sqrt{0{,}0931} = -0{,}3310$ (см. табл. 2.17).

ТАБЛИЦА 2.17.
ГЛАВНЫЕ КООРДИНАТЫ СТРОК

Возрастная группа	**Ось 1**	**Ось 2**	**Ось 3**
18-24	-0,3310	0,0180	-0,0244
25-34	-0,0355	-0,0546	0,0594
35-44	-0,0627	0,0465	-0,0157
45-54	-0,0380	0,0330	0,0064
55-64	0,1020	-0,1024	-0,0460
65-74	0,2060	-0,0165	-0,0057
75+	0,3992	0,1497	0,0125

Шаг 19. Главные координаты столбцов получаются применением (2.11) к задаче столбцов, т.е.:

$$\mathbf{G} = \mathbf{D}_c^{-1/2}\mathbf{V}\mathbf{\Gamma}$$

или, в скалярных обозначениях,

$$g_{ij} = v_{jk}\gamma_k / \sqrt{c_j}$$

Например, $g_{42} = -0{,}6460 \times 0{,}0611 / \sqrt{0{,}1096} = -0{,}1204$ (см. табл. 2.18).

ТАБЛИЦА 2.18.
ГЛАВНЫЕ КООРДИНАТЫ СТОЛБЦОВ

Категория ответа	Ось 1	Ось 2	Ось 3
Слишком быстро	0,0416	-0,0388	-0,0101
В самый раз	-0,2481	0,0721	-0,0137
Слишком медленно	-0,2157	-0,0660	0,1388
Затрудняюсь ответить	0,3056	0,1204	0,0275

Получив набор координат точек, мы можем изобразить их графически. Так, на рис. 2.4., представлена карта строк и столбцов в двумерном пространстве. Для построения этой карты использовались два первых столбца матрицы $\mathbf{F}$ (для точек строк) и два первых столбца матрицы $\mathbf{G}$ (для точек колонок), где в обоих случаях первый столбец используется как координата по горизонтальной (x) оси, а второй – как координата по горизонтальной (y).

Три оси в совокупности объясняют 100% инерции, так что если бы мы рассмотрели трехмерную карту, то вся информация, содержащаяся в табл. 2.1., была бы на ней полностью представлена. Две первые оси в совокупности объясняют 84,2% + 12,4% = 96,6% общей инерции. Таким образом, перейдя в двумерное пространство из исходного трехмерного мы потеряли 3,4% информации (объясняемые как раз третьей осью), что является очень хорошим показателем качества решения.

Тем не менее, интерпретация расстояний на карте соответствий должна быть крайне осторожной. Во-первых, точки, располагающиеся близко друг к другу в двумерном пространстве, могут очень далеко отстоять друг от друга в трехмерном пространстве или пространстве еще более высокой размерности. Во-вторых, что еще более важно, напрямую интерпретировать расстояния мы можем только между точками, принадлежащими к одному набору переменных, т.е. отдельно между точками строк и отдельно между точками столбцов. Расстояния же между точками строк и точками столбцов напрямую не определены. Интерпретация взаимного расположения точек строк и точек столбцов осуществляется в терминах главных осей: противопоставления по горизонтальной и вертикальной осям справедливы и для точек строк, и для точек колонок; и сходное распределение точек из разных наборов вдоль одной из осей свидетельствует об их взаимосвязи.

В нашем примере самая молодая возрастная группа располагается на левом полюсе

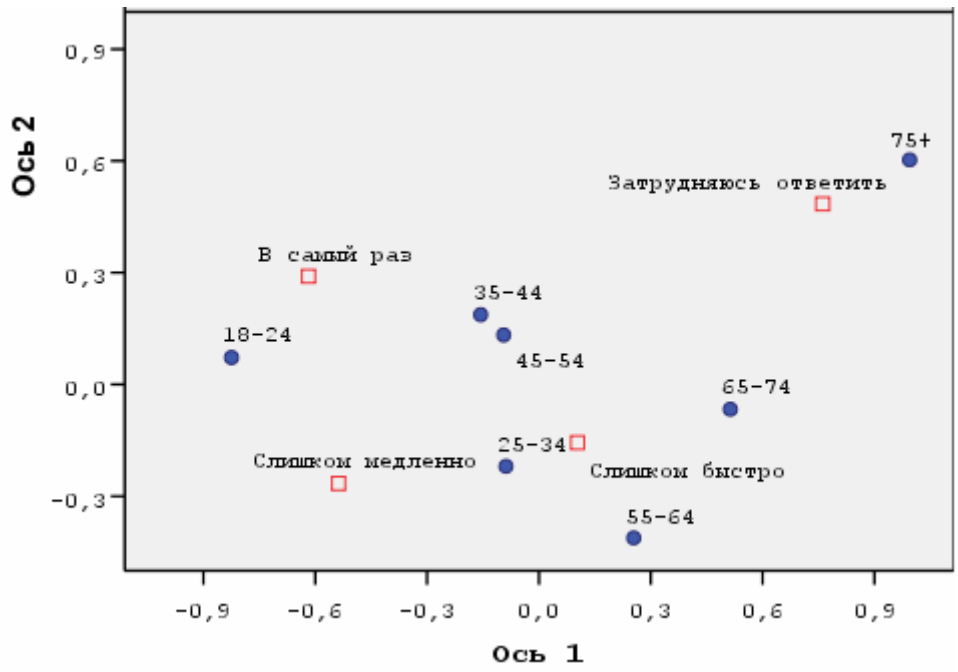


Рис.2.4. Графическое решение таблицы 2.1 в пространстве, образованном первыми двумя главными осями: симметричная карта (все точки изображены в главных координатах)

горизонтальной оси; далее, после значительного разрыва идут следующие три возрастные группы, затем – уже меньший разрыв отделяет от них следующие две группы, и, наконец, достаточно далеко от тех отстоит последняя, самая старшая возрастная группа, «75+». Возрастные группы фактически выстраиваются в порядке возрастания, однако разделяются неравными интервалами. При этом варианты ответов «в самый раз» и «слишком медленно» располагаются слева, вариант «слишком быстро» – примерно в середине, и вариант «затрудняюсь ответить» - справа. Таким образом, молодые группы ассоциируются с позицией, что развитие гражданских прав идет слишком медленными темпами или же в самый раз; в то время как для старших возрастных групп характерна более консервативная позиция, согласно которой развитие гражданских прав происходит слишком быстро. Вдобавок, можно сказать, что вариант «затрудняюсь ответить» доминирует в самой старшей возрастной группе.

Карта, изображенная на рис. 2.4., называется симметричной (symmetric plot). Несмотря на наглядность и удобство таких карт, существует опасность неверного истолкования результатов, если карта интерпретируется только визуально. Причина этой опасности в том, что и для точек строк, и для точек колонок используются главные координаты, которые представляют профили, а не вершины; а расстояния между профилями строк и профилями столбцов интерпретировать нельзя. Если бы, например, категории строк были представлены профилями, а категории столбцов – вершинами, то мы получили бы возможность интерпретировать расстояния между ними напрямую. Так, в разделе 2.5 (см. рис. 2.2) мы рассматривали ситуацию, когда профили строк располагались в пространстве,

образованном вершинами (точками столбцов) и показали, что чем ближе точка профиля, располагается к вершине, представляющей столбец, тем сильнее связь между данной строкой и данным столбцом (барицентрическое свойством анализа соответствий). Иными словами, расположение каждого профиля в пространстве вершин представляет собой взвешенное среднее вершин. Таким образом, для того, чтобы интерпретировать расстояния между точками, принадлежащими к разным наборам, точки строк (профили) должны быть представлены в пространстве точек столбцов (вершин), или наоборот. А для того, чтобы определить положение вершин, нам нужны не *главные координаты* (principal coordinates), а *стандартные координаты* (standard coordinates).

Шаг 20. Стандартные координаты строк рассчитываются делением главных координат на соответствующее сингулярное значение:

$$\mathbf{X} = \mathbf{F\Gamma}^{-1} = \mathbf{D}_r^{-1/2}\mathbf{U}$$

или, в скалярных обозначениях,

$$x_{ik} = f_{ik} / \gamma_k$$

Например, x_{11} = –03310/0,1611 = –2,0545 (см. табл. 2.19).

ТАБЛИЦА 2.19.
СТАНДАРТНЫЕ КООРДИНАТЫ СТРОК

Возрастная группа	Ось 1	Ось 2	Ось 3
18-24	-2,0545	0,2912	-0,7518
25-34	-0,2205	-0,8849	1,8298
35-44	-0,3891	0,7530	-0,4827
45-54	-0,2356	0,5345	0,1962
55-64	0,6328	-1,6584	-1,4193
65-74	1,2185	-0,2680	-0,1749
75+	2,4776	2,4259	0,3858

Шаг 21. Стандартные координаты столбцов рассчитываются делением главных координат на соответствующее сингулярное значение:

$$\mathbf{Y} = \mathbf{G\Gamma}^{-1} = \mathbf{D}_c^{-1/2}\mathbf{V}$$

или, в скалярных обозначениях,

$$y_{ik} = g_{ik} / \gamma_k$$

Например, y_{22} = 0,0721/0,0617 = 1,1682 (см. табл. 2.20).

ТАБЛИЦА 2.20.
СТАНДАРТНЫЕ КООРДИНАТЫ СТОЛБЦОВ

Категория ответа	Ось 1	Ось 2	Ось 3
Слишком быстро	0,2579	-0,6285	-0,3102
В самый раз	-1,5398	1,1682	-0,4234
Слишком медленно	-1,3389	-1,0701	4,2788
Затрудняюсь ответить	1,8966	1,9511	0,8477

Для того чтобы получить карту с изображенными на ней вершинами и профилями, аналогичную рис. 2.2, нужно использовать изобразить вершины в стандартных координатах, а профили – в главных координатах [Bendixen, 1996, p.27]. В нашем случае в качестве профилей мы представим точки строк, т.е. возрастные группы, которые будут располагаться в пространстве, образованном вершинами – точками столбцов, т.е. вариантами ответа. Таким образом, для точек строк мы возьмем главные координаты (табл. 2.17), а для точек столбцов – стандартные координаты (табл. 2.20). Полученная в двумерном решении карта, изображенная на рис 2.5. называется асимметричной.

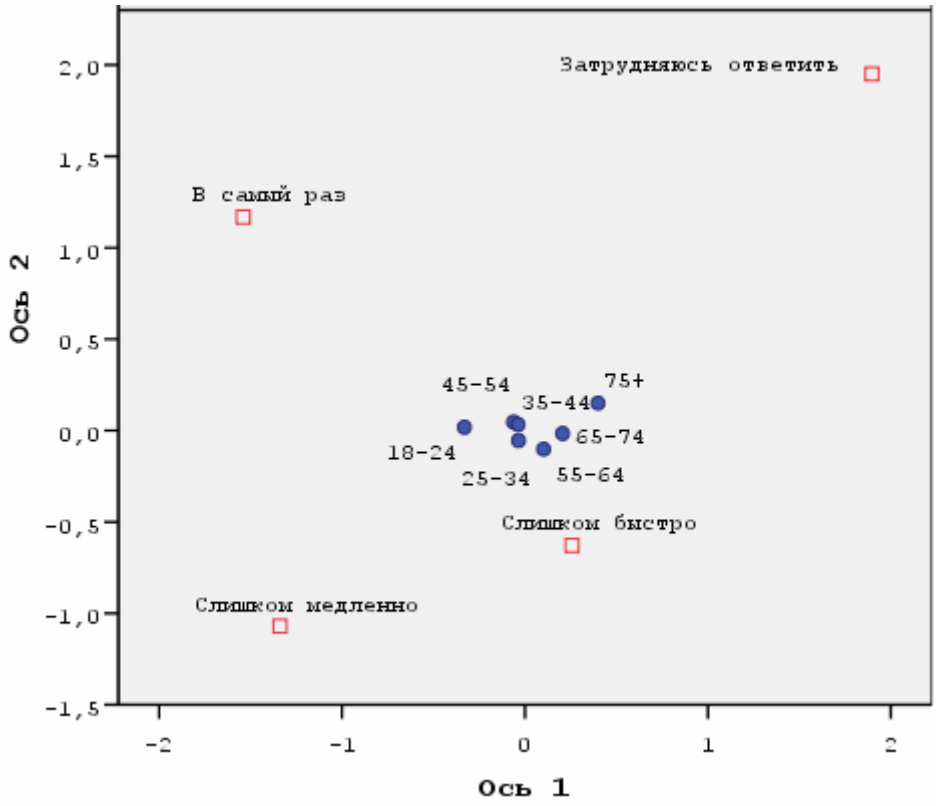


РИС.2.5. Графическое решение таблицы 2.1 в пространстве, образованном первыми двумя главными осями: асимметричная карта (точки столбцов (вершины) изображены в стандартных координатах, точки строк – в главных координатах)

Интерпретируя асимметричные карты, мы можем напрямую сравнивать расстояния между профилями и вершинами; в то время как на симметричных картах у нас вообще нет понятия вершины. Каждая точка-профиль на рис. 2.5 является взвешенным средним четырех точек-вершин, где весами являются элементы самих профилей. Отсюда, например, если мы припишем вершине «слишком быстро» вес 0,585 (см. профили строк в табл. 2.5); вершине «в самый раз» – вес 0,314; вершине «слишком медленно» – вес 0,059; а вершине «затрудняюсь ответить» – вес 0,042; то взвешенным средним этих четырех вершин будет точка «18-24 лет». В этом смысле точка-профиль приближается к той вершине, по которой у нее больше всего соответствующий элемент профиля (см. раздел 2.5): в нашем примере профиль «18-24» имеет наибольший вес по вершине «слишком быстро».

Таким образом, асимметричные карты имеют очень четкую и прямолинейную интерпретацию в отличие симметричных карт, где интерпретация менее очевидна. Почему же тогда на практике, как правило, используются симметричные карты? Основная причина кроется в том, что точки профилей занимают очень маленькую часть пространства, – как в первой ситуации на рис. 2.2. Другими словами, различия между профилями часто не слишком большие, и поэтому профили имеют тенденцию скапливаться в центре асимметричной карты. Иногда они практически сливаются друг с другом, так что даже не удается вывести метки на карте, чтобы понять, какая точка какой строке соответствует. Проблема усугубляется, когда мы имеем дело с еще большим числом профилей. Тем не менее, в случае высокой инерции асимметричные карты могут выглядеть достаточно привлекательно и существенно облегчать интерпретацию результатов анализа соответствий.

С другой стороны, использование асимметричной карты имеет смысл тогда, когда мы можем выделить описываемые и описывающие переменные, – как в нашем примере. Если же оба набора переменных равноценны, то, исходя из содержательных соображений, симметричная карта, вероятно, все же будет предпочтительнее.

Если сравнить рис. 2.4 и рис. 2.5, т.е. симметричную и асимметричную карту для одного и того же примера, то можно заметить, что позиции профилей строк (возрастных групп) фактически идентичны в обоих случаях. Расположение профилей столбцов друг относительно друга на симметричной карте выглядит очень похожим на расположение вершин на асимметричной карте, с той лишь разницей, что на этих двух картах разные единицы измерения. Фактически, для обоих наборов точек существует некий масштабирующий фактор (scaling factor) относительно одной оси, и другой масштабирующий фактор относительно второй оси. На самом деле, этот масштабирующий фактор есть не что иное как соответствующее оси сингулярное число (или квадратный корень из главной инерции оси). Говоря точнее, первая главная ось (горизонтальная) на рис. 2.4. соответствует значению инерции, равному 0,0260; квадратный корень из которого равен 0,161. Таким образом, по горизонтальной оси координаты профилей столбцов на рис. 1.1 составляют около 1/6 (0,161) координат соответствующих вершин на рис. 2.2. Относительно же вертикальной оси, квадратный корень из второй главной инерции (0,0038) составляет 0,062. Сжатие профилей строк по сравнению с соответствующими им вершинами по второй оси даже сильнее, чем по первой: координаты профилей составляют всего около 1/16 (0,062) координат соответствующих вершин.

2.9. ПОКАЗАТЕЛИ КАЧЕСТВА РЕШЕНИЯ: АБСОЛЮТНЫЕ И ОТНОСИТЕЛЬНЫЕ ВКЛАДЫ

Снижая размерность пространства, мы неизбежно теряем часть исходной информации. При этом ситуация усугубляется тем, что не все точки одинаково хорошо представлены в полученном решении, – точно также, как и в методе главных компонент. Поэтому для более корректной интерпретации результатов анализа соответствий используется ряд дополнительных статистик: прежде всего, вклады точек в инерцию осей и вклады осей в инерцию точек. Их также называют абсолютными и относительными вкладами.

Шаг 22. Каждая главная инерция раскладывается на компоненты $r_i f_{ik}^2$ для каждой строки i:

$$\lambda_k = \sum_i r_i f_{ik}^2$$

Или, в матричной форме,

$$\mathbf{D}_\lambda = \mathbf{F}^T \mathbf{D}_r \mathbf{F}$$

Компоненты инерции строк $r_i f_{ik}^2$ приведены в табл. 2.21. Например, для первой строки и первой оси мы имеем 0,0931 × (-0,3310)^2=0,01020. Если просуммировать столбцы матрицы, то мы получим собственные значения: например, λ_1 = 0,01020 + ... + 0,00779 = 0,0260 (ср. табл. 2.16).

ТАБЛИЦА 2.21.
КОМПОНЕНТЫ ИНЕРЦИИ СТРОК

Возрастная группа	Ось 1	Ось 2	Ось 3
18-24	0,01020	0,00003	0,00006
25-34	0,00023	0,00054	0,00064
35-44	0,00086	0,00047	0,00005
45-54	0,00029	0,00022	0,00001
55-64	0,00141	0,00142	0,00029
65-74	0,00519	0,00003	0,00000
75+	0,00779	0,00110	0,00001

Шаг 23. Вклады строк в главную инерцию оси определяются как компоненты инерции строк, деленные на главную инерцию оси λ_k:

$$r_i f_{ik}^2 / \lambda_k$$

Например, для первой строки и первой оси мы имеем: 0,01020/0,02597=0,3928 (см. табл. 2.22).

ТАБЛИЦА 2.22.
ВКЛАДЫ СТРОК В ИНЕРЦИЮ ОСЕЙ (АБСОЛЮТНЫЕ ВКЛАДЫ)

Возрастная группа	Ось 1	Ось 2	Ось 3
18-24	0,3928	0,0079	0,0526
25-34	0,0088	0,1414	0,6047
35-44	0,0329	0,1234	0,0507
45-54	0,0112	0,0577	0,0078
55-64	0,0549	0,3731	0,2732
65-74	0,1998	0,0088	0,0037
75+	0,3001	0,2877	0,0073

Интерпретация *абсолютных вкладов* следующая. Это показатель, говорящий о том, в какой степени геометрическая ориентация оси определяется конкретными точками. Абсолютные вклады используются при интерпретации осей, при попытке дать им название: так, точки с высокими абсолютными вкладами являются наиболее важными в контексте данной оси. Сумма абсолютных вкладов по каждой оси дает 100%. Для того, чтобы отобрать наиболее существенные для интерпретации оси точки, можно использовать точки, чей абсолютный вклад выше среднего. Средний абсолютный вклад получается делением 100% на число строк:

$$\text{средний абсолютный вклад} = \frac{1}{I}$$

В нашем примере 7 строк, и, следовательно, средний абсолютный вклад равен 1/7 = 0,1429. Этот порог превышают только три точки: «18-24», «65-74» и «75+». Но наибольшие вклады в инерцию горизонтальной оси дают две точки: «18-24» (≈40%) и «75+» (≈30%), что, в общем-то, не удивительно, поскольку они располагаются на полюсах оси, и в этом смысле основное противопоставление по этой оси будет проходить между самыми молодыми и самыми пожилыми. Две эти точки в совокупности объясняют горизонтальную ось на 40% + 30% = 70%, в то время как остальные точки вместе взятые объясняют оставшиеся 30% инерции оси.

Шаг 24. Для i-й строки компоненты инерции по всем K осям суммируются, образуя общую инерцию строки, которая определяется как масса, умноженная на квадрат расстояния от профиля строки до центроида,

$$\sum_j \frac{(p_{ij}/r_i - c_j)^2}{c_j} = \sum_i r_i f_{ik}^2$$

например, для последней строки: 0,00779 + 0,00110 + 0,00001 = 0,00890. Выражение слева идентично сумме квадратов элементов i-й строки матрицы $\mathbf{A}$ (ср. 2.15).

$$\sum_j s_{ji}^2 = \sum_j \frac{(p_{ij} - r_i c_j)^2}{r_i c_j}$$

Например, для последней строки: $0{,}0009^2 + 0{,}0444^2 + 0{,}0301^2 + 0{,}0776^2 = 0{,}00890$ (см. табл. 2.22).

ТАБЛИЦА 2.22.
ИНЕРЦИЯ СТРОК

18-24	0,01028
25-34	0,00140
35-44	0,00138
45-54	0,00052
55-64	0,00312
65-74	0,00523
75+	0,00890

Шаг 25. Квадрат корреляции строки и главной оси представляет собой компоненту инерции $r_i f_{ik}^2$, деленную на общую инерцию строки:

$$r_i f_{ik}^2 / \sum_j s_{ij}^2$$

Например, для первой строки и первой оси: 0,01020/0,01028 = 0,9917 (см. табл. 2.23).

ТАБЛИЦА 2.23.
ВКЛАДЫ ОСЕЙ В ИНЕРЦИЮ СТРОК (КВАДРАТЫ КОРРЕЛЯЦИИ, ОТНОСИТЕЛЬНЫЕ ВКЛАДЫ)

Возрастная группа	**Ось 1**	**Ось 2**	**Ось 3**
18-24	0,9917	0,0029	0,0054
25-34	0,1625	0,3840	0,4535
35-44	0,6204	0,3409	0,0387
45-54	0,5608	0,4234	0,0158
55-64	0,4522	0,4556	0,0922
65-74	0,9928	0,0064	0,0008
75+	0,8759	0,1232	0,0009

Геометрически это есть не что иное как косинус угла между профилем строки и главной осью. Данный показатель также называется *относительным вкладом.* Относительный вклад точки не зависит от ее массы, и показывает, насколько хорошо точка объясняется выбранной осью. Если относительный вклад оси в инерцию точки высокий, то угол между вектором точки и этой осью мал. В этом смысле точка как бы лежит в направлении оси, что предполагает высокую корреляцию между вектором точки и осью (см. шаг 27).

Сумма относительных вкладов каждой точки по всем осям равна 100%, что означает, что в

полном решении мы не теряем ни капли исходной информации. Однако, как правило, мы ограничиваемся рассмотрением небольшого числа осей, поэтому 100% будут недостижимы.

Для определения того, какие точки лучше всего объясняются выбранной осью, можно отбирать точки, чей относительный вклад превышает некий порог, например, 0,25 или 0,50, и др. А. Кутлалиев и А. Попов предлагают устанавливать порог именно на уровне не менее 0,50, так как в случае, если квадрат косинуса между вектором точки и осью равен 0,5, то угол между ними не более 45%. Таким образом, мы можем быть уверены, что не менее половины инерции данной точки принадлежит данной оси, а оставшаяся половина инерции распределена между другими осями, причем не больше, чем на анализируемой оси [Кутлалиев, Попов, 2005, стр.307].

В нашем примере порог 0,5 преодолевают все точки, кроме «25-34» (ее квадрат косинуса с первой осью около 0,16). Если мы посмотрим на карту соответствий, изображенную на рис 2.4., а также таблицу главных координат строк, то увидим, что точка «25-34» выбивается из общего порядка расположения возрастных групп на горизонтальной оси. Так, при движении вдоль горизонтальной оси слева направо, мы проходим точки «18-24» (координата по горизонтальной оси -0,3310), затем «35-44» (координата -0,0627), затем «45-52» (координата -0,0380), и только потом – идет точка «25-34» (с координатой -0,0355). На самом деле, утверждение о том, что эта точка нарушает порядок категорий, не совсем корректно, потому что ее вообще нельзя рассматривать в контексте горизонтальной оси из-за очень низкого относительного вклада.

Далее понятия «относительный вклад», «квадрат корреляции» и «квадрат косинуса» будут использоваться как синонимы.

Шаг 26. В пространстве сниженной размерности, K^*, объясненная инерция суммируется по K^* осям с целью получить меру *качества представленности* каждой строки:

$$\text{качество представленности } i\text{-й строки} = \sum_{k=1}^{K^*} r_i f_{ik}^2 \Big/ \sum_j s_{ij}^2$$

Например, качество представленности второй строки в двумерном пространстве вычисляется следующим образом: 0,1625 + 0,3840 = 0,5465. Другими словами, около 55% инерции этой строки сохраняется в двумерном решении, и около 45% - приходится на оставшуюся третью ось; таким образом, в двумерном пространстве эта точка достаточно плохо представлена, тогда как качество представленности остальных точек значительно выше, более 90% (см. табл. 2.24).

Геометрически показатель качества представленности есть не что иное как косинус угла между точкой и плоскостью (или, в общем случае, подпространством), образованном первыми K^* главными осями. Данный показатель является аналогом показателя «общности» (communalities) в анализе главных компонент.

ТАБЛИЦА 2.24.
КАЧЕСТВО ПРЕДСТАВЛЕННОСТИ СТРОК В ДВУМЕРНОМ ПРОСТРАНСТВЕ

18-24	0,9946
25-34	0,5465
35-44	0,9613
45-54	0,9842
55-64	0,9078
65-74	0,9992
75+	0,9991

Шаг 27. Извлечением квадратного корня из показателей в табл. 2.23 мы получаем корреляции между профилями и главными осями. Поскольку квадраты корреляций всегда положительны, то, для того, чтобы учесть направление связи, т.е. знак коэффициента корреляции, нужно приписать знак соответствующей координаты каждому из значений корреляции. Таким образом, мы получаем эквивалент показателя факторных нагрузок (factor loadings) в методе главных компонент. Например, первая строка, «18-24», имеет отрицательную первую координату (-0,3310, см. табл.2.17), и, следовательно, корреляция между этой строкой и первой главной осью составляет $-\sqrt{0.9917} = -0.9958$ (см. табл. 2.25).

ТАБЛИЦА 2.25.
КОРРЕЛЯЦИИ МЕЖДУ СТРОКАМИ И ГЛАВНЫМИ ОСЯМИ

Возрастная группа	**Ось 1**	**Ось 2**	**Ось 3**
18-24	-0,9958	0,0539	-0,0735
25-34	-0,4031	-0,6197	0,6734
35-44	-0,7877	0,5839	-0,1967
45-54	-0,7489	0,6507	0,1257
55-64	0,6725	-0,6750	-0,3036
65-74	0,9964	-0,0800	-0,0283
75+	0,9359	0,3510	0,0300

Следующие шаги, с 28-го по 33-й являются аналогами шагов с 22-го по 27-й, примененными к столбцам таблицы.

Шаг 28. Каждая главная инерция раскладывается на компоненты $c_j g_{jk}^2$ для каждого столбца j:

$$\lambda_k = \sum_j c_j g_{jk}^2$$

Или, в матричной форме,

$$\mathbf{D}_\lambda = \mathbf{G}^\mathrm{T}\mathbf{D}_c\mathbf{G}$$

Компоненты инерции строк $c_j g_{jk}^2$ приведены в табл. 2.26.

ТАБЛИЦА 2.26.
КОМПОНЕНТЫ ИНЕРЦИИ СТОЛБЦОВ

Категория ответа	Ось 1	Ось 2	Ось 3
Слишком быстро	0,00111	0,00097	0,00007
В самый раз	0,01253	0,00106	0,00004
Слишком медленно	0,00209	0,00020	0,00087
Затрудняюсь ответить	0,01024	0,00159	0,00008

Шаг 29. Вклады столбцов в главную инерцию (абсолютные вклады) определяются как компоненты инерции столбцов, деленные на главную инерцию оси λ_k:

$$c_j g_{jk}^2 / \lambda_k$$

(см. табл. 2.27).

ТАБЛИЦА 2.27.
ВКЛАДЫ СТОЛБЦОВ В ИНЕРЦИЮ ОСЕЙ (АБСОЛЮТНЫЕ ВКЛАДЫ)

Категория ответа	Ось 1	Ось 2	Ось 3
Слишком быстро	0,0427	0,2536	0,0618
В самый раз	0,4824	0,2777	0,0365
Слишком медленно	0,0806	0,0515	0,8230
Затрудняюсь ответить	0,3943	0,4173	0,0788

В нашем примере средний абсолютный вклад для столбцов равен ¼ = 0,25. Данный порог превышают две точки: «в самый раз» и «затрудняюсь ответить», которые в сумме объясняют почти 88% инерции горизонтальной оси. Причем эти же две точки вносят наибольший вклад и в инерцию второй оси (почти 70% в сумме). А, например, точка «слишком медленно» практически никак не влияет на геометрическую ориентацию первых двух осей, но зато на 82% объясняет третью ось, которую, впрочем, мы в данном решении не рассматриваем.

Шаг 30. Для j-го столбца компоненты инерции по всем K осям суммируются, образуя общую инерцию столбца, которая определяется как масса × квадрат расстояния от профиля столбца до центроида,

$$\sum_i \frac{(p_{ij} / r_i - c_j)^2}{c_j} = \sum_i c_j g_{jk}^2$$

(см. табл. 2.28).

ТАБЛИЦА 2.28.
ИНЕРЦИЯ СТОЛБЦОВ

Слишком быстро	0,00214
В самый раз	0,01362
Слишком медленно	0,00315
Затрудняюсь ответить	0,01191

Шаг 31. Квадрат корреляции столбца и главной оси (относительный вклад) представляет собой компоненту инерции $c_j g_{jk}^2$, деленную на общую инерцию столбца:

$$c_j g_{jk}^2 / \sum_i s_{ij}^2$$

(см. табл. 2.29).

ТАБЛИЦА 2.29.
ВКЛАДЫ ОСЕЙ В ИНЕРЦИЮ СТОЛБЦОВ (КВАДРАТЫ КОРРЕЛЯЦИЙ, ОТНОСИТЕЛЬНЫЕ ВКЛАДЫ)

Категория ответа	**Ось 1**	**Ось 2**	**Ось 3**
Слишком быстро	0,5182	0,4514	0,0304
В самый раз	0,9195	0,0776	0,0028
Слишком медленно	0,6633	0,0322	0,2745
Затрудняюсь ответить	0,8596	0,1335	0,0070

Для первой оси относительные вклады всех точек превышают порог 0,5. Наибольший квадрат корреляции с горизонтальной осью имеет точка «в самый раз», почти 92%, что означает что она практически полностью объясняется первой осью, и для интерпретации ее положения на карте соответствий нам не нужно привлекать вторую и третью оси. А, например, у точки «слишком быстро» квадрат корреляции с первой осью лишь немногим больше 0,5; а со второй – 0,45; и, следовательно, для интерпретации положения этой точки мы не можем ограничиться только первой осью или только второй осью, а должны принимать во внимание и первую, и вторую; в то время как для третьей оси ее относительный вклад уже незначителен (около 3%).

Шаг 32. В пространстве сниженной размерности, K^*, объясненная инерция суммируется по K^* осям с целью получить меру качества представленности каждой столбца:

$$\text{качество представленности } j\text{-го столбца} = \sum_{k=1}^{K^*} c_j g_{jk}^2 / \sum_i s_{ij}^2$$

(см. табл. 2.30).

ТАБЛИЦА 2.30.
КАЧЕСТВО ПРЕДСТАВЛЕННОСТИ СТОЛБЦОВ В ДВУМЕРНОМ ПРОСТРАНСТВЕ

Слишком быстро	0,9696
В самый раз	0,9971
Слишком медленно	0,6955
Затрудняюсь ответить	0,9931

В нашем примере все точки-столбцы достаточно хорошо представлены в двумерном пространстве. Тем не менее, при интерпретации карты соответствий следует принять во внимание, что точка «слишком медленно» представлена в двумерном решении на 70%, тогда как 30% ее инерции приходится на третью ось.

Шаг 33. Извлечением квадратного корня из показателей в табл. 2.23 мы получаем корреляции между профилями и главными осями. Поскольку квадраты корреляций всегда положительны, то, для того, чтобы учесть направление связи, т.е. знак коэффициента корреляции, нужно приписать знак соответствующей координаты каждому из значений корреляции. Таким образом, мы получаем эквивалент показателя факторных нагрузок (factor loadings) в методе главных компонент (см. табл. 2.31).

ТАБЛИЦА 2.31.
КОРРЕЛЯЦИИ МЕЖДУ СТОЛБЦАМИ И ГЛАВНЫМИ ОСЯМИ

Категория ответа	**Ось 1**	**Ось 2**	**Ось 3**
Слишком быстро	0,7199	-0,6719	-0,1744
В самый раз	-0,9589	0,2786	-0,0529
Слишком медленно	-0,8144	-0,1794	0,5239
Затрудняюсь ответить	0,9271	0,3654	0,0837

2.10 ПРАКТИЧЕСКИЕ РЕКОМЕНДАЦИИ

Шаг 34. Наконец, итоговые численные результаты анализа соответствий приводятся 1) в таблице собственных чисел (главных инерций) и процентов объясненной инерции, которые представлены в табл. 2.16; и 2) в таблице координат и вкладов строк и столбцов, которые сведены в табл. 2.32.

В большинстве статистических пакетов формат вывода численных результатов анализа соответствий совпадает с приведенным ниже. Также, значения вкладов часто домножают на 100 или 1000, с целью облегчить визуальное восприятие цифр.

ТАБЛИЦА 2.32.
ОСНОВНЫЕ СТАТИСТИКИ ДЛЯ СТРОК И СТОЛБЦОВ

Строки	Масса	Координаты		Инерция	Вклады				
		Ось 1	Ось 2		Точек в инерцию осей		Осей в инерцию точек		Качество в 2 осях
					Ось 1	Ось 2	Ось 1	Ось 2	
18-24	0,093	-0,331	0,018	0,334	0,393	0,008	0,992	0,003	0,995
25-34	0,181	-0,336	-0,055	0,046	0,009	0,141	0,162	0,384	0,546
35-44	0,218	-0,063	0,046	0,045	0,033	0,123	0,620	0,341	0,961
45-54	0,202	-0,038	0,033	0,017	0,011	0,058	0,561	0,423	0,984
55-64	0,136	0,102	-0,102	0,101	0,054	0,373	0,452	0,465	0,908
65-74	0,122	0,206	-0,017	0,170	0,200	0,009	0,993	0,006	0,999
75+	0,049	0,399	0,150	0,289	0,300	0,288	0,876	0,123	0,999
Столбцы									
Слишком быстро	0,642	0,042	-0,039	0,069	0,043	0,254	0,518	0,451	0,970
В самый раз	0,203	-0,248	0,072	0,442	0,482	0,278	0,920	0,078	0,997
Слишком медленно	0,045	-0,216	-0,066	0,102	0,081	0,051	0,663	0,062	0,725
Затрудняюсь ответить	0,110	0,306	0,120	0,386	0,394	0,417	0,860	0,133	0,993

В заключение, сформулируем несколько практических рекомендаций интерпретации решения анализа соответствий.

1. Используя анализ соответствий, мы работаем с профилями, а не с абсолютными частотами таблицы. В этом ключе анализ соответствий можно рассматривать как метод поиска схожих профилей. Так, если профили строк (или столбцов) похожи (что подразумевает сходство распределений их относительных частот), то на карте соответствий точки этих профилей будут лежать близко друг к другу. Чем сильнее различия между профилями, тем дальше друг от друга будут располагаться точки на карте.

2. Профили маргинальных сумм и для строк, и для столбцов, лежат в начале координат. Таким образом, точка, имеющая схожий со средним профиль, будет лежать вблизи центра.

3. Важно иметь в виду, что точки, лежащие близко друг к другу в пространстве двух осей, могут оказаться весьма далекими при добавлении третьей и более осей.

4. Расстояние между точками строк (или столбцов) является хи-квадрат расстояниям, т.е. взвешенным евклидовым расстоянием, где вес определяется по соответствующему элементу среднего профиля. Однако расстояние между точкой строки и точкой столбца напрямую не определено. Поэтому интерпретация близости точки строки и точки столбца должна осуществляться с осторожностью. Так, положение точки строки должно определяться не относительно одной конкретной точки столбца, а относительно расположения всех точек столбца, и наоборот.

5. В дополнение к расположению точек относительно друг друга, в анализе соответствий, как правило, интерпретируют оси и дают им названия, основываясь на порядке распределения точек вдоль осей (в этом плане интерпретация графического решения анализа соответствий похожа на

интерпретацию результатов многомерного шкалирования или метода главных компонент). При этом важно определить, какие точки являются наиболее существенными при интерпретации конкретной оси; а также качество представленности точек в полученном решении. Для того чтобы получить ответы на эти вопросы, используются дополнительные статистики – абсолютные и относительные вклады.

6. Важно понимать разницу между абсолютными и относительными вкладами. Вклад точки в инерцию оси (абсолютный вклад) служит основой для интерпретации и поиска названия (или «метки») оси; в то время как вклад оси в инерцию точки (относительный вклад) показывает, насколько хорошо точка объясняется выбранной осью. Как правило, точки, имеющие высокие абсолютные вклады, будут иметь и высокие квадраты корреляций с осью, но не наоборот [Greenacre, 1984]. Поскольку оба набора статистик всегда имеют положительные значения, необходимо соотносить их со знаком соответствующей координаты.

7. Точка может вносить большой вклад в инерцию оси двумя способами: во-первых, если она находится на большом расстоянии от центра тяжести (начала координат), даже при небольшой массе; и, во-вторых, если имеет большую массу и коррелирует с данной осью [Кутлалиев, Попов, 2005, стр.311].

8. Какое количество осей нужно выбрать для анализа? Фактически, смысл анализа соответствий состоит в том, чтобы представить исходную матрицу данных в пространстве как можно более низкой размерности. Другими словами, мы пытаемся объяснить данные с помощью наименьшего возможного числа параметров (так называемый принцип «научной бережливости Оккама» [Clausen, 1994, p.24]). Но с другой стороны, итоговое решение должно максимально полно описывать исходные данные, т.е. процент объясненной инерции должен быть достаточно высоким. Как преодолеть противоречие между двумя требованиями: желанием одновременно иметь и малую размерность искомого пространства, и высокий процент объясненной информации? Четкого ответа на этот вопрос нет в принципе, и его решение остается на совести исследователя. Тем не мене, для облегчения выбора можно использовать несколько более или менее формальных критериев. Данные критерии были сформулированы А. Крыштановским применительно к методу главных компонент, однако мы считаем, что они справедливы и для анализа соответствий:

Первый критерий – формально-статистический. Данный критерий, называемый критерием Кайзера, предлагает отбирать столько осей (размерностей), сколько есть собственных чисел, больших единицы [Крыштановский, 2006, стр.203]. При этом в методе главных компонент собственные значения, превышающие 1, объясняют большую долю дисперсии, чем в среднем по всем собственным значениям; а собственные значения, меньшие 1, объясняют меньшую долю дисперсии, чем в среднем. Однако в анализе соответствий используется не разложение матрицы по собственным значениям, а сингулярное разложение, и, следовательно, использование критерия Кайзера в чистом виде будет не совсем корректно из-за порога 1. Поэтому можно переформулировать критерий Кайзера следующим образом: отобрать для анализа все оси, чьи собственные значения превышают среднее по всем собственным значениям. Аналогичный подход предлагают использовать А. Кутлалиев и А. Попов [Кутлалиев, Попов, 2005, стр.306]

Второй критерий базируется на самостоятельном отборе числа осей, ориентируясь на то,

чтобы это число осей объясняло некий требуемый процент объясненной инерции; например, 70% или 80%, и т.д. [Крыштановский, 2006, стр.203].

Третий критерий основывается на так называемом методе «каменистой осыпи». Согласно этому подходу, строится график, на котором по оси абсцисс откладываются номера осей, а по оси ординат – значения собственных чисел для каждой из осей. Поскольку все собственные значения вычисляются в порядке убывания, график будет представлять собой понижающуюся кривую. Далее на этом графике, если это возможно, определяют точки, в которых происходит более или менее резкое понижение, после чего отбирается столько осей, сколько точек на графике расположено до момента такого рода резкого понижения [Крыштановский, 2006, стр.203].

Тем не менее, ни один из перечисленных критериев не дает доказательных оснований по отношению к выбору числа осей. Поэтому при определении размерности искомого пространства исследователь, по выражению Ю.Н. Толстовой, должен «лавировать» между «сциллой» и «харибдой», найдя в итоге такую ситуацию, когда и размерность пространства небольшая, и процент объясненной информации достаточно высок, и интерпретация удачна. Ситуация, типичная для анализа данных: все строится на постоянном человеко-машинном диалоге [Толстова, 2006].

ГЛАВА 3.
АНАЛИЗ МНОГОМЕРНЫХ ДАННЫХ И МНОЖЕСТВЕННЫЙ АНАЛИЗ СООТВЕТСТВИЙ

В предыдущей главе мы рассмотрели основные понятия и механизм анализа соответствий на примере небольшой таблицы. Однако в полной мере преимущества анализа соответствий раскрываются при анализе больших таблиц, когда визуальное сравнение абсолютных или относительных частот будет уже крайне малоэффективным.

В этой главе мы рассмотрим, как простой анализ соответствий может быть использован при исследовании таблиц множественных ответов и многомерных таблиц; а затем введем понятие множественного анализа соответствий и разберем его на конкретном примере.

3.1. АНАЛИЗ ТАБЛИЦ МНОЖЕСТВЕННЫХ ОТВЕТОВ

Примером ситуации, когда построение таблицы множественных ответов (multiple response) может весьма существенно облегчить работу с данными, является достаточно типичная для маркетинговых исследований задача анализа имиджа брендов. Существует множество вариантов постановки этой задачи. В самом общем виде и в самой мягкой формулировке суть ее состоит в следующем. Респондентам предлагают небольшой список брендов или продуктов, и просят по каждому из тех, которых они знают, выбрать из ряда характеристик или атрибутов те, которые, по их мнению, в наибольшей степени соответствуют продукту. В принципе, респондент может отметить несколько атрибутов для одного продукта; может отметить вообще все, или же ни одного. Как правило, бренды или продукты располагают в столбцах таблицы, а высказывания или атрибуты – в строках; и, таким образом, факт того, что респондент ставит в соответствие продукту А характеристику Х выражается в том, что на пересечении указанных строки и столбца ставится 1, тогда как в остальных ячейках стоят нули. Суммируя такие матрицы по всем респондентам, мы получаем сводную таблицу множественных ответов, анализ которой осложняется тем, что каждый бренд и каждую характеристику называет разное число респондентов; иначе говоря, у нас разные базы сравнения. Это как раз тот случай, когда преимущество использования хи-квадрат расстояния в анализе соответствий очевидно: последнее позволяет уравновесить разные базы, и учесть влияние брендов и характеристик как с высокой, так и с низкой частотой упоминаемости.

Рассмотрим подобную ситуацию более подробно. В табл. 3.1 приведены данные о

ТАБЛИЦА 3.1.
СООТВЕТСТВИЕ ИМИДЖЕВЫХ ХАРАКТЕРИСТИК БАНКАМ, АБСОЛЮТНЫЕ ЧАСТОТЫ

	Citibank	Home Credit and Finance bank	Raiffeisen Bank	Альфа банк	Банк Возрождение	Ренессанс Капитал	Русский стандарт	Сбербанк	Уралсиб
Серьезный и стабильный	94	23	109	126	23	8	68	400	46
Для всей семьи	47	27	27	83	11	7	47	342	4
Предлагает много выгодных услуг	71	36	48	102	19	8	68	198	30
Дружелюбен к клиентам	74	36	63	108	31	12	77	181	24
Понимает мои потребности	40	17	32	70	17	9	46	196	13
Ему можно доверять (не разгласит, не передаст сведения обо мне)	52	23	62	66	17	14	42	235	17
У него постоянные клиенты	75	27	74	112	25	14	61	331	23
Находится недалеко от дома/работы	34	12	22	62	10	7	38	385	25
Простота оформления необходимых бумаг	56	30	37	78	18	7	69	237	17
Имеет обширную сеть банкоматов	65	16	32	117	17	4	59	311	18
Заботится о клиентах	60	25	51	94	13	10	48	178	21
Условия его услуг понятны	57	26	51	89	18	13	58	255	19
В нем лучше всего брать кредит	36	45	34	60	13	7	58	148	11
Большая сеть отделений	45	17	22	103	10	6	65	356	23
Умеренные цены за услуги	33	23	25	58	7	5	38	236	15
Быстро выполняет денежные операции	53	26	46	94	13	8	53	241	19
Предоставляет всю нужную информацию	66	31	51	96	23	8	53	252	24
Приятная атмосфера, там себя чувствуешь хорошо	44	23	69	97	17	11	51	167	21
Индивидуальное отношение к клиенту	54	24	57	96	17	8	46	166	23

Источник: COMCON, Premier TGI, апрель-май 2006 г., Москва

соответствии девятнадцати имиджевых характеристик девяти московским банкам. Источником данных является регулярное синдикативное исследование Premier TGI (Стиль потребления среднего класса), проводимое компанией КОМКОН[6]. В ходе исследования респондентам, знающим (знание определялось по подсказке) тот или иной банк, предлагалось выбрать неограниченное число характеристик, наиболее подходящих, по их мнению, данному банку.

Как видно из табл. 3.1, наибольшие значения абсолютных частот по всем строкам приходятся на столбец «Сбербанк», что, в общем-то, не удивительно, поскольку Сбербанк обладает самой высокой известностью среди всех остальных банков. В противоположность этому, например, Банк Ренессанс Капитал обладает меньшей известностью, что выражается в меньших значениях абсолютных частот в соответствующем столбце. Очевидно, что напрямую сравнивать подобные данные нельзя. Тем не менее, благодаря использованию хи-квадрат расстояния, которое, напомним,

[6] Подробное описание исследования Premier TGI можно найти на сайте группы компаний КОМКОН: http://www.comcon-2.com/default.asp?trID=66

ТАБЛИЦА 3.2.
СИНГУЛЯРНЫЕ ЧИСЛА И ГЛАВНАЯ ИНЕРЦИЯ ОСЕЙ ДЛЯ ТАБЛ. 3.1.

Ось	Сингуляр-ное число	Главная инерция (собственное значение)	Величина хи-квадрат[a]	Значи-мость	Объясненная инерция	
					Процент	Кумулятивный процент
1	0,184	0,034			0,643	0,643
2	0,095	0,009			0,170	0,813
3	0,064	0,004			0,078	0,891
4	0,047	0,002			0,042	0,933
5	0,038	0,001			0,028	0,961
6	0,033	0,001			0,021	0,982
7	0,024	0,001			0,011	0,993
8	0,019	0,000			0,007	1,000
ВСЕГО		0,052	572,284	0,000	1,000	1,000

[a] 144 степени свободы

является взвешенным аналогом евклидова расстояния, в анализе соответствий различные базы уравновешиваются.

В результате применения анализа соответствий к табл. 3.1, мы получаем восемь осей, сингулярные числа и главная инерция для которых приведены в табл. 3.2. Несмотря на то, что полученная величина хи-квадрат 572,284 при 144 степенях свободы является значимой, само применение критерия хи-квадрат для таблицы множественных ответов, строго говоря, не вполне осмыслено. Собственные значения (величина главной инерции) для каждой из осей показаны на

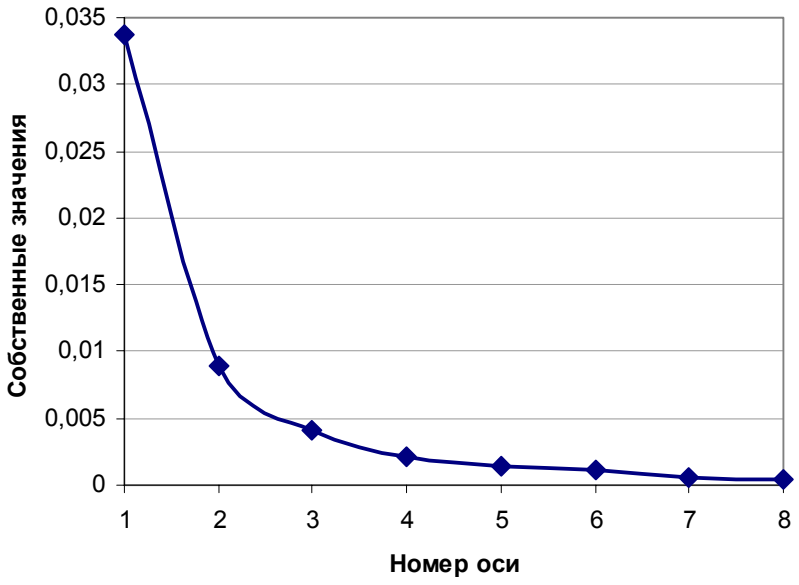


РИС. 3.1. СОБСТВЕННЫЕ ЗНАЧЕНИЯ ПОЛУЧЕННЫХ ОСЕЙ ДЛЯ ТАБЛ. 3.1: ГРАФИК «КАМЕНИСТОЙ ОСЫПИ»

рис 3.1. в виде графика «каменистой осыпи». Так, относительно резкий скачок происходит при переходе от двух осей к трем; так что, по-видимому, целесообразно остановиться на двумерном решении. Две первые оси в совокупности объясняют 81,3% инерции исходной таблицы, что является достаточно хорошим показателем качества решения. Тем не менее, по некоторым содержательным соображениям, которые мы озвучим ниже, представляется важным включить в рассмотрение и третью ось. Три первых оси в совокупности объясняют уже 89,1% инерции, что означает, что только около 10% инерции приходится на оставшиеся оси.

Итак, вначале мы рассмотрим двумерное решение табл. 3.1, а затем, в следующем разделе, – трехмерное, и сравним полученные результаты.

Интерпретация двумерного решения

Карта, образованная первыми двумя осями, представлена на рис. 3.2. Основные статистики для строк и столбцов приведены в табл. 3.3.

Для того, чтобы получить наиболее корректную и последовательную интерпретацию результатов анализа соответствий, необходимо вначале определить, какие точки мы будем считать описываемыми, а какие – описывающими. Иначе говоря, будем ли мы рассматривать положение банков в пространстве характеристик, или положение характеристик в пространстве банков. В этом

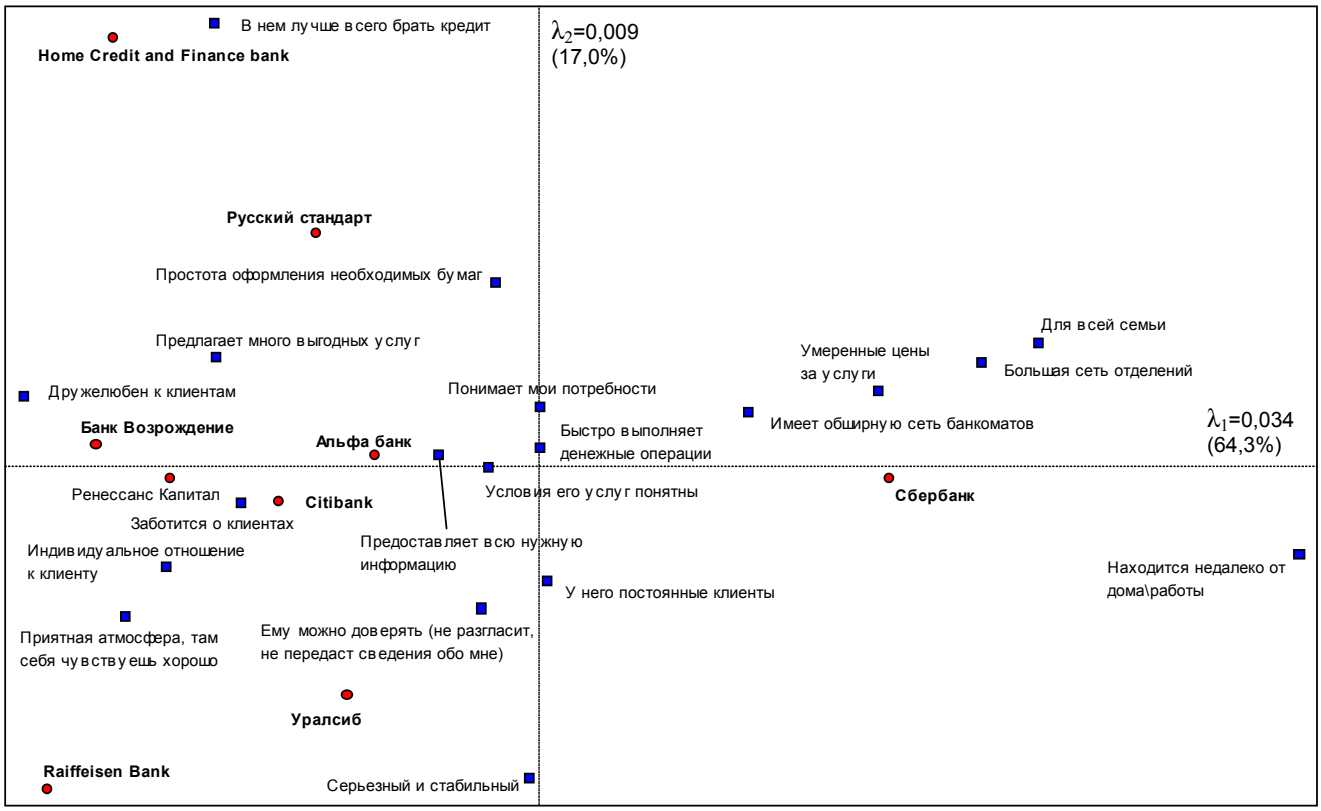


РИС. 3.2. ГРАФИЧЕСКОЕ РЕШЕНИЕ ТАБЛ. 3.1 В ПРОСТРАНСТВЕ, ОБРАЗОВАННОМ ПЕРВОЙ И ВТОРОЙ ОСЯМИ (СИММЕТРИЧНАЯ КАРТА)

ТАБЛИЦА 3.3.
ОСНОВНЫЕ СТАТИСТИКИ ДЛЯ СТРОК И СТОЛБЦОВ, ДВУМЕРНОЕ РЕШЕНИЕ

Строки	Масса	Координаты		Инерция	Вклады				Качество в 2 осях
		Ось 1	Ось 2		Точек в инерцию осей		Осей в инерцию точек		
					Ось 1	Ось 2	Ось 1	Ось 2	
Серьезный и стабильный	0,082	-0,030	-0,600	0,003	0,000	0,313	0,004	0,824	0,828
Для всей семьи	0,055	0,632	0,283	0,005	0,119	0,046	0,777	0,080	0,857
Предлагает много выгодных услуг	0,053	-0,432	0,214	0,003	0,054	0,026	0,675	0,086	0,761
Дружелюбен к клиентам	0,056	-0,676	0,176	0,005	0,138	0,018	0,896	0,031	0,927
Понимает мои потребности	0,040	0,030	0,089	0,000	0,000	0,003	0,018	0,079	0,097
Ему можно доверять (не разгласит, не передаст сведения обо мне)	0,048	-0,078	-0,300	0,002	0,002	0,046	0,035	0,265	0,300
У него постоянные клиенты	0,068	-0,017	-0,227	0,001	0,000	0,037	0,006	0,526	0,532
Находится недалеко от дома/работы	0,055	0,978	-0,164	0,010	0,284	0,016	0,940	0,014	0,953
Простота оформления необходимых бумаг	0,050	-0,028	0,364	0,001	0,000	0,070	0,008	0,690	0,698
Имеет обширную сеть банкоматов	0,059	0,294	0,044	0,002	0,028	0,001	0,411	0,005	0,415
Заботится о клиентах	0,046	-0,388	-0,083	0,002	0,038	0,003	0,773	0,018	0,791
Условия его услуг понятны	0,054	-0,042	0,005	0,000	0,001	0,000	0,079	0,000	0,080
В нем лучше всего брать кредит	0,038	-0,422	0,908	0,005	0,037	0,330	0,244	0,581	0,825
Большая сеть отделений	0,059	0,601	0,151	0,005	0,117	0,014	0,824	0,027	0,851
Умеренные цены за услуги	0,040	0,450	0,187	0,002	0,045	0,015	0,787	0,070	0,857
Быстро выполняет денежные операции	0,051	-0,012	0,037	0,000	0,000	0,001	0,011	0,051	0,062
Предоставляет всю нужную информацию	0,055	-0,125	0,006	0,000	0,005	0,000	0,359	0,000	0,360
Приятная атмосфера, там себя чувствуешь хорошо	0,046	-0,546	-0,291	0,003	0,074	0,041	0,718	0,105	0,823
Индивидуальное отношение к клиенту	0,045	-0,492	-0,198	0,002	0,059	0,019	0,841	0,070	0,911
ВСЕГО по строкам	1,000			0,052	1,000	1,000			
Столбцы									
Citibank	0,097	-0,338	-0,065	0,003	0,060	0,004	0,667	0,013	0,680
Home Credit and Finance bank	0,045	-0,530	0,901	0,007	0,068	0,384	0,333	0,496	0,829
Raiffeisen Bank	0,084	-0,652	-0,605	0,010	0,194	0,323	0,628	0,278	0,906
Альфа банк	0,157	-0,227	0,021	0,004	0,044	0,001	0,422	0,002	0,424
Банк Возрождение	0,029	-0,558	0,039	0,003	0,050	0,000	0,635	0,002	0,636
Ренессанс Капитал	0,015	-0,433	-0,064	0,002	0,016	0,001	0,285	0,003	0,289
Русский стандарт	0,096	-0,267	0,445	0,004	0,037	0,200	0,350	0,499	0,848
Сбербанк	0,442	0,464	-0,029	0,018	0,517	0,004	0,990	0,002	0,992
Уралсиб	0,036	-0,265	-0,466	0,003	0,014	0,083	0,161	0,255	0,416
ВСЕГО по столбцам	1,000			0,052	1,000	1,000			

выборе мы должны руководствоваться содержательной задачей. Так, вероятно, более целесообразным будет расположить банки в пространстве характеристик, предварительно

интерпретировав оси и дав им названия.

Интерпретация осей осуществляется на основе вкладов, которые каждая точка вносит в инерцию рассматриваемых осей (абсолютных вкладов). Мы имеем 19 высказываний, и, следовательно, средний абсолютных вклад для строк будет равен 1/19 = 0,0526. Таким образом, в качестве точек, в наибольшей степени определяющих геометрическую ориентацию осей, мы будем рассматривать те точки, абсолютный вклад которых превышает порог 0,0526. Применительно к горизонтальной оси это точки (в порядке убывания значения вклада): «находится недалеко от дома, работы» (абсолютный вклад 0,284), «дружелюбен к клиентам» (0,138), «для всей семьи» (0,119), «большая сеть отделений» (0,117), «приятная атмосфера, там себя чувствуешь хорошо» (0,074) и «индивидуальное отношение к клиенту» (0,059). При этом первая, третья и четвертая из названных точек имеют положительные координаты по первой оси, а вторая, пятая и шестая – отрицательные координаты (заметим, что понятия «положительный» и «отрицательный» ни в коем случае не несут никакой содержательной нагрузки, а используются исключительно для обозначения направления осей). Противоположные полюса горизонтальной оси могут быть представлены следующим образом:

«отрицательное» направление «положительное» направление

- Дружелюбен к клиентам
- Приятная атмосфера, там себя чувствуешь хорошо
- Индивидуальное отношение к клиенту

- Находится недалеко от дома, работы
- Для всей семьи
- Большая сеть отделений

Очевидно, что горизонтальную ось можно определить как «клиентоориентированность» – «территориальное удобство». При этом, в нашем случае геометрически противоположные полюса не являются, строго говоря, логически противоположными. Тем не менее, поскольку горизонтальная ось объясняет наибольшую долю инерции, самые сильные различия в восприятии имиджа банков будут наблюдаться именно по этому фактору.

Если для определения смысла и геометрической ориентации осей мы руководствовались, прежде всего, точками с высокими абсолютными вкладами; то для получения дополнительной информации и проверки сделанных выводов можно использовать точки, которые имеют высокие значения квадрата корреляции с осью, пусть даже при невысоких абсолютных вкладов. Так, например, абсолютный вклад точки «заботится о клиентах» в горизонтальную ось равен всего 0,038, и она находится ближе к центру, чем три названные выше осеобразующие точки. Тем не менее, она довольно сильно скоррелирована с осью (квадрат корреляции равен 0,773) и располагается как раз в направлении отрицательного полюса, т.е. «клиентоориентированности». Таким образом, положение данной точки косвенно подтверждает корректность нашей интерпретации горизонтальной оси.

Аналогично, принимая во внимание величину абсолютных вкладов и знак координат соответствующих точек, противоположные полюса вертикальной оси можно схематично изобразить в виде:

«отрицательное» направление «положительное» направление

- Серьезный и стабильный
- В нем лучше всего брать кредит
- Простота оформления необходимых бумаг

Кроме того, при интерпретации вертикальной оси следует также принять во внимание положение точки «у него постоянные клиенты», которая, хотя и имеет невысокий абсолютный вклад (всего лишь 0,006), но скоррелирована с осью (квадрат корреляции равен 0,526) и располагается в направлении отрицательного полюса, т.е. в том же направлении, что и точка «серьезный и стабильный». Таким образом, наличие постоянных клиентов воспринимается респондентами как атрибут серьезного и стабильного банка.

Фактически, по второй оси, стабильность противопоставляется простоте получения кредита и, возможно, других банковских услуг. Любопытно, что серьезность и стабильность банка вовсе не означает, что в нем лучше всего брать кредит; поскольку данные характеристики находятся на противоположных полюсах данной оси.

В итоге, с помощью анализа соответствий мы определили два ключевых фактора, определяющих имидж банков: «клиентоориентированность – территориальное удобство» и «стабильность – простота получения кредита». Эти два фактора образуют пространство, в котором теперь можно изобразить банки. Убрав с карты точки, представляющие высказывания, и заменив их

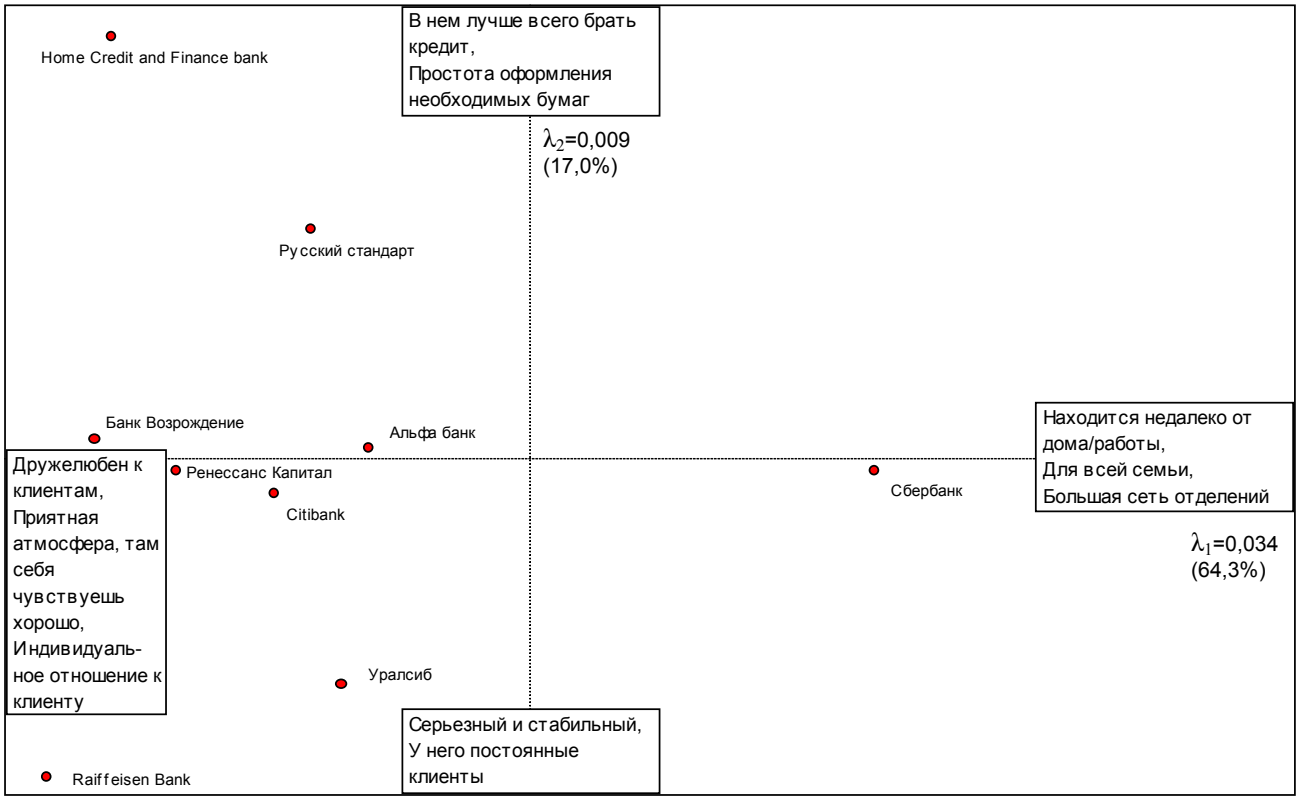


РИС. 3.3. ГРАФИЧЕСКОЕ РЕШЕНИЕ ТАБЛ. 3.1: БАНКИ ПРЕДСТАВЛЕНЫ В ПРОСТРАНСТВЕ ХАРАКТЕРИСТИК, ОБРАЗОВАННЫМ ПЕРВОЙ И ВТОРОЙ ОСЯМИ

соответствующими метками осей (см. рис. 3.3), мы получаем в каком-то смысле даже более информативное графическое решение, чем простая симметричная карта (рис. 3.2). Во-первых, четко обозначены полюса осей. И, во-вторых, на такой карте нет опасности неверной интерпретации расстояния между точками строк и точками столбцов, поскольку первые заменены на метки осей. Таким образом, у нас нет больше соблазна сравнивать расстояния между точками из разных наборов, чего, в общем-то, делать нельзя. Сравнивать же расстояния между точками, принадлежащими к одному набору, т.е. в данном случае, между банками, мы, по-прежнему, вправе. Заметим, что подобная карта не является асимметричной, так как у нас по-прежнему нет понятия вершин (см. раздел 2.8).

Начнем интерпретацию положения банков с точки «Сбербанк». Это – единственная точка, расположенная в правой полуплоскости; все остальные находятся слева от центра. Вдобавок, масса точки «Сбербанк» (0,442) практически равна массе остальных точек, вместе взятых (совокупная масса оставшихся точек столбцов равна 1 – 0,442 = 0,558). Поэтому первый же вывод, который мы можем сделать, состоит в том, Сбербанк воспринимается скорее как имеющий удобное территориальное расположение, чем как клиентоориентированный, в то время как остальные рассматриваемые банки, наоборот, в большей степени являются клиентоориентированными по сравнению со Сбербанком. При этом, что примечательно, относительно Сбербанка нельзя сказать, насколько он ближе к полюсу «серьезный и стабильный» или же к полюсу «удобство получения кредита», потому что точка практически лежит на горизонтальной оси, и, следовательно, ее координата по вертикальной оси и относительный вклад близки к нулю. Это означает, что для Сбербанка в одинаковой степени характерны атрибуты и верхнего, и нижнего полюса; или же в одинаковой степени не характерны ни те, ни другие. Фактически, в контексте вертикальной оси характеристики Сбербанка мало чем отличаются от средних показателей по всем банкам. Таким образом, он «серьезен и стабилен» и «удобен при получения кредита» ровно настолько, насколько все банки в среднем; следовательно, по этому фактору он ничем от среднего не отличается.

Далее, чем левее расположена точка, тем в большей степени соответствующий ей банк воспринимается как клиентоориентированный. Так, Raiffeisen Bank, находящийся левее всех (координата по горизонтальной оси -0,652) и достаточно сильно скоррелированый с «отрицательным» направлением горизонтальной оси (квадрат корреляции равен 0,628), является наиболее клиентоориентированным из рассматриваемых банков. Более того, он же воспринимается еще и как самый серьезный и стабильный, поскольку расположен ниже всех и удовлетворительно объясняется вертикальной осью (относительный вклад 0,297).

Следующим по уровню «клиентоориентированности» идет Банк Возрождение (координата по горизонтальной оси -0,558; квадрат корреляции 0,669), относительно которого нельзя сказать, насколько он ближе к полюсу «серьезный и стабильный» или же к полюсу «удобство получения кредита», поскольку по вертикальной оси он находится в районе нуля и имеет ничтожный относительный вклад, так же, как и Сбербанк. В известном смысле, Банк Возрождение и Сбербанк можно рассматривать как противоположности: для них обоих не существенно противопоставление по вертикальной оси; в то время как по горизонтальной они разносятся по контрастным полюсам, где первый воспринимается как клиентоориентированный, а второй – как имеющий удобное

территориальное расположение.

Противоположностью Raiffeisen Bank по вертикальной оси является Home Credit & Finance Bank, который так же, как и первый, воспринимается как клиентоориентированный (координата по горизонтальной оси равна -0,530, что лишь немного меньше по модулю, чем у Банка Возрождение), однако, в силу того, что находится ближе всех к верхнему полюсу вертикальной оси, является с точки зрения респондентов наиболее удобным для получения кредита, но при этом в значительно меньшей степени «серьезным и стабильным», чем остальные банки. Последнее, в общем-то, не удивительно, поскольку Home Credit & Finance Bank появился на российском рынке потребительского кредитования сравнительно недавно (с 2002 года[7]), и, возможно, еще не успел заслужить авторитет «серьезного и стабильного» в глазах потребителей, но, тем не менее, приобрел широкую известность благодаря выгодным кредитным предложениям.

По сравнению с Home Credit & Finance Bank, Банк Русский Стандарт, занимающий на сегодняшний день первое место среди частных банков страны по объемам кредитования населения[8], расположен значительно ниже: его координата по вертикальной оси (0,901) почти в два раза меньше, чем у Home Credit & Finance Bank (0,445), что означает, что Home Credit & Finance Bank воспринимается как почти в два раза «более удобный» для получения кредита, чем Русский Стандарт. Но, с другой стороны, это также означает, что Русский Стандарт, который сильнее сдвинут вниз, воспринимается как более «серьезный и стабильный», чем Home Credit & Finance Bank; а также как более удобный в территориальном плане: точка «Русский Стандарт» находится не только ниже, но и правее. Полученные выводы вполне соответствуют и экспертной оценке автора: так, Home Credit & Finance Bank, действительно предлагает более выгодные условия получения кредита, чем Банк Русский Стандарт; однако последний имеет значительно более широкие каналы дистрибуции и обширную региональную сеть, и, кроме того, раньше начал деятельность на рынке, чем, несомненно, заслужил определенную репутацию.

Точка «Citibank» достаточно хорошо объясняется горизонтальной осью. Уровень клиентоориентированности этого банка воспринимается как несколько более низкий, чем у Home Credit & Finance Bank (координата по горизонтальной оси первого равна -0,338 против -0,530 у второго); при этом противопоставление факторов по вертикальной оси для Citibank'а не актуально: инерция соответствующей ему точки объясняется вертикальной осью всего на 1,3%, а вторая координата близка к 0.

Что касается остальных банков – Банка Ренессанс Капитал, Банка Уралсиб и Альфа-Банка, то они довольно плохо представлены в двумерном пространстве: суммы относительных вкладов по первым двум осям равны 0,289; 0,416 и 0,424 соответственно. Следовательно, для объяснения положения этих точек нам необходимо выходить в пространство более высокой размерности, чем двумерное.

[7] Информация с сайта самого банка: http://www.homecredit.ru/Misc/Bank_info/Bank_History.shtm
[8] По данным самого банка: http://www.rs.ru/ru/about/

3.2. ИНТЕРПРЕТАЦИЯ ТРЕХМЕРНОГО РЕШЕНИЯ

Подключив к анализу третью ось, объясняющую 7,8% инерции; мы получаем 89,1% объясненной инерции в совокупности. Координаты точек по третьей оси, а также абсолютные и относительные вклады и показатели качества представленности точек в трехмерном пространстве приведены в табл. 3.4. Карта плоскости, образованной второй и третьей осями, представлена на рис. 3.4.

Для интерпретации третьей оси воспользуемся той же схемой, что и ранее, т.е. вначале выберем точки, чей абсолютный вклад выше среднего, и затем определим противоположные полюса оси с учетом знака координат точек:

«отрицательное» направление → «положительное» направление

- Имеет обширную сеть банкоматов
- Большая сеть отделений

- Ему можно доверять (не разгласит, не предаст сведения обо мне)
- В нем лучше всего брать кредит

Таким образом, третью ось можно определить как «наличие большой сети – доверие, надежность». Заметим, что фактор «наличие большой сети» отнюдь не тождественен фактору «территориальное удобство», который мы определили в рамках первой оси. Если территориальное удобство предполагает близость отделений банка к дому/работе (квадрат корреляции характеристики «находится недалеко от дома/работы» с положительным направлением первого фактора огромен: 0,940), то фактор «наличие большой сети» никак не связан с непосредственной территориальной близостью (квадрат корреляции той же характеристики с третьей осью равен всего 0,007). С другой стороны, точно также и непосредственная территориальная близость не обязательно предполагает наличие большой сети отделений и банкоматов.

Интересно, что фактор «банк, заслуживающий доверия», находящийся на положительном полюсе третьей оси, не тождественен таким характеристикам, как, например «серьезный и стабильный» или «индивидуальное отношение к клиенту», поскольку первая практически полностью принадлежит второй оси, а вторая находится на противоположном полюсе третьей оси. При этом характеристика «в нем лучше всего брать кредит», которая имеет высокий абсолютный вклад и положительную корреляцию с третьей осью, была уже нами «задействована» ранее при интерпретации второй оси. Данная ситуация похожа на ту, которая часто возникает в анализе главных компонент, когда одна и та же переменная имеет высокое значение факторной нагрузки сразу для нескольких факторов. Тем не менее, при внимательном изучении таблицы вкладов мы можем заменить, что характеристика «в нем лучше всего брать кредит» имеет в два раза более высокий вклад во вторую ось (0,311), чем в третью (0,163); а также более чем в четыре раза сильнее скоррелирована со второй осью (0,548), чем с третьей (0,129). Следовательно, эта характеристика в

большей степени относится ко второй оси, чем к третьей. Все же, при интерпретации третьей оси мы также вправе учесть ее влияние. Однако на положительном полюсе третьей оси у нас есть

ТАБЛИЦА 3.4.
ОСНОВНЫЕ СТАТИСТИКИ ДЛЯ СТРОК И СТОЛБЦОВ, ТРЕХМЕРНОЕ РЕШЕНИЕ

Строки	**Координаты**	**Вклады**						
	Ось 3	**Точек в инерцию осей**			**Осей в инерцию точек**			**Качество в 3 осях**
		Ось 1	Ось 2	Ось 3	Ось 1	Ось 2	Ось 3	
Серьезный и стабильный	0,048	0,000	0,313	0,003	0,004	0,824	0,004	0,832
Для всей семьи	0,185	0,119	0,046	0,029	0,777	0,080	0,023	0,880
Предлагает много выгодных услуг	-0,272	0,054	0,026	0,061	0,675	0,086	0,093	0,854
Дружелюбен к клиентам	-0,119	0,138	0,018	0,012	0,896	0,031	0,010	0,937
Понимает мои потребности	-0,037	0,000	0,003	0,001	0,018	0,079	0,009	0,106
Ему можно доверять (не разгласит,не передаст сведения обо мне)	0,551	0,002	0,046	0,230	0,035	0,265	0,605	0,905
У него постоянные клиенты	0,143	0,000	0,037	0,022	0,006	0,526	0,141	0,673
Находится недалеко от дома/работы	0,140	0,284	0,016	0,017	0,940	0,014	0,007	0,960
Простота оформления необходимых бумаг	-0,014	0,000	0,070	0,000	0,008	0,690	0,001	0,699
Имеет обширную сеть банкоматов	-0,545	0,028	0,001	0,272	0,411	0,005	0,491	0,907
Заботится о клиентах	-0,155	0,038	0,003	0,017	0,773	0,018	0,043	0,834
Условия его услуг понятны	0,126	0,001	0,000	0,013	0,079	0,000	0,247	0,327
В нем лучше всего брать кредит	0,518	0,037	0,330	0,159	0,244	0,581	0,128	0,953
Большая сеть отделений	-0,349	0,117	0,014	0,113	0,824	0,027	0,097	0,948
Умеренные цены за услуги	0,190	0,045	0,015	0,023	0,787	0,070	0,049	0,906
Быстро выполняет денежные операции	-0,064	0,000	0,001	0,003	0,011	0,051	0,102	0,164
Предоставляет всю нужную информацию	-0,035	0,005	0,000	0,001	0,359	0,000	0,010	0,370
Приятная атмосфера, там себя чувствуешь хорошо	0,078	0,074	0,041	0,004	0,718	0,105	0,005	0,828
Индивидуальное отношение к клиенту	-0,168	0,059	0,019	0,020	0,841	0,070	0,034	0,945
ВСЕГО по строкам		1,000	1,000	1,000				
Столбцы								
Citibank	-0,186	0,060	0,004	0,052	0,667	0,013	0,070	0,750
Home Credit and Finance bank	0,536	0,068	0,384	0,200	0,333	0,496	0,118	0,947
Raiffeisen Bank	0,390	0,194	0,323	0,199	0,628	0,278	0,078	0,984
Альфа банк	-0,370	0,044	0,001	0,336	0,422	0,002	0,390	0,814
Банк Возрождение	0,009	0,050	0,000	0,000	0,635	0,002	0,000	0,636
Ренессанс Капитал	0,703	0,016	0,001	0,117	0,285	0,003	0,262	0,551
Русский стандарт	-0,116	0,037	0,200	0,020	0,350	0,499	0,023	0,871
Сбербанк	0,067	0,517	0,004	0,031	0,990	0,002	0,007	1,000
Уралсиб	-0,279	0,014	0,083	0,044	0,161	0,255	0,062	0,478
ВСЕГО по столбцам		1,000	1,000	1,000				

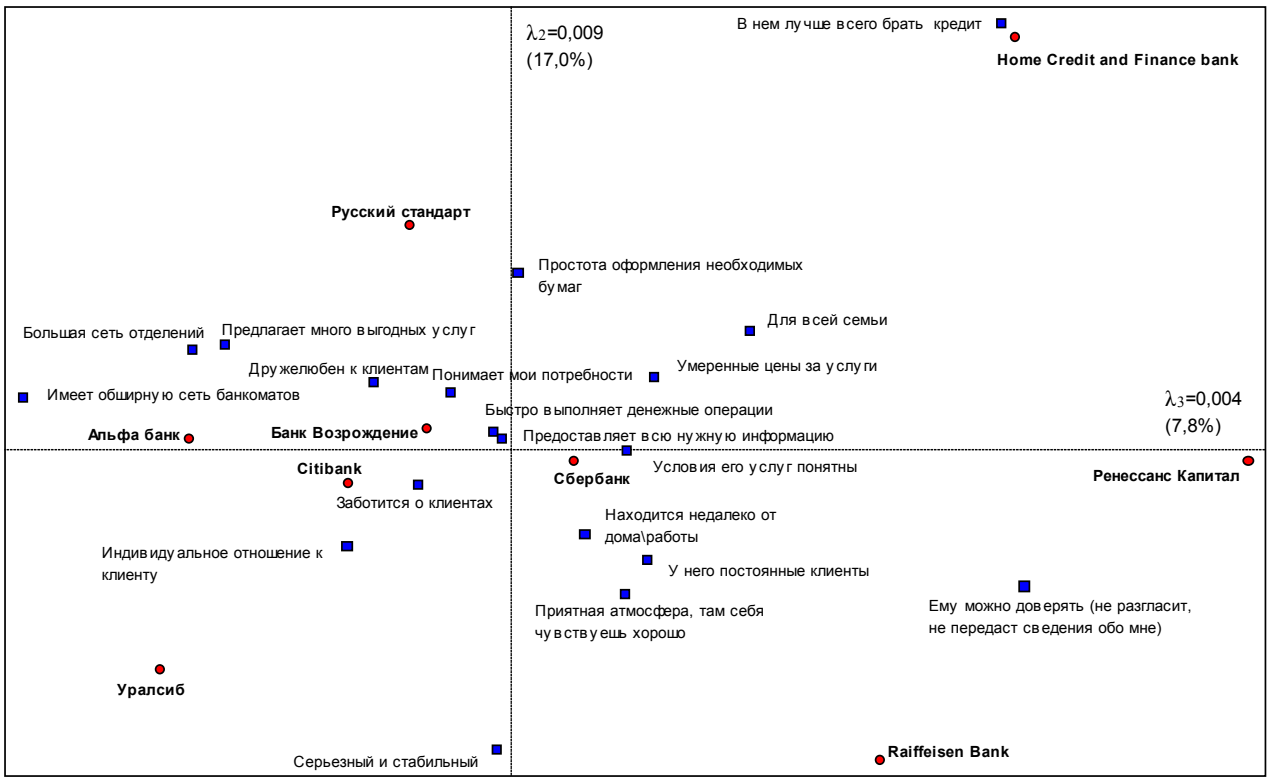


РИС. 3.4. ГРАФИЧЕСКОЕ РЕШЕНИЕ ТАБЛ. 3.1 В ПРОСТРАНСТВЕ, ОБРАЗОВАННОМ ВТОРОЙ И ТРЕТЬЕЙ ОСЯМИ (СИММЕТРИЧНАЯ КАРТА)

значительно более сильная характеристика: «ему можно доверять», которая сильнее всех остальных скоррелирована с осью (квадрат корреляции равен 0,605), и одна определяет геометрическую ориентацию оси на четверть (абсолютный вклад равен 0,230). Таким образом, в контексте третьей оси характеристика «в нем лучше всего брать кредит» должна восприниматься скорее как дополнение к характеристике «ему можно доверять», сила влияния которой намного больше. Отсюда, правый полюс третьей оси в большей степени определен вторым высказыванием, тогда как первое служит для более емкой и осмысленной интерпретации оси.

Изобразив банки в пространстве факторов, определяемых второй и третьей осями, мы получаем карту 3.5. В отличие от плоскости, образованной первыми двумя осями, на этой карте нет такого резкого противопоставления Сбербанка и всех остальных банков. Это объясняется тем, что оно осталось в первой оси, поскольку сила влияния точки «Сбербанк» ограничивается только лишь первой осью: ее абсолютные и относительные вклады по второй и третьей осям ничтожно малы и стремятся к нулю. В плоскости второй и третьей осей Сбербанк находится очень близко к центру, что свидетельствует о том, что по рассматриваемым факторам («стабильность – простота получения кредита» и «наличие большой сети – доверие, надежность») восприятие Сбербанка не отличается от восприятия гипотетического «среднего» банка. Суммарный вклад второй и третьей оси в инерцию точки «Сбербанк» составляет менее 1% (0,009), и такой крайне низкий показатель качества представленности точки на плоскости второй и третьей осей, опять же, указывает на то, что для интерпретации восприятия Сбербанка нам достаточно одной только первой оси, которая объясняет

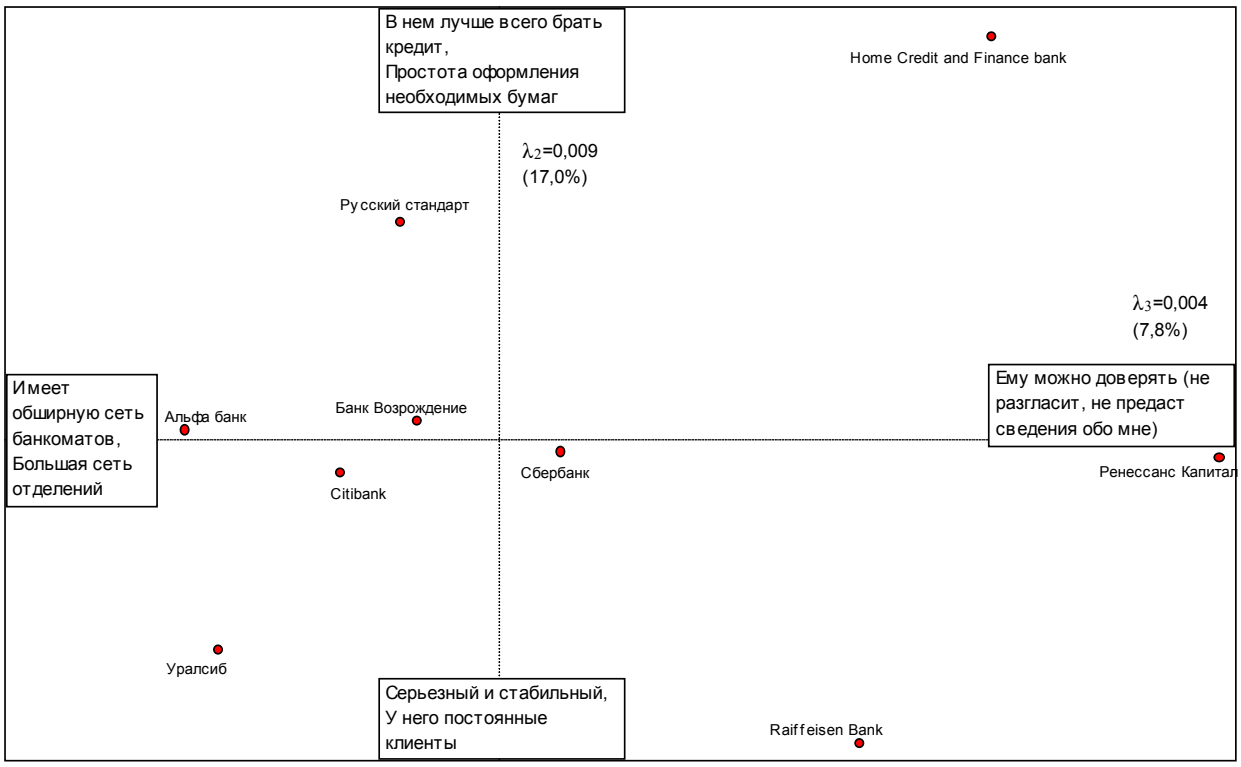


РИС. 3.5. ГРАФИЧЕСКОЕ РЕШЕНИЕ ТАБЛ. 3.1 В ПРОСТРАНСТВЕ, ОБРАЗОВАННОМ ВТОРОЙ И ТРЕТЬЕЙ ОСЯМИ: БАНКИ ПРЕДСТАВЛЕНЫ В ПРОСТРАНСТВЕ ХАРАКТЕРИСТИК

99% инерции данной точки (квадрат корреляции с первой осью равен 0,990).

Интересно положение и банка Возрождение, который мы выше определили как в некотором смысле «противоположность» Сбербанку по фактору «клиентоориентированность – территориальное удобство». Банк Возрождение точно также расположен очень близко к центру, и его качество представленности на рассматриваемой плоскости составляет 0,002. Однако это не означает, что для интерпретации имиджа банка Возрождение нам тоже достаточно только лишь первой оси, поскольку суммарное качество представленности этой точки в пространстве первых трех осей равно 63,6%. Следовательно, почти треть инерции этой точки приходится на оставшиеся оси более высокого порядка. Тем не менее, мы можем сделать вывод, что если для банка Возрождение весьма существенно противопоставление по линии «клиентоориентированность – территориальное удобство», где он соответствует левому полюсу (т.е. клиентоориентированности), то факторы «стабильность – простота получения кредита» и «наличие большой сети – доверие, надежность» совершенно не актуальны для восприятия его имиджа. По этим факторам восприятие банка не отличается от среднего. Тем не менее, очевидно, что существует еще как минимум один, а может быть, несколько факторов, которые в совокупности объясняют около трети инерции точки и сосредоточены в пространстве более высокой размерности.

Ряд точек, которые в плоскости первых двух осей располагались близко к центру, на рассматриваемой плоскости разносятся по противоположным полюсам. Речь идет, прежде всего, о банках Ренессанс Капитал, Уралсиб и Альфа-Банк. Рассмотрим, например, положение точки «Банк Ренессанс Капитал». Она имеет самую большую координату по третьей оси (0,703), вследствие чего

находится правее всех остальных точек, высокий абсолютный вклад (0,117) и неплохую корреляцию с осью (квадрат корреляции 0,262). При этом по второй оси и координата, и абсолютный, и относительной вклад этой точки близки к нулю. Таким образом, банк Ренессанс Капитал воспринимается как очень надежный, заслуживающий доверия; и вместе с тем для него не существенно противопоставление по оси «стабильность – простота получения кредита». Однако вспомним, что точка «Ренессанс Капитал» коррелирует также с первой осью (квадрат корреляции 0,285), причем даже немного сильнее, чем с третьей; хотя ее абсолютный вклад в инерцию первой оси незначителен. Отсюда следует, что на имидж банка Ренессанс Капитал существенное влияние оказывают как минимум два фактора: «клиентоориентированность – территориальное удобство» и «наличие большой сети – доверие, надежность», где банк воспринимается как клиентоориентированный (хотя и в меньшей степени, чем, например, Raiffeisen Bank и банк Возрождение – см. интерпретацию первой оси) и заслуживающий доверие, причем по последнему фактору банк имеет наивысшее значение среди всех банков. Тем не менее, суммарное качество представленности точки «Ренессанс Капитал» в трехмерном пространстве достаточно низкое: 0,551. Это означает, что почти половина инерции точки сосредоточена в пространстве более высокой размерности и объясняется какими-то еще факторами.

Качество представленности точки «Альфа-Банк», инерция которой двумя первыми осями в совокупности объяснялась на 42,4%, благодаря введению третьей оси выросло почти вдвое и составляет 0,814. Точка «Альфа-Банк» вносит наибольший вклад в инерцию третьей оси по сравнению с остальными банками (ее абсолютный вклад 0,336), располагается в направлении левого полюса и скоррелирована с ним (относительный вклад 0,390), что свидетельствует о том, что Альфа-Банк воспринимается как имеющий самую большую сеть отделений и банкоматов. По экспертной оценке автора, это вполне соответствует действительности.

Что касается банка Уралсиб, то он, по-прежнему, достаточно плохо объясняется даже трехмерным пространством: более половины инерции точки сосредоточено в следующих осях. Из рассмотренных нами осей наибольшую корреляцию Уралсиб имеет со второй осью (квадрат корреляции 0,254), причем расположен в нижней полуплоскости. Это дает нам некоторые основания считать, что в восприятии этого банка немного более выражен фактор стабильности и серьезности, чем фактор удобства получения кредита. Тем не менее, для более полного анализа имиджа банка Уралсиб нам нужно снова привлекать дополнительные оси более высокого порядка.

Подведем итоги. Анализ соответствий позволил выявить три ключевых фактора, по которым восприятие банков сильнее всего различается. Эти три фактора в совокупности объясняют почти 90% инерции исходной таблицы, что может рассматриваться как достаточно высокий показатель качества решения. Первый, наиболее сильный фактор отделяет Сбербанк, воспринимающийся как наиболее удобный в территориальном плане, от остальных банков, которые воспринимаются всей совокупностью респондентов как более клиентоориентированные, чем Сбербанк. Следующий фактор определяет дополнительные отличия между оставшимися банками: часть из них воспринимается скорее как более серьезные и стабильные, в то время как другие – более удобными для получения кредита. Наконец, третий фактор противопоставляет банки, имеющие обширную сеть отделений и банкоматов, от банков, воспринимающихся как заслуживающие доверия. При этом полученное

решение практически не отражает положения банка Уралсиб в пространстве этих признаков: его восприятие не сводится к трем выделенным факторам, его отличия более тонкие, и их выявление требует введения дополнительных осей, потому что первые три оси, полученные в результате применения анализа соответствий, объясняют меньше половины инерции точки «Уралсиб».

Немаловажным представляется тот факт, что полученные факторы являются в некотором смысле иерархическими, поскольку самые сильные различия между банками объясняются первым фактором (64,3% различий), затем – вторым (17,0% различий), менее сильные различия – третьим (7,8% различий), и еще меньшие – оставшимися факторами. Это свойство анализа соответствий будет далее более подробно рассматриваться в главе 4.

3.3. ИСПОЛЬЗОВАНИЕ ДОПОЛНИТЕЛЬНЫХ ТОЧЕК

Еще одна интересная особенность анализа соответствий – это возможность использования дополнительных точек (supplementary points), не влияющих на результат, но способных оказать существенную помощь при его интерпретации. Такие дополнительные точки могут рассматриваться как имеющие нулевую массу, и таким образом, не вносящие никакого вклада в геометрическую ориентацию осей. Тем не менее, их координаты в полученном решении могут быть вычислены с помощью формулы (2.11) (см. главу 2; шаги 18-19). Также могут быть вычислены и их относительные вклады, не зависящие от массы (см. главу 2, шаги 25 и 29). В результате, дополнительные точки могут быть помещены на полученную карту соответствий без какого бы то ни было влияния на результат.

Дополнительные точки могут использоваться как для облегчения интерпретации карт соответствий, так и в качестве неких внешних критериев проверки валидности результатов [Clausen, 1998, p.23]. Кроме того, есть и еще одна ситуация применения дополнительных точек, которая описывается ниже.

Профили, сильно отличающиеся от других, могут порождать точки, оказывающие доминирующее воздействие на геометрическую ориентацию осей. Такие точки, часто называемые «выбросами» (outliers), способны довольно существенно повлиять на результаты анализа соответствий. Как правило, это происходит тогда, когда точка вносит большой абсолютный вклад в инерцию оси и одновременно имеет высокое значение координаты по этой оси (т.е. располагается близко к полюсу) [Hoffman and Franke, 1986]. В результате, такая точка находится на большом расстоянии от других точек, которые, в свою очередь, сжимаются на более тесном участке пространства.

В нашем случае ярким примером такого выброса является Сбербанк. Масса точки «Сбербанк» равна сумме масс всех остальных точек; эта точка полностью доминирует на первой главной оси, имея квадрат корреляции с ней 0,990, и более чем на 50% определяя ее геометрическую ориентацию. Вследствие этого, остальные точки вытесняются в левую полуплоскость, где различия, которые могли бы быть между ними в терминах первого фактора, «съедаются» более сильными различиями, которые порождает первая главная ось между ними и Сбербанком. Именно из-за этого

более полный анализ восприятия целого ряда банков требует введения четвертой и выше осей.

Один из способов решения проблемы «выбросов», предлагаемый Ш.-Э. Клозеном [Clausen, 1998, p.23], состоит в том, чтобы работать с ними как с дополнительными точками. Благодаря этому «выбросы» не будут оказывать влияния на геометрическую ориентацию осей, и мы получим возможность более детально исследовать взаимосвязи между остальными точками.

Таким образом, наша задача состоит в том, чтобы поместить точку «Сбербанк» в качестве дополнительной точки на плоскость (или, в общем случае, пространство низкой размерности), образованной без учета влияния этой точки. Фактически, мы получим уже новое решение: изменится размерность таблицы (вместо 9 столбцов теперь будет 8 и один дополнительный, который не участвует в сингулярном разложении матрицы), изменится количество и значения собственных чисел, изменятся проценты объясненной дисперсии, соответствующие осям, изменятся координаты точек и вклады.

Так, новые значения сингулярных чисел и главных инерций осей приведены в табл. 3.5. Семь собственных значений в сумме дают величину общей инерции: 0,039. По сравнению с предыдущим примером, где общая инерция равнялась 0,052 (см. табл. 3.2), этот показатель снизился. Это говорит о том, что как только мы исключили из анализа (точнее, из сингулярного разложения матрицы) Сбербанк, мера разброса точек стала меньше. При этом доля объясненной инерции перераспределилась между полученными осями так, что нагрузка первого фактора снизилась, но зато второй и третий факторы объясняют теперь почти в полтора раза больший процент инерции, чем в предыдущем примере. Одновременно с этим снизился и совокупный процент объясненной инерции, приходящийся на первые две оси: теперь он равен 71,2%, тогда как в предыдущем примере первые две оси объясняли 81,3% инерции исходных данных. Аналогично, первые три оси в совокупности объясняют теперь 82,5% инерции, а в предыдущем примере три оси в совокупности объясняли 89,1% инерции. Таким образом, можно сделать вывод о том, что различия между оставшимися точками стали более яркими; и целый ряд интересных взаимосвязей, который терялся ранее за весом Сбербанка, теперь будет более очевиден.

ТАБЛИЦА 3.5.
СИНГУЛЯРНЫЕ ЧИСЛА И ГЛАВНАЯ ИНЕРЦИЯ ОСЕЙ ДЛЯ ТАБЛ. 3.1: ТОЧКА «СБЕРБАНК» ЯВЛЯЕТСЯ ДОПОЛНИТЕЛЬНОЙ

Ось	Сингуляр-ное число	Главная инерция (собственное значение)	Величина хи-квадрат[a]	Значи-мость	Объясненная инерция	
					Процент	Кумулятивный процент
1	0,129	0,017			0,430	0,430
2	0,104	0,011			0,282	0,712
3	0,066	0,004			0,113	0,825
4	0,050	0,003			0,066	0,891
5	0,048	0,002			0,060	0,951
6	0,034	0,001			0,030	0,981
7	0,027	0,001			0,019	1,000
ВСЕГО		0,039	234,623	0,000	1,000	1,000

[a] 126 степеней свободы

Симметричная карта, отражающая расположение точек в пространстве первых двух осей, изображена на рис. 3.6. При первом же взгляде на нее мы видим, что, по сравнению с рис. 3.2, расположение точек изменилось: прежде всего, банки больше не концентрируются в левой полуплоскости, противостоя Сбербанку, а равномерно распределяются по всей карте. При этом точка «Сбербанк» все равно отстоит от остальных точек, но теперь уже не так контрастно. Кроме того, можно заменить, что изменилось положение не только банков, но и высказываний. Следовательно, мы вправе ожидать, что интерпретация осей теперь будет другая.

Первые две оси в совокупности объясняют 71,2% инерции, что, в общем-то, является удовлетворительным значением, однако можно добиться значительно более высокого качества решения, если рассмотреть также третью ось; и, возможно, даже, четвертую. Для краткости, мы не

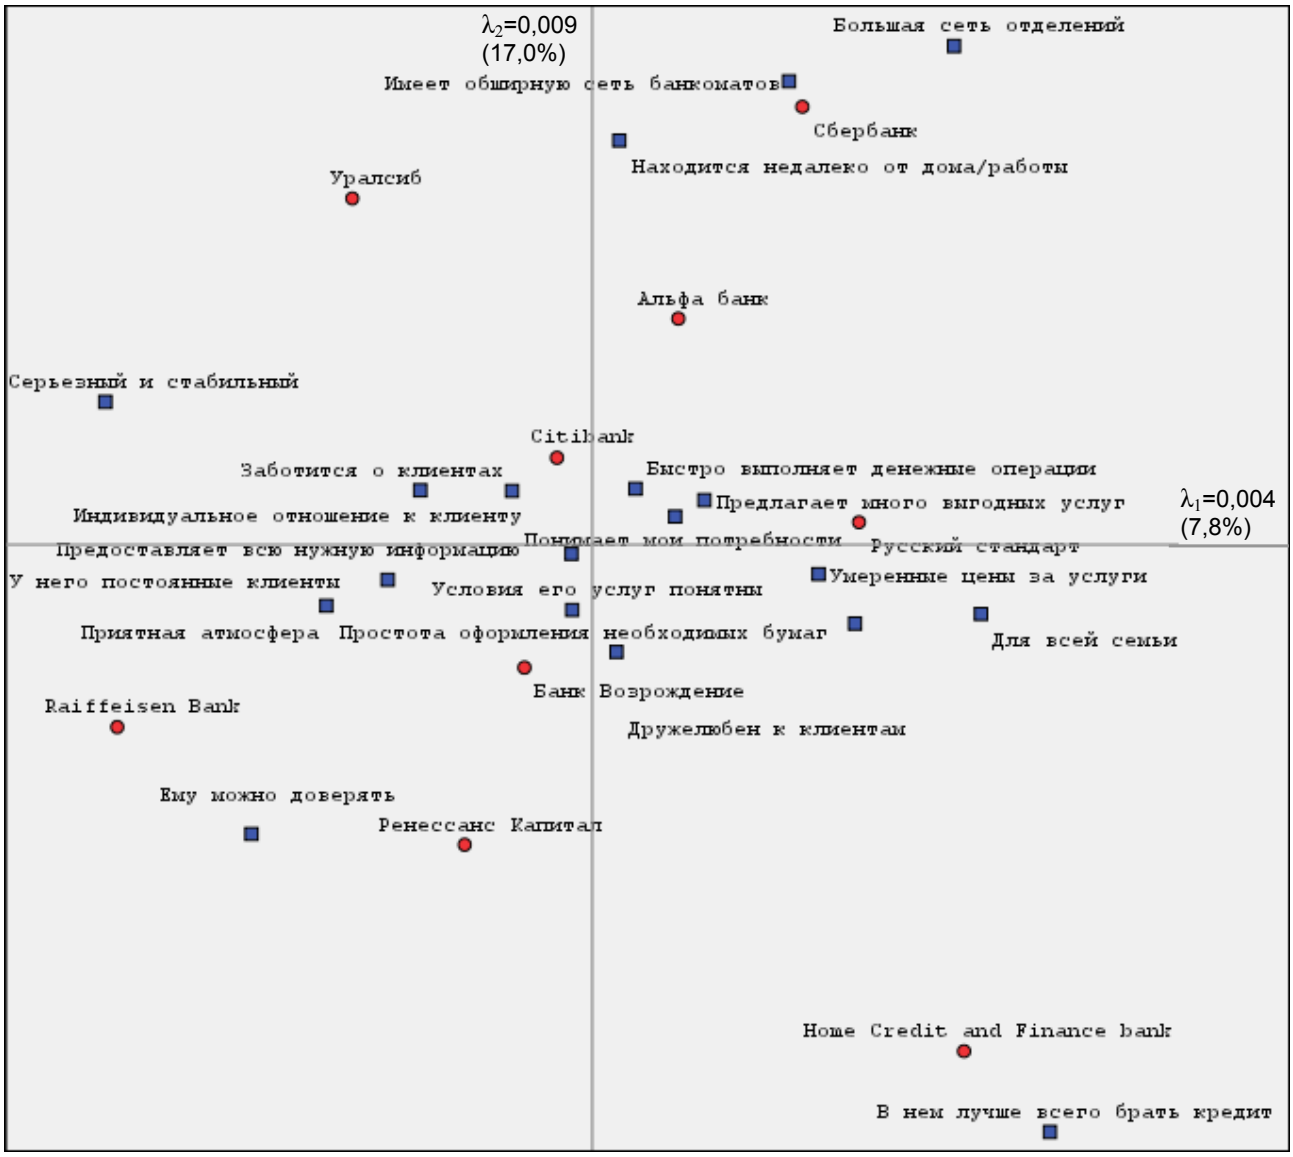


РИС. 3.6. ГРАФИЧЕСКОЕ РЕШЕНИЕ ТАБЛ. 3.1 В ПРОСТРАНСТВЕ, ОБРАЗОВАННОМ ПЕРВОЙ И ВТОРОЙ ОСЯМИ: ТОЧКА «СБЕРБАНК» ЯВЛЯЕТСЯ ДОПОЛНИТЕЛЬНОЙ

будем здесь подробно останавливаться на интерпретации новых осей и расположения точек, предоставив сделать это читателю, который может найти все необходимые для этого статистики в Приложении А.

Отметим только, что точка «Сбербанк», являющаяся дополнительной, теперь далеко не так хорошо представлена в двумерном решении, как это было в предыдущем примере. Суммарный квадрат корреляции точки с плоскостью, образованной первыми двумя осями, равен всего 0,319 (см. Приложение А), в то время как в предыдущем примере аналогичный показатель составлял 0,992. Такое снижение качества представленности точки «Сбербанк», в принципе, не удивительно, если учесть, что мы проектируем ее на плоскость, полученную без ее участия. Из предыдущего примера мы знаем, какие характеристики сильнее всего ассоциировались со Сбербанком, – это, прежде всего, те характеристики, которые имели высокую корреляцию с первой осью в том решении, и располагались в направлении положительного полюса, – т.е. «находится недалеко от дома, работы», «большая сеть отделений», «для всей семьи». В новом же решении расположение точек, соответствующих этим характеристикам, перераспределилось между осями, причем так, что первые две из них теперь коррелируют с вертикальной осью, а третья – с горизонтальной. Таким образом, смысловая нагрузка осей меняется, что, в свою очередь, ведет к изменению вкладов точек.

3.4. АНАЛИЗ «СОСТАВЛЕННЫХ» ТАБЛИЦ

Важнейшей особенностью анализа соответствий является его возможность работать с многомерными таблицами.

Пусть у нас есть три переменные, I, J, и K, категории которых обозначим I = 1…I, j = 1..J, k = 1…K. Если мы захотим построить таблицу сопряженности этих переменных, то получим трехмерную (кубическую) таблицу, содержащую IJK, ячеек (см. рис. 3.7 (a)). Мы можем проанализировать отдельные «слои» этой таблицы, - например, для каждой из категорий переменной K рассмотреть пересечения вида $I \times J$ (см. рис. 3.7 (b)), и, таким образом, отразить все возможные трехмерные взаимодействия. С другой стороны, мы можем рассмотреть грани кубической таблицы, в которых будут представлены попарные взаимодействия $I \times$, $J \times K$, $I \times K$ (см. рис. 3.7 (c)).

В том случае, если у нас количество переменных увеличится, например, до четырех, то четырехмерная таблица будет иметь уже намного более сложную гиперкубическую структуру, содержащую $IJKL$ ячеек. Так, с возрастанием числа переменных, число ячеек в гиперкубах будет увеличиваться, а значения частот будут становиться все меньше и меньше. Такие гиперкубические таблицы чрезвычайно сложны для анализа, а, между тем, исследователю часто необходимо рассматривать подобные многомерные взаимодействия.

Мы ниже рассмотрим два способа решения этой проблемы. Первый из них предполагает использование простого анализа соответствий для «составленной» таблицы, а второй – множественного анализа соответствий, который мы разберем в следующем разделе.

Если одну из переменных можно представить как описываемую, а остальные – в качестве описывающих, то мы получаем возможность построить так называемую «составленную»

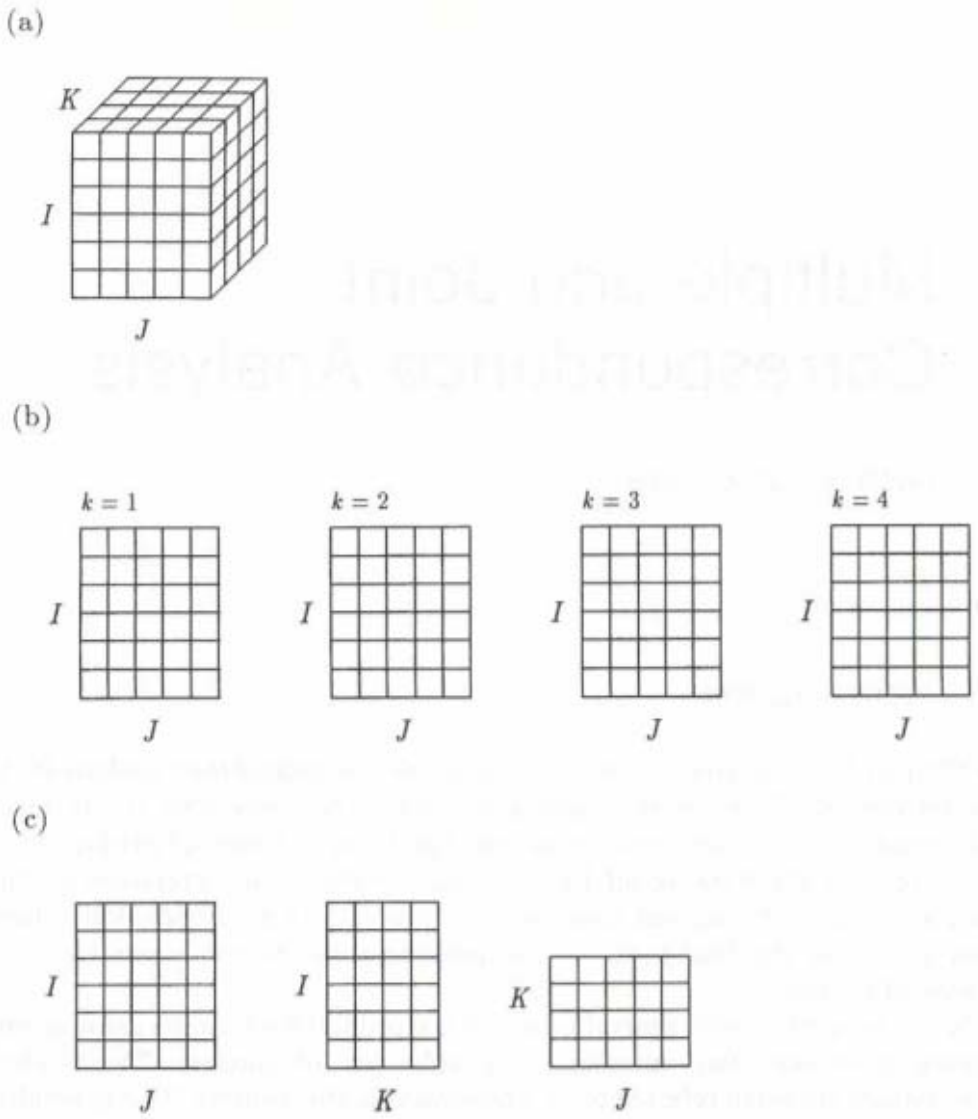


РИС. 3.7. (A) ТРЕХМЕРНАЯ ТАБЛИЦА СОПРЯЖЕННОСТИ ПЕРЕМЕННЫХ I (6 КАТЕГОРИЙ), J (5 КАТЕГОРИЙ) И K (4 КАТЕГОРИИ);
(B) ЧЕТЫРЕ «СЛОЯ» ТРЕХМЕРНОЙ ТАБЛИЦЫ, ДЛЯ КАЖДОЙ ИЗ КАТЕГОРИЙ ПЕРЕМЕННОЙ K
(C) ДВУМЕРНЫЕ ГРАНИ ТРЕХМЕРНОЙ ТАБЛИЦЫ

(concatenated) таблицу, где описывающая переменная будет пересекаться с каждой из описываемых [Greenacre, 1998, p.134]. Так, если у нас есть, например, четыре переменных: образование респондента, его должность, принадлежность к категории неработающих (для тех, кто не работает) и принадлежность к психографическому типу, то, вероятно, имеет смысл представить переменную «психографический тип» в качестве описываемой, а остальные три – в качестве описывающих. Пересекая первую со вторыми, мы получаем табл. 3.6, которая, фактически, состоит из трех таблиц, составленных друг под другом. Описание и методику построения психографических типов можно найти в приложении C.

ТАБЛИЦА 3.6.
ПСИХОГРАФИЧЕСКИЙ ТИП РЕСПОНДЕНТА[9], ОБРАЗОВАНИЕ, ДОЛЖНОСТЬ ИЛИ ПРИНАДЛЕЖНОСТЬ К КАТЕГОРИИ НЕРАБОТАЮЩИХ

	Выживающие	**Традиционалисты**	**Стремящиеся**	**Обыватели**	**Беззаботные**	**Новаторы**	**Благополучные**	**Достигшие успеха**
Неполное среднее	197	102	146	155	73	202	91	106
Среднее,среднее специальное	894	527	611	599	250	648	506	481
Высшее	478	295	370	527	190	559	468	472
Ученая степень кандидата или доктора наук	4	5	5	12	5	11	17	10
Руководитель (директор, президент)	5	5	12	20	8	33	26	38
Зам.руководителя, главный специалист	17	15	23	41	13	38	37	36
Руководитель подразделения	50	18	36	54	29	63	63	84
Квалифицированный специалист с высшим образованием	174	103	132	213	68	212	182	169
Служащий без высшего образования	153	95	114	124	40	134	99	93
Технический и обслуживающий персонал	148	72	99	95	35	110	81	91
Квалифицированный рабочий, мастер	148	109	121	140	58	123	121	109
Подсобный рабочий	43	25	34	38	18	38	20	16
Должность - другое	176	119	155	143	58	170	144	111
Пенсионер по инвалидности	64	30	23	17	8	19	17	21
Домохозяйка/временно неработающий	106	73	77	75	40	72	72	63
Пенсионер по возрасту или по выслуге лет	311	159	104	89	32	76	66	42
Зарегистрированный безработный	16	6	8	3	2	8	3	1
Учащийся школы/ПТУ,техникума	128	47	137	188	102	268	89	128
Студент ВУЗа	33	17	51	73	23	87	37	61
Неработающие - другое	41	38	38	28	15	44	27	36

Источник: COMCON, TGI-Россия, 1 квартал 2006 г., города с населением 100 тыс. чел. и более

Если применить анализ соответствий к каждой из этих трех подтаблиц, то мы получим три карты соответствий, показывающих взаимосвязь между психографическим типом и образованием

[9] Описание и методику построения психографических типов см. в Приложении С.

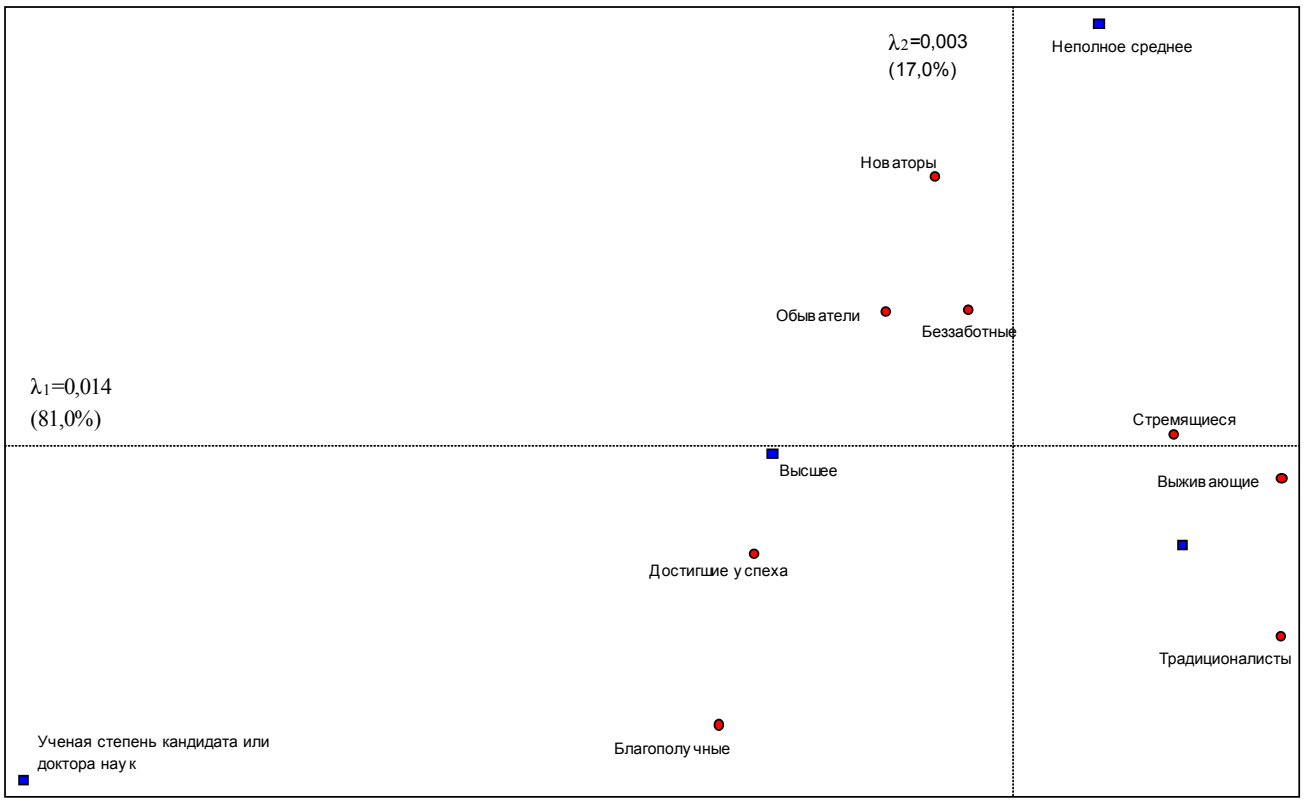


РИС. 3.8. ДВУМЕРНОЕ ГРАФИЧЕСКОЕ РЕШЕНИЕ ВЕРХНЕЙ ПОДТАБЛИЦЫ ТАБЛ. 3.6: ПСИХОГРАФИЧЕСКИЙ ТИП И ОБРАЗОВАНИЕ РЕСПОНДЕНТА (СИММЕТРИЧНАЯ КАРТА)

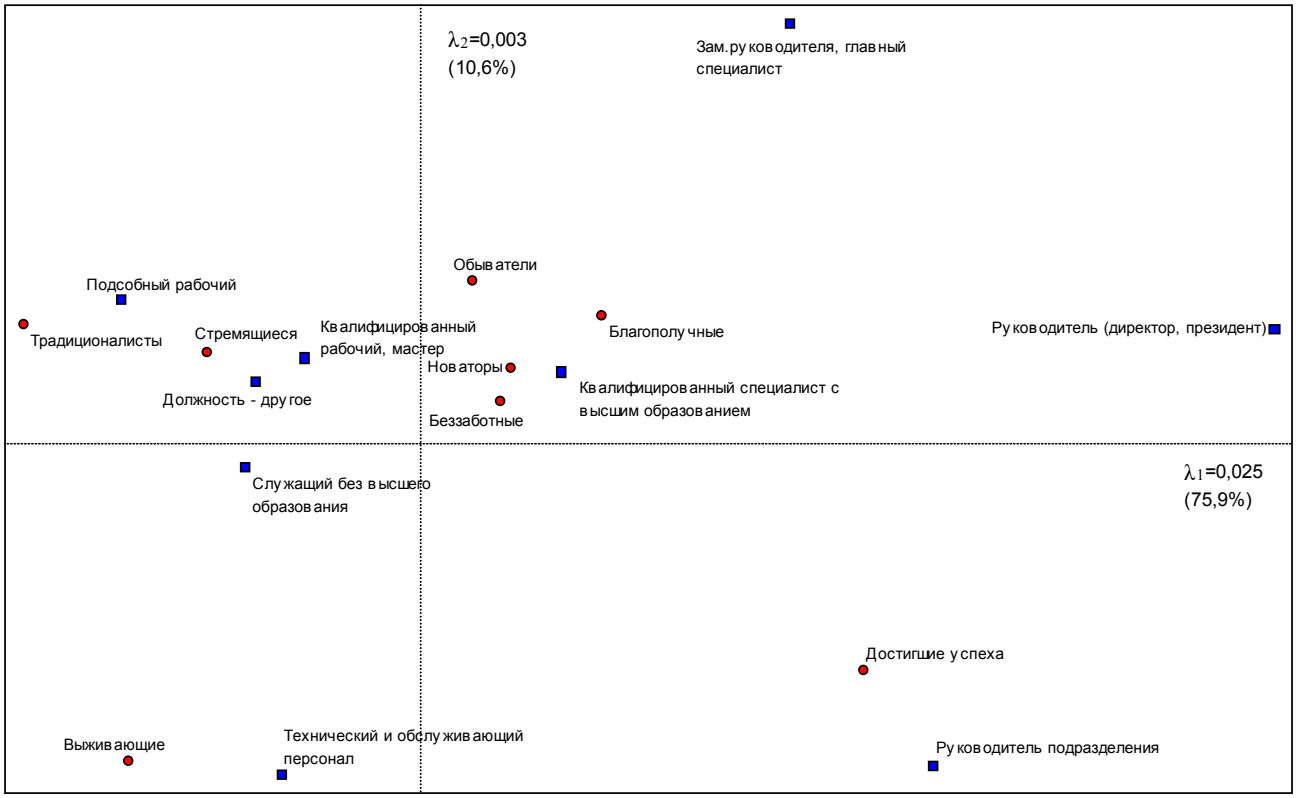


РИС. 3.9. ДВУМЕРНОЕ ГРАФИЧЕСКОЕ РЕШЕНИЕ СРЕДНЕЙ ПОДТАБЛИЦЫ ТАБЛ. 3.6: ПСИХОГРАФИЧЕСКИЙ ТИП И ДОЛЖНОСТЬ РЕСПОНДЕНТА (СИММЕТРИЧНАЯ КАРТА)

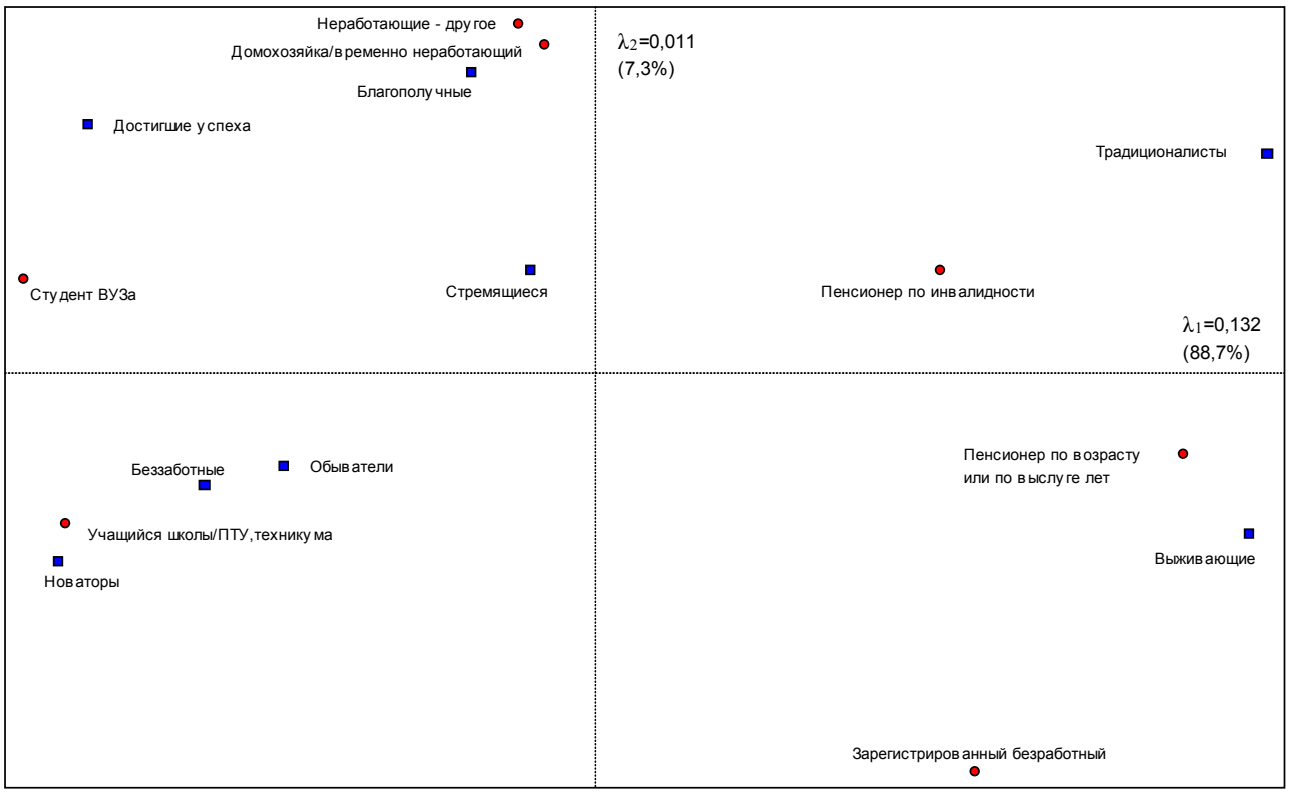


РИС. 3.10. ДВУМЕРНОЕ ГРАФИЧЕСКОЕ РЕШЕНИЕ НИЖНЕЙ ПОДТАБЛИЦЫ ТАБЛ. 3.6: ПСИХОГРАФИЧЕСКИЙ ТИП И КАТЕГОРИЯ НЕРАБОТАЮЩИХ (СИММЕТРИЧНАЯ КАРТА)

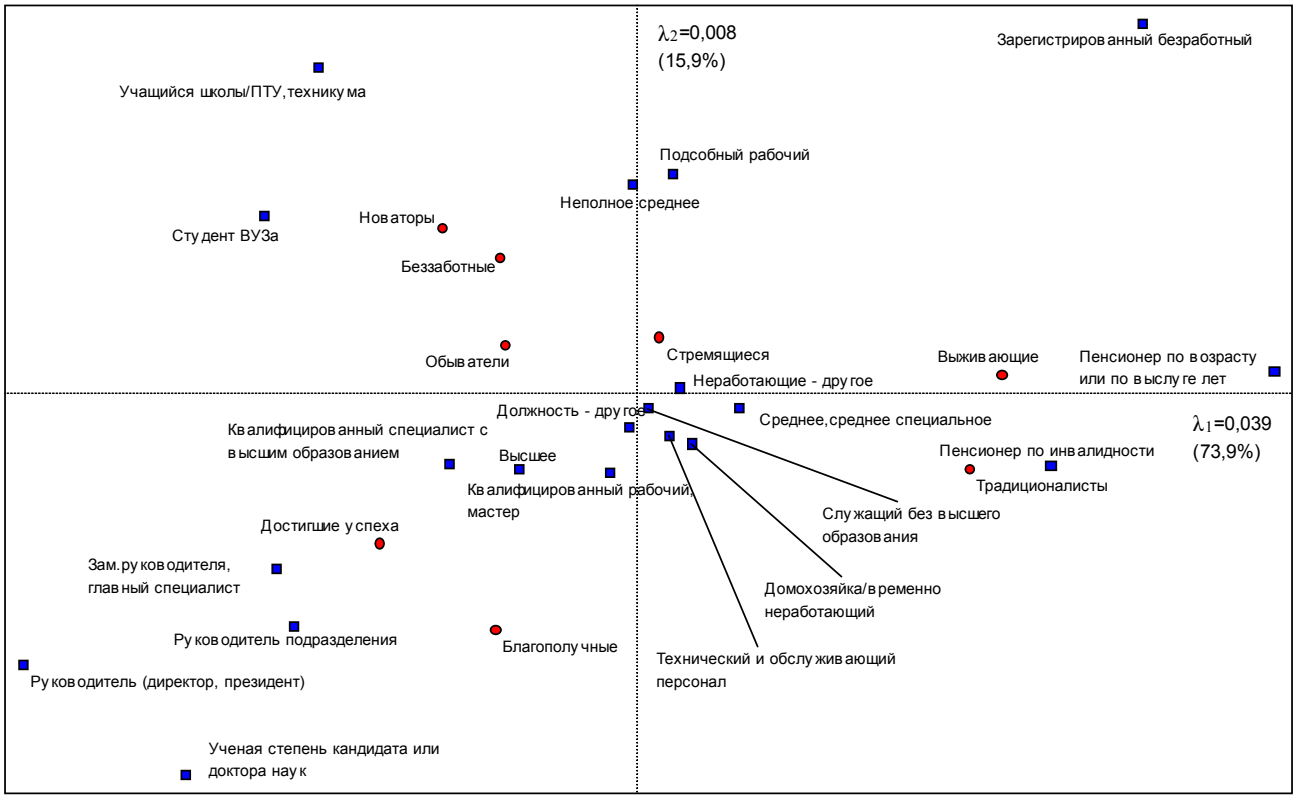


РИС. 3.11. ДВУМЕРНОЕ ГРАФИЧЕСКОЕ РЕШЕНИЕ ПОЛНОЙ ТАБЛ. 3.6: ПСИХОГРАФИЧЕСКИЙ ТИП И ОБРАЗОВАНИЕ, ДОЛЖНОСТЬ И КАТЕГОРИЯ НЕРАБОТАЮЩИХ (СИММЕТРИЧНАЯ КАРТА)

респондента (см. рис. 3.8), психографическим типом и должностью респондента (см. рис. 3.9), а также между психографическим типом и категорией неработающих (см. рис. 3.10). Подробные числовые статистики для каждого из анализов приведены в приложении А.

Каждая из трех карт, изображенных на рис. 3.8, 3.9 и 3.10 представляет максимальный возможный в первых двух осях процент объясненной дисперсии для каждого случая. Анализируя эти карты, мы можем прийти к следующим выводам. Во-первых, по уровню образования психографические типы делятся на две большие группы, отделяемые первой главной осью: для таких типов, как Беззаботные, Новаторы, Обыватели, Достигшие успеха, Благополучные более характерно иметь высшее образование; причем для двух последних – также и ученую степень. В то же время, для Выживающих, Традиционалистов и Стремящихся более характерно иметь среднее и неполное среднее образование.

Более сильные различия между психографическими типами наблюдаются по категории переменной «должность». О более сильной степени взаимосвязи говорит и большое значение инерции, равное 0,033; в то время как в ситуации психографического типа и образования инерция составляла только 0,017 (см. Приложение А). При этом следует заметить, что для более корректного сравнения значений инерции для таблиц разного размера лучше использовать некий нормирующий коэффициент, например, V Крамера, представленный в разделе 2.7 (см. шаг 16).

Для Выживающих наиболее типичным должностным является технический и обслуживающий персонал; в то время как Традиционалисты и Стремящиеся ассоциируются с подсобными и квалифицированными рабочими. Напротив, руководящие должности сосредоточены на правом полюсе горизонтальной оси рис. 3.9., и в высшей степени характерны для психографического типа Достигшие успеха. Ближе к центру карты находятся остальные точки, что говорит о том, что различия между ними более тонкие; и контраст между Традиционалистами и Выживающими на левом полюсе и Достигшими Успеха на правом намного сильнее. Тем не менее, можно сказать, что точки «Обыватели», «Новаторы» и «Беззаботные» сдвинуты все-таки в сторону высших должностей, чем низших; и, кроме того, по горизонтальной оси они имеют координаты, попадающие в отрезок между координатами точек «квалифицированный рабочий, мастер» и «квалифицированный специалист с высшим образованием». Следовательно, наиболее характерными для этих психографических типов должностями будут являться должности, попадающие в этот интервал. При этом, для Благополучных более характерно работать квалифицированным специалистом с высшим, чем для Обывателей, Новаторов или Беззаботных, поскольку соответствующая точка ближе к правому полюсу.

Наконец, по категории неработающих, наблюдаются наиболее сильные различия между психографическими типами (инерция равна 0,149). Таким образом, можно сказать, что переменная «категория неработающих» значительно сильнее дискриминирует категории переменной «психографический тип». Представители различных психографических типов не работают по разным причинам. Если Традиционалисты и Выживающие чаще являются пенсионерами, то Новаторы и Беззаботные – учащимися и студентами (различия по горизонтальной оси). Что касается Благополучных и Достигших успеха, то для этих психографических типов более характерны категории «домохозяйка/временно неработающий» и «другое» (различия по вертикальной оси). Для Стремящихся наиболее типичную категорию неработающих определить сложно, поскольку точка

находится вблизи центра координат и довольно плохо объясняется в двумерном решении. Наконец, отметим, что точка «зарегистрированный безработный» в данном случае является типичным «выбросом». Ее профиль очень сильно отличается от остальных, поскольку это пока еще крайне нетипичная для российского рынка труда категория. Данная точка имеет очень высокие модули координат по обеим осям, чем сильно влияет на геометрическую ориентацию осей. Кроме того, в отношении нее нельзя сказать, какой психографический тип с ней связан. Фактически, в данном случае можно было бы поместить ее на карту в качестве дополнительной точки.

На каждой их рассмотренных карт положение точек, соответствующих психографическим типам, различное. Возникает вопрос: можно ли как-то совместить эти карты для того, чтобы взаимосвязи между всеми точками одновременно? Для того, чтобы получить такую совмещенную карту, мы должны выполнить анализ соответствий на всем наборе таблиц, так, как он представлен в табл. 3.6, где подтаблицы составлены одна под другой в соответствии с порядком категорий переменной «психографический тип». Другими словами, полная матрица размера 20 × 8 анализируется так, как если бы она представляла собой единую таблицу сопряженности,

$$N = \begin{pmatrix} N_1 \\ N_2 \\ \vdots \\ N_Q \end{pmatrix}$$

где Q=3, поскольку из четырех переменных одна находится в столбцах матрицы.

Предполагая отсутствие пропущенных данных, М. Гринакр [Greenacre, 1998, p.145] показывает, что инерция такой составленной таблицы равняется среднему значению инерций каждой из входящих в нее подтаблиц:

$$\varphi^2(N) = \frac{1}{Q}\sum_{q=1}^{Q}\varphi^2(N_q)$$

В случае же наличия пропущенных данных этот результат выполняется только приблизительно.

На рис. 3.10 представлено графическое решение «одновременного» анализа трех подтаблиц. Среднее значение инерции составляет 0,053; 89% которой представлено на плоскости, образованной первыми двумя осями. Фактически, эта карта «резюмирует» результаты трех предыдущих карт. Так, Выживающие и Традиционалисты ассоциируются с пенсионерами и со средним/средним специальным образованием; Благополучные и Достигшие успеха – напротив, с руководящими должностями, высшим образованием, ученой степенью. Новаторы и Беззаботные в большей степени ассоциируются со студентами, учащимися, неполным средним образованием, и даже подсобными рабочими (видимо, подрабатывают после учебы). Точки «обыватели» и «Стремящиеся» достаточно плохо представлены в двумерном решении, и о них ничего определенного сказать нельзя.

3.5. МНОЖЕСТВЕННЫЙ АНАЛИЗ СООТВЕТСТВИЙ

Вместо того, чтобы анализировать таблицу, где категории одной переменной пересекаются с категориями других переменных, мы можем провести совместный анализ всех возможны пар пересечений. Для этого нам необходимо создать матрицу попарных сочетаний всех категорий. Эта матрица называется *матрицей Бёрта* (Burt matrix); и она приведена в табл. 3.7 для нашего примера. Фактически, матрица Бёрта содержит все возможные кросс-таблицы для имеющихся переменных, т.е. 16 таблиц нашем случае. Из них, четыре квадратных таблицы, лежащие на главной диагонали матрицы, представляют собой пересечения переменной самой с собой.

Матрица Бёрта и индикаторная матрица

В верхнем и нижнем треугольнике матрицы Бёрта находятся симметричные, но транспонированные друг относительно друга, пары сочетаний. Так, например, подтаблицу, находящуюся в последнем столбце табл. 3.7 выше главной диагонали, в которой психографические типы пересекаются с остальными переменными, мы уже рассматривали в предыдущем разделе.

Анализируя матицу Бёрта, мы попадаем в ситуацию *множественного анализа соответствий*.

Вообще, классическое определение множественного анализа соответствий, представленное М. Гринакром [см. напр. Greenacre, 1998, p.151], подразумевает применение алгоритма простого анализа соответствий не к матрице Бёрта, а к так называемой *индикаторной матрице* (indicator matrix), обозначаемой $\mathbf{Z}$. Последняя имеет столько строк, сколько имеется респондентов, и столько столбцов, сколько имеется категорий у всех переменных, вместе взятых. Так, например, в массиве данных, использовавшемся для построения табл. 3.6 и 3.7, 9276 респондентов и 28 возможных категорий ответа; таким образом, $\mathbf{Z}$ представляет собой матрицу 9276 × 28. Каждая строка матрицы $\mathbf{Z}$ состоит в основном из нулей, однако в столбце, соответствующем определенному варианту ответа, стоит единица. Например, респондент, имеющий высшее образование, являющийся заместителем руководителя (наличие определенной должности автоматически предполагает, что человек не относится к категории неработающих) и принадлежащий к психографическому типу Новаторов, может быть описан набором ответов (3, 2, 0, 6). В индикаторной матрице эта запись будет выглядеть следующим образом:

0010 010000000 0000000 00000100

На самом деле, в матрице $\mathbf{Z}$ строка представляет собой сплошной набор 28 символов, не разделенных пробелами, которые мы включили для удобства визуального восприятия данных. Первые четыре столбца относятся к категориям переменной «образование», и, поскольку наш респондент имеет высшее образование, что соответствует третьей по счету категории, это

ТАБЛИЦА 3.7.
МАТРИЦА БЁРТА

	Неполное среднее	Среднее,среднее специальное	Высшее	Ученая степень	Руководитель	Зам.руководителя, гл. Спец.	Руководитель подразделения	Квалифиц. Спец.с в/о	Служащий без в/о	Технический и обсл.персонал	Квалифицир.рабочий, мастер	Подсобный рабочий	Должность - другое	Пенсионер по инвалидности	Домохозяйка/врем.нераб.	Пенсионер по возрасту	Зарегистр. безработный	Учащийся	Студент ВУЗа	Неработающие - другое	Выживающие	Традиционалисты	Стремящиеся	Обыватели	Беззаботные	Новаторы	Благополучные	Достигшие успеха
Неполное среднее	1072	0	0	0	1	2	4	3	37	36	56	45	64	32	41	157	4	550	6	34	197	102	146	155	73	202	91	106
Среднее,среднее специальное	0	4516	0	0	29	48	131	34	686	560	739	164	652	119	342	493	31	199	138	151	894	527	611	599	250	648	506	481
Высшее	0	0	3359	69	117	170	262	1216	129	135	134	23	360	48	195	229	12	9	238	82	478	295	370	527	190	559	468	472
Ученая степень кандидата или доктора наук	0	0	69	69	1	7	5	38	0	0	0	0	7	0	2	3	0	0	0	6	4	5	5	12	5	11	17	10
Руководитель (директор, президент)	1	29	117	1	147	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	5	5	12	20	8	33	26	38
Зам.руководителя, главный специалист	2	48	170	7	0	220	0	0	0	0	0	0	0	0	0	0	0	0	0	0	17	15	23	41	13	38	37	36
Руководитель подразделения	4	131	262	5	0	0	397	0	0	0	0	0	0	0	0	0	0	0	0	0	50	18	36	54	29	63	63	84
Квалифицированный специалист с высшим образованием	3	34	1216	38	0	0	0	1253	0	0	0	0	0	0	0	0	0	0	0	0	174	103	132	213	68	212	182	169
Служащий без высшего образования	37	686	129	0	0	0	0	0	852	0	0	0	0	0	0	0	0	0	0	0	153	95	114	124	40	134	99	93
Технический и обслуживающий персонал	36	560	135	0	0	0	0	0	0	731	0	0	0	0	0	0	0	0	0	0	148	72	99	95	35	110	81	91
Квалифицированный рабочий, мастер	56	739	134	0	0	0	0	0	0	0	929	0	0	0	0	0	0	0	0	0	148	109	121	140	58	123	121	109
Подсобный рабочий	45	164	23	0	0	0	0	0	0	0	0	232	0	0	0	0	0	0	0	0	43	25	34	38	18	38	20	16
Должность - другое	64	652	360	7	0	0	0	0	0	0	0	0	1076	0	0	0	0	0	0	0	176	119	155	143	58	170	144	111

	Неполное среднее	Среднее,среднее специальное	Высшее	Ученая степень	Руководитель	Зам.руководителя, гл. Спец.	Руководитель подразделения	Квалифиц. Спец.с в/о	Служащий без в/о	Технический и обсл.персонал	Квалифицир.рабочий, мастер	Подсобный рабочий	Должность - другое	Пенсионер по инвалидности	Домохозяйка/врем.нераб.	Пенсионер по возрасту	Зарегистр. безработный	Учащийся	Студент ВУЗа	Неработающие - другое	Выживающие	Традиционалисты	Стремящиеся	Обыватели	Беззаботные	Новаторы	Благополучные	Достигшие успеха
Пенсионер по инвалидности	32	119	48	0	0	0	0	0	0	0	0	0	0	199	0	0	0	0	0	0	64	30	23	17	8	19	17	21
Домохозяйка/временно неработающий	41	342	195	2	0	0	0	0	0	0	0	0	0	0	578	0	0	0	0	0	106	73	77	75	40	72	72	63
Пенсионер по возрасту или по выслуге лет	157	493	229	3	0	0	0	0	0	0	0	0	0	0	0	879	0	0	0	0	311	159	104	89	32	76	66	42
Зарегистрированный безработный	4	31	12	0	0	0	0	0	0	0	0	0	0	0	0	0	47	0	0	0	16	6	8	3	2	8	3	1
Учащийся школы/ПТУ,техникума	550	199	9	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1087	0	0	128	47	137	188	102	268	89	128
Студент ВУЗа	6	138	238	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	382	0	33	17	51	73	23	87	37	61
Неработающие - другое	34	151	82	6	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	267	41	38	38	28	15	44	27	36
Выживающие	197	894	478	4	5	17	50	174	153	148	148	43	176	64	106	311	16	128	33	41	1613	0	0	0	0	0	0	0
Традиционалисты	102	527	295	5	5	15	18	103	95	72	109	25	119	30	73	159	6	47	17	38	0	931	0	0	0	0	0	0
Стремящиеся	146	611	370	5	12	23	36	132	114	99	121	34	155	23	77	104	8	137	51	38	0	0	1164	0	0	0	0	0
Обыватели	155	599	527	12	20	41	54	213	124	95	140	38	143	17	75	89	3	188	73	28	0	0	0	1341	0	0	0	0
Беззаботные	73	250	190	5	8	13	29	68	40	35	58	18	58	8	40	32	2	102	23	15	0	0	0	0	549	0	0	0
Новаторы	202	648	559	11	33	38	63	212	134	110	123	38	170	19	72	76	8	268	87	44	0	0	0	0	0	1495	0	0
Благополучные	91	506	468	17	26	37	63	182	99	81	121	20	144	17	72	66	3	89	37	27	0	0	0	0	0	0	1084	0
Достигшие успеха	106	481	472	10	38	36	84	169	93	91	109	16	111	21	63	42	1	128	61	36	0	0	0	0	0	0	0	1099

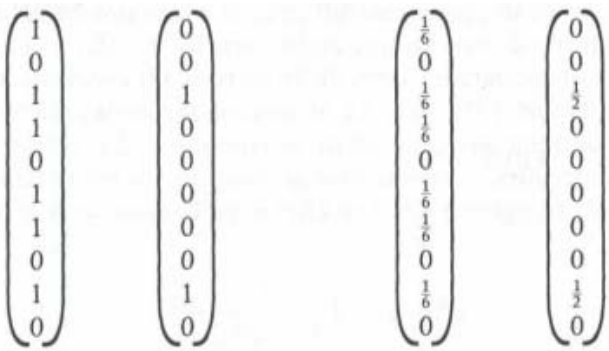
кодируется как «0010». Схожим образом, принадлежность ко второй по счету категории переменной «должность» выражается в записи «010000000» и, поскольку наш респондент работает, и, следовательно, не принадлежит к категории неработающих, третий набор символов кодируется сплошными нулями: «0000000». Наконец, психографический тип «Новаторы» является шестым по счету, что в индикаторной матрице соответствует записи «00000100».

Поскольку мы отделяли наборы столбцов, соответствующие переменным, друг от друга, мы можем представить матрицу $\mathbf{Z}$ в общем виде как совокупность Q матриц, где Q равно числу переменных:

$$\mathbf{Z} = [\mathbf{Z}_1 \quad \mathbf{Z}_2 \quad \ldots \quad \mathbf{Z}_Q]$$

Фактически, множественный анализ соответствий есть не что иное как применение алгоритма простого анализа соответствий, который был детально разобран нами в главе 2, к матрице такого вида. Поскольку маргинальные суммы по всем строкам одинаковы, массы всех строк будут равняться 1/n, где n – общее количество наблюдений, т.е. размер выборки. Маргинальные суммы по всем столбцам также равны; таким образом, массы столбцов пропорциональны этим маргинальным суммам, как в простом анализе соответствий. Хи-квадрат расстояние между респондентами будет являться аналогом некого «коэффициента несовпадений», который тем выше, чем большее число категорий у респондентов различается. И поскольку в каждом столбце может стоять только 0 или 1, этот «коэффициент несовпадений» будет представлять собой сумму квадратов несовпадений между двумя строками. Причем каждый квадрат разности делится на соответствующую массу, вследствие чего более редкие ответы входят в формулу с большим весом, и, наоборот – точно также, как и в простом анализе соответствий (см. раздел 2.3).

Применительно к столбцам матрицы $\mathbf{Z}$ базовые геометрические понятия анализа соответствий уже становятся сложнее. Так, например, пусть у нас есть два столбца $\mathbf{Z}$, описывающие две категории разных переменных, - они показаны слева. Справа же показаны соответствующие профили столбцов:



Геометрическое понимание профилей такого вида уже значительно сложнее.

Тем не менее, суть анализа матрицы $\mathbf{Z}$ становится яснее, если осознать, что $\mathbf{Z}$ теснейшим образом связана с матрицей всех возможных сочетаний переменных, которую мы выше определили как матрицу Бёрта. Если мы умножим слева матрицу $\mathbf{Z}$ на ее транспозицию, то получим как раз матрицу Бёрта $\mathbf{B}$, имеющую размер $J \times J$:

$$\mathbf{B} = \mathbf{Z}^{\mathrm{T}}\mathbf{Z} = \begin{pmatrix} \mathbf{D}_1 & \mathbf{N}_{12} & \cdots & \mathbf{N}_{1Q} \\ \mathbf{N}_{21} & \mathbf{D}_2 & \cdots & \mathbf{N}_{2Q} \\ \vdots & \vdots & \ddots & \vdots \\ \mathbf{N}_{Q1} & \mathbf{N}_{Q2} & \cdots & \mathbf{D}_Q \end{pmatrix}$$

где $\mathbf{N_qs}=\mathbf{Z}^{\mathrm{T}}_{\mathbf{q}}\mathbf{Z_s}$. Таким образом, множественный анализ соответствий может быть определен и как простой анализ соответствий матрицы Бёрта **B**, поскольку он аналогичен анализу матрицы **Z** благодаря связи сингулярных чисел и сингулярных векторов обеих матриц (см. раздел 2.7). В результате сингулярного разложения обеих матриц получаются одни и те же правые сингулярные векторы, и сингулярные числа матрицы **B** являются квадратами сингулярных чисел матрицы **Z** [Greenacre, 1998, p.153].

Геометрическая взаимосвязь между анализами матриц **B** и **Z** следующая. Во-первых, стандартные координаты категорий (т.е. столбцов матрицы **Z**, и, аналогично, либо столбцов, либо строк матрицы **B**) одинаковы. И, во-вторых, значения главных инерций матрицы **B** являются квадратными корнями главных инерций **Z**.

Интерпретация результатов множественного анализа соответствий

Рис. 3.12 показывает графическое решение табл. 3.7., полученное в результате применения множественного анализа соответствий. Подробные числовые статистики приводятся в приложении А.

При первом взгляде на карту множественного анализа соответствий бросается в глаза практически крестообразное расположение точек. Так, если повернуть оси примерно на 45 градусов, то они лягут как раз вдоль направлений, образованных точками. Тогда на правом вернем полюсе будут располагаться учащиеся школ и гимназий, имеющие неполное среднее образование; на правом нижнем – пенсионеры и рабочие; на правом нижнем – пенсионеры, рабочие, учащиеся ПТУ, люди со средним и средним специальным образованием; на левом нижнем – служащие, технический и обслуживающий персонал, домохозяйки, зарегистрированные безработные; на правом верхнем – руководящие должности, высшее образование, ученая степень, студенты, психографические типы Благополучные и Достигшие успеха[10].

Интерпретировать полученные оси в терминах социального положения будет не совсем корректно. Так, у нас в левом верхнем квадранте сосредотачиваются представители как высшего класса, так и среднего; тогда как низший класс занимает всю нижнюю полуплоскость. При этом учащиеся и люди с неполным средним образованием вообще выносятся в отдельный квадрант.

Гораздо более плодотворным нам представляется определить оси, используя понятия различных форм капитала, использованные П. Бурдье [Burdieu, 1984]. Используя абсолютные и относительные вклады, приведенные в Приложении А, мы видим, что горизонтальная ось в наибольшей степени характеризуется образованием: точка «ученая степень» - на левом полюсе против точек «неполное среднее» и «учащийся» на правом. Кроме того, большие вклады и

[10] На карте соответствий они обозначены как «Преуспевающие»

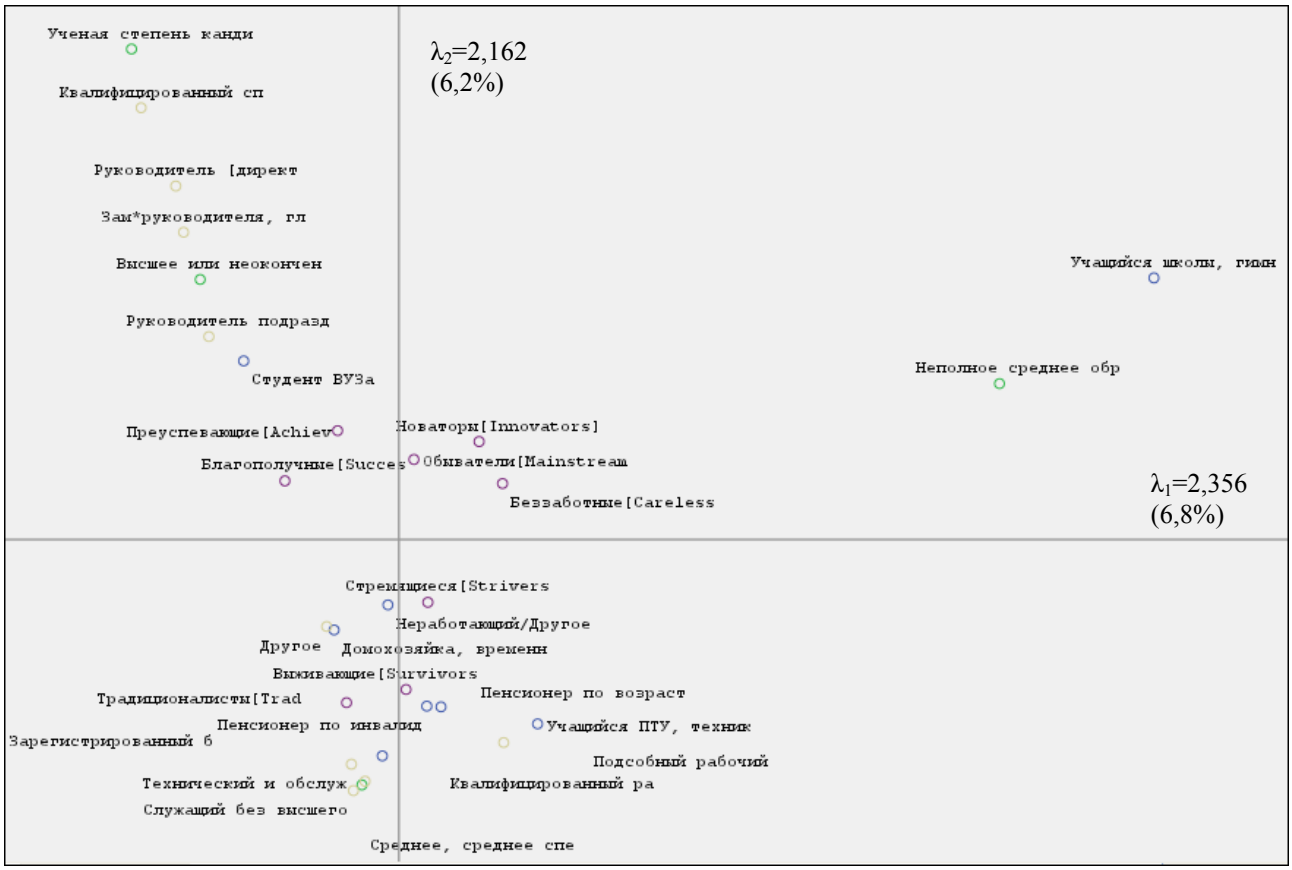


РИС. 3.12. РЕЗУЛЬТАТЫ МНОЖЕСТВЕННОГО АНАЛИЗА СООТВЕТСТВИЙ ТАБЛ. 3.7.

координаты по горизонтальной оси имеют категории неработающих – студент, домохозяйка слева против пенсионеров справа. Таким образом, логично интерпретировать горизонтальную ось как ось «человеческого капитала» в смысле «совокупности накопленных профессиональных знаний, умений и навыков, получаемых в процессе образования и повышения квалификации, которые впоследствии могут приносить доход – в виде заработной платы, процента или прибыли» [Радаев, 2005, стр. 128]. Точки, располагающиеся справа, характеризуют низкий уровень человеческого капитала: учащиеся школ, гимназий и ПТУ, люди с неполным средним образованием, подсобные рабочие. Слева же, наоборот, располагаются точки, характеризующие высокий уровень человеческого капитала: высшее образование, руководящие должности. Заметим, что студенты располагаются в левой полуплоскости, стремясь к полюсу высокого человеческого капитала – в отличие от своих, может быть, сверстников, обучающихся в ПТУ.

Вертикальную ось представляется целесообразным определить как ось культурно-символического капитала, который обозначает «способность человека к производству мнений. ... Это также способность навязывать определенное понимание другим агентам. Важнейшую роль в его функционировании играет манипулирование различными способами оценок имеющихся и потенциальных ресурсов (символическое насилие)» [Радаев, 2005, стр. 132]. Так, вдоль вертикальной оси, снизу вверх, фактически вытягивается вся иерархия должностей; при этом в верхней

полуплоскости также находятся точки «ученая степень», «высшее или неоконченное образование», а также психографический тип «Новаторы», сильно скоррелированый с вертикальной осью а также вносящий определенный содержательный смысл в ее интерпретацию: кто как не Новаторы способны к производству мнений? Таким образом, в направлении положительного полюса вертикальной оси располагаются точки, характеризующие высокую степень культурно-символического капитала: это элита, представители высших классов, интеллигенция, студенты – как потенциальная элита, а также люди, склонные к новаторству. В направлении же отрицательно полюса вертикальной оси мы имеем точки, соответствующие низкому значению культурно-символического капитала: среднее образование, низшие должности, и психографические типы Выживающие, Традиционалисты, Стремящиеся.

В итоге, с помощью множественного анализа соответствий мы рассмотрели одновременное влияние психографического типа человека, образования, статуса занятости и принадлежности к категории неработающих, и получили двумерное социальное пространство, в котором главным осям соответствует величина человеческого и культурно-символического капитала. Более того, в результате использования множественного анализа соответствий мы получаем возможность определить, какие из исходных категорий в наибольшей степени дискриминируют изучаемую совокупность. Так, из всех переменных, участвовавших в анализе, сильнее всего респонденты различаются по образованию и статусу занятости, причем наблюдаются существенные отличия между категориями неработающих: если студенты имеют высокие значения и социального, и культурного капитала, то, учащиеся школ и ПТУ – низкие значения и того и другого; а, например, домохозяйки в целом имеют даже больший социальный капитал, чем пенсионеры и учащиеся школ и ПТУ, но зато характеризуются низкой возможностью к производству мнений, т.е. низким значением культурно-символического капитала.

При этом экономический капитал, который Бурдье определял как наиболее универсальную форму капитала, наиболее легко конвертируемую в другие формы [Burdieu, 1984], тесным образом связан как с человеческим капиталом, так и с культурно-символическим. Фактически, первый есть форма долгосрочной инвестиции в экономический капитал; а второй облегчает способы мобилизации экономического капитала [Радаев, 2005, стр.133]. Поэтому нетрудно предположить, что высокий объем человеческого и/или культурно-символического капитала предполагает также определенный объем экономического капитала, который выражается в размере имеющихся средств, дохода, сбережений и др. В этом плане неудивительно, что высшие должности, характеризующиеся высокими показателями по двум первым осям, будут иметь также и высокий объем экономического капитала, хотя и последний напрямую в нашем решении не задействован.

Объясненная инерция

Наконец, еще одна заметная особенность множественного анализа соответствий, которую мы пока не рассматривали подробно – это существенно более низкие, чем в простом анализе соответствий, значения объясненной инерции. Так, в нашем примере две главные оси объясняют в совокупности всего 13% инерции исходной индикаторной матрицы. Такие низкие значения являются обычными в

ситуации множественного анализа соответствий, однако их нельзя однозначно трактовать как показатели качества решения.

Причина этого занижения в том, что множественный анализ соответствий представляет собой одновременный анализ всех возможных попарных сочетаний переменных, в том числе переменных самих с собой. В свою очередь, каждое пересечение переменной самой с собой является диагональной матрицей, где на главной диагонали стоят соответствующие категориям абсолютные частоты, а все остальные элементы равны нулю. Такая экстремальная форма таблицы, естественно, вносит огромный вклад в общую инерцию, доминируя над сочетаниями других переменных и искажает их истинные вклады в общую инерцию. Геометрически завышенное подобным образом значение инерции приводит к тому, что крайние точки разносятся по полюсам осей.

Тем не менее, М. Гринакр предлагает способ восстановления неискаженного показателя качества решения с помощью приближенной формулы, которая при расчете главной инерции приписывает меньший вес диагональным значениям таблиц, вследствие чего вне-диагональные элементы приобретают близкое к истинному влияние [Greenacre, 1993, formula 17.4]. Так, вместо получаемых в множественном анализе соответствий собственных чисел, мы должны пересчитать их по формуле

$$\left(\frac{Q}{Q-1}\right)^2 \times \left(\sqrt{\lambda_k} - \frac{1}{Q}\right)^2 \qquad k = 1, 2, \ldots$$

при том, что эта формула справедлива только для $\sqrt{\lambda_k} > 1/Q$. Используя эту формулу, мы получаем существенное улучшение качества решения. Так, первая главная инерция будет равняться 2,935 вместо 2,356 и объяснять 33,9% инерции вместо 6,8%; тогда как вторая главная инерция будет равняться 2,648 и объяснять 30,5% инерции вместо 6,2%. Таким образом, совокупный показатель качества решения будет равен 33,9 + 30,5 = 64,4%, что уже очень неплохой результат.

Глава 4.
Совместное использование анализа соответствий и кластерного анализа

Если специфика простого анализа соответствий состоит в том, что, выполняя анализ по столбцам, мы одновременно выполняем и анализ по строкам (поскольку и анализ строк, и анализ столбцов предполагают сингулярное разложение одной и той же матрицы – см. раздел 2.7), то специфика множественного анализа соответствий, аналогично, состоит в том, что, выполняя анализ по переменным, мы одновременно выполняем анализ и по респондентам (см. раздел 3.5). В множественном анализе соответствий сингулярное разложение матрицы Бёрта, представляющей сгруппированные данные, эквивалентно анализу индикаторной матрицы, в которой содержатся данные на уровне респондентов. Таким образом, мы получаем значения координат по осям и вкладов не только для переменных (столбцов индикаторной матрицы), но и для респондентов (строк индикаторной матрицы).

Пример значений координат и вкладов отдельных респондентов для предыдущего примера (табл. 3.7) приведен в табл. 4.1., причем – в силу огромного объема этой информации – ограничен только первыми пятью респондентами. Используя полученные координаты, мы можем изобразить точки, соответствующие отдельным респондентам, в том же пространстве. И здесь целесообразно вспомнить барицентрическое свойство анализа соответствий (см. раздел 2.8), которое применительно к множественному анализу соответствий заключается в том, что «Ищется такая проекция данных в пространство небольшой размерности, чтобы приблизить следующую структуру: каждая точка, соответствующая объекту, расположена в центре облака характерных для него категорий, а точка, представляющая категорию переменных, в свою очередь, являлась центром тяжести соответствующих объектов» [Адамов, 1991, стр. 92].

В простом анализе соответствий и точки строк, и точки столбцов располагались в одном и том же пространстве, образованном одними и теми же осями с одинаковыми значениями главных инерций, полученными в результате сингулярного разложения одной и той же матрицы. По аналогии, в множественном анализе соответствий респонденты и категории переменных точно также располагаются в одном пространстве, образованном одними и теми же осями с одинаковыми главными инерциями, полученными в результате сингулярного разложения индикаторной матрицы (в случае, если мы работаем с матрицей Бёрта, содержащей только сгруппированные данные, у нас нет информации по отдельным респондентам, и, следовательно мы не можем изображать их в

ТАБЛИЦА 4.1. КООРДИНАТЫ И ВКЛАДЫ ПЕРВЫХ ПЯТИ РЕСПОНДЕНТОВ В КОНФИГУРАЦИИ ОСЕЙ (В ФОРМАТЕ SPSS), ПОЛУЧЕННОЙ В РЕЗУЛЬТАТЕ ПРИМЕНЕНИЯ МНОЖЕСТВЕННОГО АНАЛИЗА СООТВЕТСТВИЙ К ТАБЛ. 3.7. (В СТРОКАХ «МАССЫ» И «ВКЛАДЫ ТОЧЕК В ИНЕРЦИЮ ОСЕЙ» СТОЯТ ОКРУГЛЕННЫЕ ЗНАЧЕНИЯ, БЛИЗКИЕ 0 ИЗ-ЗА БОЛЬШОГО РАЗМЕРА ВЫБОРКИ, N=9276)

Object Scores

Case Number	Dimension 1	Dimension 2	Демография\ Образование	Демография\ Неработающие[16+]\ Учащийся школы, гимназии, лицея	Демография\ Работа\ Работа\ Должность[16+]\ Руководитель [директор, президент]	Стиль жизни\ Психографические типы потребителей [RULS]\ Выживающие[Survivors]
1	,026	-1,208	Среднее, среднее специальное образование	Пенсионер по возрасту или выслуге лет	.	Выживающие[Survivors]
2	-,591	,273	Высшее или неоконченное высшее образование	.	Квалифицированный рабочий, мастер	Преуспевающие[Achievers]
3	-,309	-1,069	Среднее, среднее специальное образование	Домохозяйка, временно неработающий	.	Традиционалисты[Traditionalists]
4	-,434	-,592	Среднее, среднее специальное образование	Домохозяйка, временно неработающий	.	Благополучные[Successful]
5	,042	-,941	Среднее, среднее специальное образование	.	Служащий без высшего образования	Беззаботные[Careless]

Object Contributions

Case Number	Mass	Inertia	Contribution: Of Point to Inertia of Dimension 1	Of Point to Inertia of Dimension 2	Of Dimension to Inertia of Point 1	Of Dimension to Inertia of Point 2	Of Dimension to Inertia of Point Total
1	,000	,001	,000	,000	,000	,157	,157
2	,000	,001	,000	,000	,033	,007	,040
3	,000	,001	,000	,000	,007	,075	,082
4	,000	,001	,000	,000	,014	,025	,038
5	,000	,001	,000	,000	,000	,055	,055

пространстве). И если в простом анализе соответствий мы можем рассматривать отдельно карту строк, отдельно – карту столбцов, или же общую карту; то в множественном анализе соответствий, точно также, мы можем рассмотреть карту переменных (столбцов), которая изображена выше на рис. 3.12; карту респондентов, которая для этих же данных приведена на рис. 4.1; или же совместную карту, которую мы здесь не приводим из за того, что она получается слишком громоздкой и нечитабельной.

Как видно из рис. 4.1, расположение респондентов в целом похоже на расположение категорий переменных: получается если не такой четкий крест, как на рис. 3.12, то, по крайней мере, нечто вроде повернутой под углом в 45 градусов буквы «Т» или «Г». Повторим, что в множественном анализе соответствий категории переменных будут располагаться в центре облака респондентов, принадлежащих к этой категории. Выше мы определили горизонтальную ось как ось социального капитала, а вертикальную – как ось культурного капитала. Таким образом, скопление точек в пространстве осей говорит о некоторых относительно устойчивых классах, или стратах

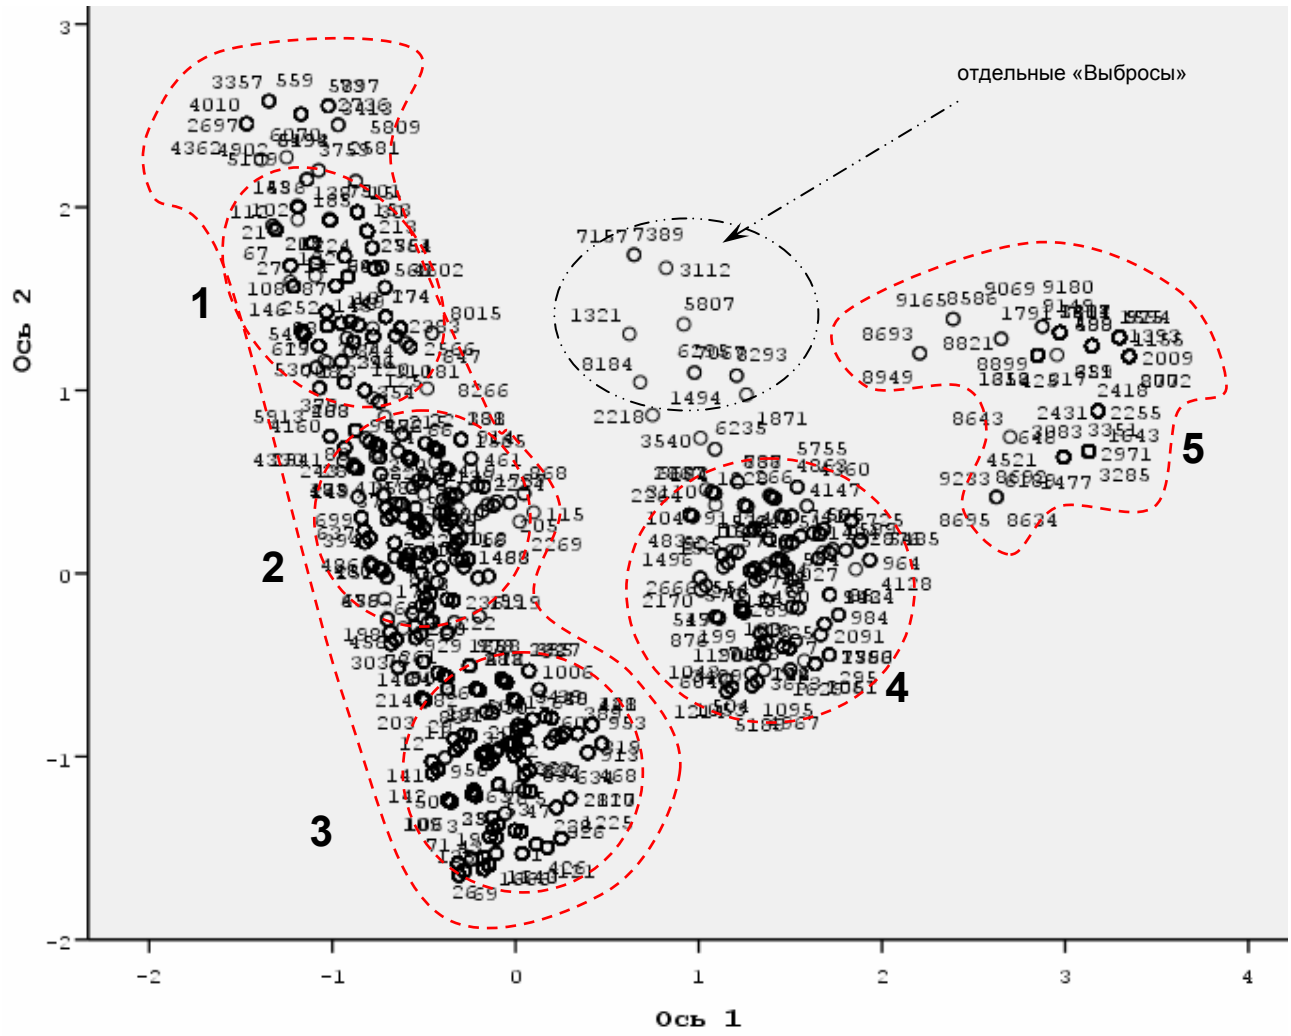


РИС. 4.1. РАСПОЛОЖЕНИЕ ТОЧЕК, СООТВЕТСТВУЮЩИХ ОТДЕЛЬНЫМ РЕСПОНДЕНТАМ В ПРОСТРАНСТВЕ ПЕРВЫХ ДВУХ ОСЕЙ, ПОЛУЧЕННЫХ В РЕЗУЛЬТАТЫ ПРИМЕНЕНИЯ МНОЖЕСТВЕННОГО АНАЛИЗА СООТВЕТСТВИЙ К ТАБЛ. 3.7. КРАСНЫМ ПУНКТИРОМ ОТМЕЧЕНЫ ВОЗМОЖНЫЕ КЛАСТЕРЫ. ОДИНОЧНЫЕ ТОЧКИ В ВЕРХНЕЙ ЦЕНТРАЛЬНОЙ ЧАСТИ КАРТЫ (7157, 7389 И ДР.) МОЖНО СЧИТАТЬ «ВЫБРОСАМИ»

общества, причем расположение этих страт нелинейное. Так, при движении слева направо, что соответствует уменьшению объема человеческого капитала, точки вытягиваются вначале вниз, что соответствует уменьшению объема культурно-символического капитала, но затем, доходя до минимального значения в районе нулевой координаты по вертикальной оси, вновь начинает повышаться, хотя при этом человеческий капитал по-прежнему снижается. В реальности это может означать, что даже обладающие низким человеческим капиталом люди стремятся иметь высокий культурно-символический капитал; т.е. нехватку образования стараются компенсировать пробивным характером, лидерскими качествами, склонностью к новаторству и т.д., что метко описывается русским устойчивым выражением «из грязи в князи». Кроме того, следует учесть, что на крайнем правом полюсе горизонтальной оси находятся учащиеся школ и гимназий, культурно-символический

капитал которых еще не до конца сформирован.

На рис. 4.1 более или менее отчетливо выделяется три облака точек, вытянутых в направлении влево-вверх, которые как бы «распыляются» на верхних краях. При этом верхняя граница самого левого облака довольно высока, верхняя граница среднего облака уже существенно ниже, а верхняя граница правого – еще ниже. Такое, с одной стороны, «распыление», а, с другой – последовательное снижение верхней границы, свидетельствует о том, что в каждом из трех облаков верхняя прослойка, обладающая наивысшим для данной совокупности объемом культурно-символического капитала сравнительно мала и представители элиты в значительной мере обособлены; причем при снижении уровня человеческого капитала уровень культурно-символического капитала представителей верхней прослойки также снижается. Иначе говоря, самого высокого уровня культурно-символического капитала, соответствующего самому левому облаку, можно добиться только при условии высочайшего человеческого капитала (или наоборот, потому что причинно-следственных отношений анализ соответствий не показывает).

Кроме того, левое облако, в свою очередь, состоит из трех групп, две нижних из которых достаточно четкие, а верхняя – довольно аморфная. Фактически, нижняя часть левого облака, обозначенная номером 3, является некой «низшей» стратой, представители которой имеют очень маленькие объемы как человеческого, так и культурного капитала. Страта 2, располагающаяся выше и левее страты 3, находится на среднем уровне культурно-символического капитала (координаты колеблются около нулевого уровня оси), но имеет уже более высокий человеческий капитал. Так, страту 2 можно условно определить как средний класс. Наконец, страта 1, менее четко очерченная, объединяет представителей политической и экономической элиты, интеллигенции, топ-менеджеров крупных компаний, и др. Для всех них характерны высокие значения по обеим осям.

Далее, при движении направо, второе облако условно состоит из ядра, которое обозначено номером 4, и некой периферии, представленной несколькими единичными точками выше. Четвертая страта также имеет объемы культурно-символического капитала, близкие к как к средним, так и к объемам страты 2 (хотя в целом чуть ниже); но вот объем человеческого капитала в ней существенно ниже. Что касается пятой страты, расположенной на правом полюсе, то мы уже разбирали ее выше.

Карта, представленная на рис. 4.1, может быть весьма ценным инструментом предварительного анализа данных. Выявив некие латентные факторы, - в нашем случае, объем человеческого капитала и объем культурно-символического капитала, - которые лежат в основе структуры данных, мы далее можем провести кластерный анализ по этим полученным факторам. Таким образом, дальнейшая задача эквивалентна кластеризации по факторным нагрузкам, которая часто следует за анализом главных компонент. Разница в том, что в методе главных компонент исходные переменные, строго говоря, должны быть измерены по интервальной шкале, тогда как анализ соответствий работает с номинальными данными, в чем мы уже успели убедиться на ряде примеров. Причем, фактически, анализ соответствий превращает исходные номинальные данные в количественные факторы. Сохранив координаты по обеим осям для каждого респондента, мы получаем новые количественные непрерывные переменные, отражающие степень выраженности фактора у определенного респондента. Эти количественные переменные затем прекрасно поддаются кластеризации.

Представив точки, соответствующие респондентам, в пространстве факторов, мы имеем возможность делать предположения о числе и форме возможных кластеров. Так, в нашем случае, можно выделить либо три кластера в форме облаков, либо пять сферических кластеров плюс некоторые выбросы, лежащие на периферии. Исходя из содержательных предположений, озвученных выше, более емким и целесообразным нам представляется последний вариант.

Дополнительным преимуществом анализа соответствий как метода, предшествующего кластерному анализу, является возможность установить фильтры по вкладам не для переменных, как мы это делали ранее в простом анализе соответствий, а для респондентов. Таким образом, респонденты, плохо объясняющиеся полученной конфигурацией осей (а наивно думать, что все респонденты у нас одинаково хорошо объясняются), могут быть отнесены в отдельный кластер «выбросов», который можно далее анализировать самостоятельно.

Поскольку число респондентов огромно (n = 9276), то, в общем-то, бессмысленно устанавливать фильтры по абсолютным вкладам, которые зависят от массы точек, а масса в нашем случае будет ничтожна (см. табл. 4.1). Намного более осмысленным представляется установить фильтры по квадрату корреляции с осями, исключив из анализа тех респондентов, которые слишком уж плохо объясняются полученным решением. Но, установив порог относительного вклада на уровне 0,5, как это рекомендовалось ранее применительно к простому анализу соответствий, мы потеряем большую часть массива (68%, если говорить точнее). Поэтому ограничимся тем, что отберем респондентов, относительный вклад которых хотя бы по одной из осей превышает 0,10; т.е. корреляция с осью не менее ≈0,316 (поскольку, напомним, относительный вклад есть не что иное как квадрат корреляции с осью). Таким образом, мы лишаемся около 12% массива респондентов, поведение которых плохо объясняется нашими факторами.

Далее проведем кластерный анализ по двум переменным: «координата по оси 1» и «координата по оси 2», которые можно добавить в исходный файл данных в результате применения множественного анализа соответствий. Поскольку обе переменные являются непрерывными количественными, мы свободны в выборе метрики расстояния; поэтому остановимся на привычной евклидовой метрике (его не стоит путать с взвешенным евклидовым расстоянием, или, иначе, хи-квадрат расстоянием, которое мы используем для вычисления близостей между профилями).

Современные компьютеры позволяют проводить иерархический кластерный анализ на больших выборках. Так, если раньше размер выборки в 300 объектов был пределом для иерархического кластерного анализа, то сегодня 9-ти тысячная выборка уже не является серьезным препятствием. Если бы мы хотели получить три кластера в форме вытянутого облака, то целесообразно было бы использовать метод ближайшего соседа. Однако из содержательных соображений – см. рассуждения выше и рис. 4.1 – для нас важно получить пять кластеров сферической формы. Для этого разумно использовать метод Варда.

Верхняя часть дендрограммы, показывающей схему объединения кластеров, приводится на рис. 4.2. Из нее видно, что на самом последнем шаге происходит объединение кластеров (1, 2, 3) и (4, 5), расположенных в левой и правой полуплоскости. Очевидно, что между этими объединенными стратами наиболее сильные различия, которые наблюдаются по горизонтальной оси: так, кластеры

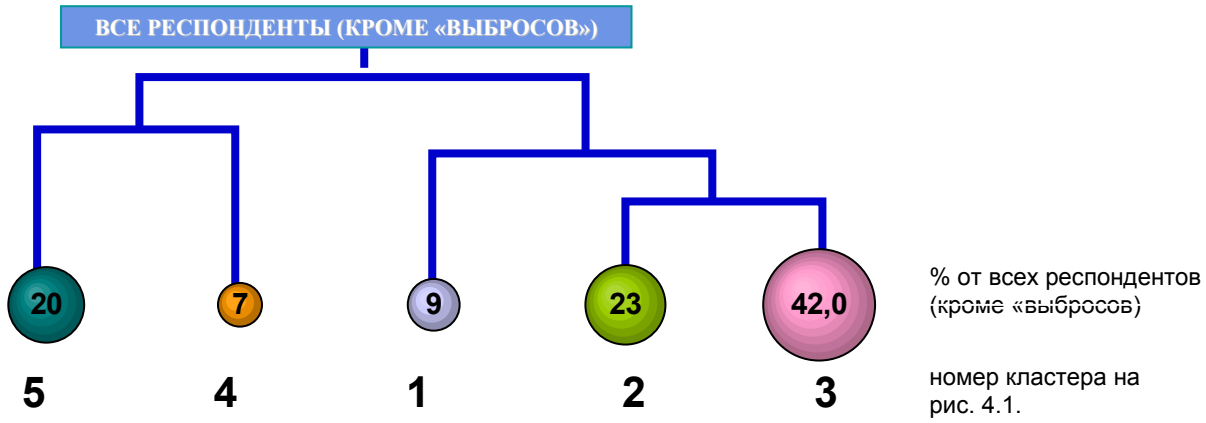


РИС. 4.2. ДЕНДРОГРАММА, ПОКАЗЫВАЮЩАЯ СХЕМУ ОБЪЕДИНЕНИЯ КЛАСТЕРОВ

(1, 2, 3) в среднем имеют высокий объем человеческого капитала, а кластеры (5, 4) – низкий объем человеческого капитала.

На предпоследнем шаге объединяются кластеры 5 и 4, которые, вообще-то, довольно сильно различаются. Так, в страте 5 выше объем культурно-символического капитала, а в страте 4 – человеческого. Далее, на пред-предпоследнем шаге к объединенному кластеру (2, 3) присоединяется кластер 1 – высший класс, элита, который обладает высокими объемами обоих типов капиталов. Наконец, на самом первом шаге объединяются кластеры 2 и 3, т.е. «средний» и «низший» классы, между которыми различия, как видно, самые слабые.

Таким образом, мы видим, что первая ось анализа соответствий разделяет те страты, которые объединяются в общий кластер на самом последнем шаге. Вторая ось отделяет страты, различия между которыми проявляются в объединении на предпоследнем шаге, и т.д. Если бы мы рассматривали четырехмерное решение, то четвертая ось разделяла бы страты, которые объединились на самом первом шаге, т.е. те, между которыми наиболее слабые различия. В данном случае анализ соответствий, дополненный кластерным анализом, можно рассматривать даже как метод классификации, что, в прочем, в литературе еще практически никак не освещено.

ВЫВОДЫ И НАПРАВЛЕНИЯ ДАЛЬНЕЙШЕЙ РАБОТЫ

В данной работе был подробно рассмотрен слабо представленный в русскоязычной литературе метод – анализ соответствий. Анализ соответствий является разведочным многомерным методом анализа данных, который представляет взаимосвязи между строками и столбцами матрицы данных в качестве точек в совместном пространстве низкой размерности.

Анализ соответствий – достаточно «гибкий» метод, не имеющий практически никаких жестких требований к исходным данным. Данный метод является прежде всего разведочным, и, таким образом, может служить существенным дополнением традиционным методам статистического анализа данных, основанным на тестировании гипотез. Важным преимуществом анализа соответствий является возможность наглядной визуализации результатов, имеющая высокую практическую важность в маркетинговых исследованиях.

Особая разновидность анализа соответствий – множественный анализ соответствий, как было показано в работе, служит крайне ценным инструментом предварительного анализа данных. С его помощью можно не только определить, какие переменные или даже отдельные категории переменных сильнее всего дискриминируют респондентов (сходство с задачей дискриминантного анализа); но и, более того, выявить некие латентные факторы, интерпретировать их, дать им названия (сходство с задачей метода главных компонент и факторного анализа) и использовать в дальнейшем анализе, – например, для кластеризации наблюдений по полученным значениям факторов. Вообще, есть целый ряд сходств между методом главных компонент и анализом соответствий, в особенности множественным; и некоторые из них, касающиеся как методологии, так и интерпретации, также отражены в работе.

Еще одно важное свойство анализа соответствий – это представление полученных осей, или факторов, как инструментов классификации (сходство с задачей кластерного анализа). Так, первая ось анализа соответствий разделяет наиболее далекие объекты – те, между которыми самые сильные различия по изучаемым параметрам, и, следовательно, те, которые объединятся в единый кластер на последнем этапе. Вторая ось анализа соответствий отделяет следующие по силе различия, и так далее; в то время как противопоставление между самыми похожими объектами, которые в кластерном анализе объединятся на первых шагах, в анализе соответствий будет представлено последними осями самого высокого порядка.

Основными целями работы были: (1) дать представление исследователю об относительно слабо отраженном в отечественной литературе методе анализа соответствий, причем как о его

математическом аппарате и базовых концептах, так и о практическом применении и интерпретации; и (2) раскрыть некоторые возможности совместного использования анализа соответствий и кластерного анализа на этапе разведочного анализа данных. Обе цели и соответствующие им задачи выполнены, и, надеемся, читатель получил базовое представление о математическом аппарате и интерпретации результатов метода, которые позволят ему избежать ряда ошибок в самостоятельной исследовательской практике; а также будет способствовать дальнейшему развитию метода.

В качестве направлений дальнейшей работы мы могли бы отметить следующие:

1. Более подробно раскрыть математический аппарат множественного анализа соответствий, который на сегодняшний день вообще не представлен в русскоязычной литературе.

2. Рассмотреть сходства и различия метода главных компонент и анализа соответствий, так как у них есть целый ряд общих моментов, как в математической основе, так и в интерпретации.

3. Более тщательно разобрать возможности совместного использования анализа соответствий и кластерного анализа; сравнить результаты, получаемые в случае использования разных методов кластеризации и способов определения метрики пространства. Рассмотреть возможное использование анализа соответствий в качестве метода классификации.

Надеемся, что предлагаемая работа внесет определенный вклад в развитие анализа соответствий в отечественной практике исследований, и, возможно, для кого-то (во всяком случае, для автора точно) послужит отправной точкой для более детального изучения как самого анализа соответствий, так и разведочных методов анализа данных в целом.

Приложение А.
Числовые статистики для примеров, не разобранных в тексте

Глава 1, таблица 1.1.

Ось	Сингуляр-ное число	Главная инерция (собственное значение)	Величина хи-квадрат[a]	Значи-мость	Объясненная инерция	
					Процент	Кумулятивный процент
1	0,177	0,0314			0,457	0,457
2	0,150	0,0224			0,326	0,783
3	0,087	0,0076			0,111	0,894
4	0,059	0,0034			0,050	0,944
5	0,038	0,0014			0,021	0,965
6	0,029	0,0009			0,012	0,978
7	0,028	0,0008			0,012	0,989
8	0,019	0,0004			0,005	0,994
9	0,015	0,0002			0,003	0,998
10	0,012	0,0001			0,002	1,000
11	0,004	0,0000			0,000	1,000
ВСЕГО		0,0686	13527,799	0,000	1,000	1,000

[a] 132 степени свободы

Строки	Масса	Координаты		Инерция	Вклады				
		Ось 1	Ось 2		Точек в инерцию осей		Осей в инерцию точек		Качество в 2 осях
					Ось 1	Ось 2	Ось 1	Ось 2	
При покупке продуктов питания, безалкогольных напитков	0,099	-0,253	-0,413	0,005	0,036	0,113	0,218	0,493	0,712
При выборе алкогольных напитков	0,079	-0,316	-0,562	0,006	0,044	0,167	0,238	0,639	0,876
При выборе табачных изделий	0,029	0,182	-0,536	0,002	0,005	0,056	0,097	0,707	0,804
При выборе одежды, обуви	0,097	-0,346	-0,310	0,004	0,065	0,062	0,522	0,354	0,876
При выборе услуг и товаров по уходу за детьми	0,064	-0,190	-0,168	0,001	0,013	0,012	0,434	0,287	0,721
При выборе бытовой техники	0,117	-0,289	0,070	0,002	0,055	0,004	0,775	0,038	0,814
При планировании покупки компьютера, аксессуаров или программного обеспечения	0,066	-0,478	0,537	0,008	0,085	0,127	0,337	0,360	0,697
При выборе автомобиля или мотоцикла	0,047	-0,072	0,357	0,002	0,001	0,040	0,025	0,523	0,548
При обращении за банковскими или страховыми услугами	0,064	0,349	-0,108	0,003	0,044	0,005	0,495	0,040	0,535
При планировании отпуска, путешествия	0,070	0,575	0,017	0,007	0,131	0,000	0,584	0,000	0,585
При планировании вечера	0,083	1,046	-0,199	0,018	0,515	0,022	0,898	0,028	0,926
При ухаживании за домашними животными	0,089	0,102	0,634	0,006	0,005	0,239	0,026	0,844	0,870
При планировании улучшения домашнего интерьера, ремонта, покупки стройматериалов	0,097	-0,002	0,488	0,005	0,000	0,154	0,000	0,678	0,678
ВСЕГО по строкам	1,000			0,069	1,000	1,000			
Столбцы									
Советы родных, друзей и знакомых	0,436	0,177	-0,215	0,008	0,077	0,135	0,322	0,402	0,725
Радио	0,028	0,856	-0,091	0,004	0,115	0,002	0,806	0,008	0,814
Газеты	0,035	0,775	0,285	0,005	0,119	0,019	0,795	0,091	0,887
Журналы	0,044	0,184	0,767	0,005	0,008	0,174	0,051	0,753	0,804
Телевидение	0,059	0,280	0,071	0,004	0,026	0,002	0,205	0,011	0,216
Листовки и брошюры в почтовом ящике	0,019	0,189	0,158	0,001	0,004	0,003	0,202	0,118	0,319
Тематические издания, справочники, каталоги	0,051	-0,026	1,220	0,012	0,000	0,512	0,001	0,970	0,971
Уличная и транспортная реклама	0,018	0,708	-0,459	0,004	0,052	0,026	0,430	0,152	0,582
Выставки, презентации	0,031	-0,315	-0,136	0,001	0,017	0,004	0,449	0,070	0,519
Интернет	0,025	0,083	0,549	0,005	0,001	0,050	0,007	0,249	0,256
Информация на местах продаж (оформление витрин и прилавков)	0,090	-0,541	-0,336	0,007	0,149	0,068	0,678	0,221	0,899
Консультации продавцов	0,164	-0,682	0,072	0,014	0,431	0,006	0,966	0,009	0,976
ВСЕГО по столбцам	1,000			0,069	1,000	1,000			

Глава 3, таблица 2.1., где точка «Сбербанк» является дополнительной

ТАБЛИЦА 3.5.
СИНГУЛЯРНЫЕ ЧИСЛА И ГЛАВНАЯ ИНЕРЦИЯ ОСЕЙ ДЛЯ ТАБЛ. 3.1: ТОЧКА «СБЕРБАНК» ЯВЛЯЕТСЯ ДОПОЛНИТЕЛЬНОЙ

Ось	Сингуляр-ное число	Главная инерция (собственное значение)	Величина хи-квадрат[a]	Значи-мость	Объясненная инерция	
					Процент	Кумулятивный процент
1	0,129	0,017			0,430	0,430
2	0,104	0,011			0,282	0,712
3	0,066	0,004			0,113	0,825
4	0,050	0,003			0,066	0,891
5	0,048	0,002			0,060	0,951
6	0,034	0,001			0,030	0,981
7	0,027	0,001			0,019	1,000
ВСЕГО		0,039	234,623	0,000	1,000	1,000

[a] 126 степеней свободы

Строки	Масса	Координаты		Инерция	Вклады				Качество в 2 осях
		Ось 1	Ось 2		Точек в инерцию осей		Осей в инерцию точек		
					Ось 1	Ось 2	Ось 1	Ось 2	
Серьезный и стабильный	0,082	-0,692	0,171	0,006	0,303	0,023	0,820	0,041	0,860
Для всей семьи	0,042	0,552	-0,130	0,003	0,098	0,007	0,564	0,025	0,590
Предлагает много выгодных услуг	0,063	0,160	0,031	0,001	0,012	0,001	0,254	0,008	0,262
Дружелюбен к клиентам	0,070	0,034	-0,184	0,001	0,001	0,023	0,012	0,283	0,295
Понимает мои потребности	0,040	0,118	0,008	0,001	0,004	0,000	0,105	0,000	0,105
Ему можно доверять	0,048	-0,484	-0,443	0,003	0,088	0,090	0,519	0,352	0,871
У него постоянные клиенты	0,067	-0,290	-0,081	0,001	0,044	0,004	0,649	0,041	0,690
Находится недалеко от дома/работы	0,034	0,038	0,542	0,002	0,000	0,097	0,003	0,439	0,442
Простота оформления необходимых бумаг	0,051	0,373	-0,144	0,002	0,056	0,010	0,585	0,070	0,656
Имеет обширную сеть банкоматов	0,054	0,280	0,626	0,003	0,033	0,203	0,156	0,635	0,791
Заботится о клиентах	0,053	-0,114	0,045	0,000	0,005	0,001	0,204	0,025	0,229
Условия его услуг понятны	0,054	-0,028	-0,124	0,000	0,000	0,008	0,015	0,234	0,249
В нем лучше всего брать кредит	0,043	0,650	-0,866	0,006	0,142	0,311	0,375	0,538	0,913
Большая сеть отделений	0,048	0,514	0,676	0,004	0,098	0,210	0,377	0,529	0,906
Умеренные цены за услуги	0,034	0,322	-0,074	0,001	0,027	0,002	0,472	0,020	0,492
Быстро выполняет денежные операции	0,051	0,062	0,048	0,000	0,002	0,001	0,115	0,056	0,171
Предоставляет всю нужную информацию	0,058	-0,029	-0,045	0,001	0,000	0,001	0,012	0,023	0,035
Приятная атмосфера	0,055	-0,378	-0,118	0,002	0,061	0,007	0,496	0,040	0,536
Индивидуальное отношение к клиенту	0,053	-0,244	0,045	0,001	0,025	0,001	0,639	0,018	0,657
ВСЕГО по строкам	1,000			0,039	1,000	1,000			
Столбцы									
Citibank	0,173	-0,050	0,092	0,002	0,003	0,014	0,034	0,093	0,127
Home Credit and Finance bank	0,080	0,528	-0,751	0,008	0,173	0,432	0,345	0,566	0,911
Raiffeisen Bank	0,150	-0,675	-0,291	0,010	0,530	0,121	0,841	0,126	0,967
Альфа банк	0,281	0,122	0,289	0,004	0,033	0,225	0,130	0,587	0,717
Банк Возрождение	0,052	-0,096	-0,206	0,002	0,004	0,021	0,031	0,114	0,144
Ренессанс Капитал	0,027	-0,181	-0,458	0,003	0,007	0,055	0,045	0,235	0,281
Русский стандарт	0,172	0,379	0,000	0,004	0,192	0,000	0,789	0,000	0,789
Уралсиб	0,065	-0,341	0,460	0,005	0,058	0,131	0,180	0,266	0,445
ВСЕГО по столбцам	1,000			0,039	1,000	1,000			
Сбербанк - дополнит. точка		*0,299*	*0,590*	*0,119*	*0,000*	*0,000*	*0,077*	*0,242*	*0,319*

Глава 3, таблица 3.6: образование и психографический тип

Ось	Сингуляр-ное число	Главная инерция (собственное значение)	Величина хи-квадрат[a]	Значи-мость	Объясненная инерция	
					Процент	Кумулятивный процент
1	0,116	0,014			0,810	0,810
2	0,053	0,003			0,170	0,980
3	0,018	0,000			0,020	1,000
ВСЕГО		0,017	150,486	0,000	1,000	1,000

[a] 21 степень свободы

Строки	Масса	Координаты		Инерция	Вклады				Качество в 2 осях
		Ось 1	Ось 2		Точек в инерцию осей		Осей в инерцию точек		
					Ось 1	Ось 2	Ось 1	Ось 2	
Неполное среднее	0,119	-0,204	0,591	0,003	0,043	0,779	0,205	0,788	0,993
Среднее,среднее специальное	0,501	-0,272	-0,138	0,005	0,319	0,178	0,895	0,105	1,000
Высшее	0,373	0,403	0,008	0,007	0,522	0,000	0,995	0,000	0,995
Ученая степень кандидата или доктора наук	0,008	1,333	-0,545	0,002	0,117	0,043	0,799	0,061	0,860
ВСЕГО по строкам	1,000			0,017	1,000	1,000			
Столбцы									
Выживающие	0,174	-0,466	-0,061	0,004	0,326	0,012	0,990	0,008	0,998
Традиционалисты	0,103	-0,356	-0,257	0,002	0,113	0,128	0,807	0,192	0,999
Стремящиеся	0,126	-0,304	0,038	0,001	0,100	0,003	0,993	0,007	1,000
Обыватели	0,143	0,227	0,096	0,001	0,063	0,025	0,922	0,076	0,998
Беззаботные	0,057	0,007	0,270	0,000	0,000	0,079	0,001	0,726	0,727
Новаторы	0,157	0,138	0,376	0,002	0,026	0,418	0,226	0,773	0,999
Благополучные	0,120	0,439	-0,374	0,004	0,199	0,315	0,735	0,244	0,979
Достигшие успеха	0,119	0,413	-0,095	0,003	0,174	0,020	0,916	0,022	0,939
ВСЕГО по столбцам	1,000			0,017	1,000	1,000			

Глава 3, таблица 3.6: должность и психографический тип

Ось	Сингуляр-ное число	Главная инерция (собственное значение)	Величина хи-квадрат[a]	Значи-мость	Объясненная инерция	
					Процент	Кумулятивный процент
1	0,157	0,025			0,759	0,759
2	0,059	0,003			0,106	0,865
3	0,040	0,002			0,048	0,913
4	0,039	0,002			0,046	0,960
5	0,030	0,001			0,027	0,987
6	0,019	0,000			0,011	0,998
7	0,009	0,000			0,002	1,000
ВСЕГО		0,033	189,841	0,000	1,000	1,000

[a] 56 степеней свободы

Строки	Масса	Координаты		Инерция	Вклады				
		Ось 1	Ось 2		Точек в инерцию осей		Осей в инерцию точек		Качество в 2 осях
					Ось 1	Ось 2	Ось 1	Ось 2	
Руководитель (директор, президент)	0,025	-1,398	-0,140	0,008	0,313	0,008	0,935	0,004	0,939
Зам.руководителя, главный специалист	0,038	-0,648	0,502	0,003	0,101	0,162	0,802	0,180	0,982
Руководитель подразделения	0,068	-0,760	-0,449	0,007	0,250	0,234	0,840	0,110	0,950
Квалифицированный специалист с высшим образованием	0,215	-0,222	0,197	0,003	0,067	0,141	0,622	0,182	0,804
Служащий без высшего образования	0,146	0,267	-0,048	0,002	0,066	0,006	0,869	0,011	0,880
Технический и обслуживающий персонал	0,125	0,256	-0,424	0,003	0,052	0,383	0,469	0,479	0,948
Квалифицированный рабочий, мастер	0,159	0,166	0,096	0,002	0,028	0,025	0,402	0,051	0,453
Подсобный рабочий	0,040	0,495	0,225	0,003	0,062	0,034	0,601	0,046	0,647
Должность - другое	0,184	0,227	0,048	0,002	0,061	0,007	0,665	0,011	0,676
ВСЕГО по строкам	1,000			0,033	1,000	1,000			
Столбцы									
Выживающие	0,157	0,487	-0,339	0,007	0,236	0,306	0,807	0,146	0,954
Традиционалисты	0,096	0,545	0,173	0,005	0,182	0,049	0,871	0,033	0,904
Стремящиеся	0,124	0,347	-0,026	0,003	0,095	0,001	0,858	0,002	0,860
Обыватели	0,149	-0,080	0,353	0,002	0,006	0,316	0,083	0,608	0,691
Беззаботные	0,056	-0,105	0,072	0,001	0,004	0,005	0,081	0,014	0,096
Новаторы	0,158	-0,165	0,060	0,002	0,027	0,010	0,413	0,021	0,434
Благополучные	0,132	-0,319	0,140	0,003	0,086	0,044	0,773	0,055	0,828
Достигшие успеха	0,128	-0,668	-0,351	0,010	0,364	0,268	0,894	0,092	0,986
ВСЕГО по столбцам	1,000			0,033	1,000	1,000			

Глава 3, таблица 3.6: категория неработающих и психографический тип

Ось	Сингуляр-ное число	Главная инерция (собственное значение)	Величина хи-квадрат[a]	Значи-мость	Объясненная инерция	
					Процент	Кумулятивный процент
1	0,363	0,132			0,887	0,887
2	0,104	0,011			0,073	0,959
3	0,053	0,003			0,019	0,978
4	0,043	0,002			0,012	0,990
5	0,030	0,001			0,006	0,996
6	0,024	0,001			0,004	1,000
ВСЕГО		0,149	512,317	0,000	1,000	1,000

[a] 42 степени свободы

Строки	Масса	Координаты		Инерция	Вклады				
		Ось 1	Ось 2		Точек в инерцию осей		Осей в инерцию точек		Качество в 2 осях
					Ось 1	Ось 2	Ось 1	Ось 2	
Пенсионер по инвалидности	0,058	-0,596	0,108	0,009	0,056	0,006	0,876	0,008	0,884
Домохозяйка/временно неработающий	0,168	-0,061	0,463	0,005	0,002	0,347	0,044	0,738	0,782
Пенсионер по возрасту или по выслуге лет	0,256	-0,829	-0,191	0,065	0,484	0,090	0,982	0,015	0,997
Зарегистрированный безработный	0,014	-0,588	-0,687	0,003	0,013	0,062	0,547	0,213	0,760
Учащийся школы/ПТУ,техникума	0,316	0,596	-0,281	0,044	0,309	0,240	0,935	0,060	0,994
Студент ВУЗа	0,111	0,668	0,190	0,020	0,136	0,038	0,898	0,021	0,919
Неработающие - другое	0,078	0,028	0,539	0,004	0,000	0,217	0,006	0,665	0,671
ВСЕГО по строкам	1,000			0,149	1,000	1,000			
Столбцы									
Выживающие	0,203	-0,836	-0,303	0,054	0,391	0,179	0,959	0,036	0,995
Традиционалисты	0,108	-0,872	0,338	0,032	0,225	0,118	0,944	0,041	0,984
Стремящиеся	0,127	0,047	0,098	0,001	0,001	0,012	0,156	0,197	0,354
Обыватели	0,138	0,415	-0,129	0,010	0,065	0,022	0,859	0,024	0,883
Беззаботные	0,065	0,516	-0,186	0,008	0,047	0,021	0,768	0,028	0,796
Новаторы	0,167	0,650	-0,329	0,028	0,194	0,174	0,916	0,067	0,984
Благополучные	0,090	0,066	0,528	0,003	0,001	0,242	0,043	0,781	0,824
Достигшие успеха	0,102	0,518	0,485	0,013	0,076	0,231	0,739	0,186	0,925
ВСЕГО по столбцам	1,000			0,149	1,000	1,000			

Глава 3, таблица 3.6: полная таблица

Ось	Сингуляр-ное число	Главная инерция (собственное значение)	Величина хи-квадрат[a]	Значи-мость	Объясненная инерция	
					Процент	Кумулятивный процент
1	0,198	0,039			0,739	0,739
2	0,092	0,008			0,159	0,898
3	0,048	0,002			0,044	0,942
4	0,037	0,001			0,026	0,968
5	0,030	0,001			0,017	0,985
6	0,021	0,000			0,009	0,993
7	0,019	0,000			0,007	1,000
ВСЕГО		0,053	969,171	0,000	1,000	1,000

[a] 133 степени свободы

Строки	Масса	Координаты		Инерция	Вклады				Качество в 2 осях
		Ось 1	Ось 2		Точек в инерцию осей		Осей в инерцию точек		
					Ось 1	Ось 2	Ось 1	Ось 2	
Неполное среднее	0,059	-0,038	0,479	0,001	0,000	0,146	0,013	0,977	0,991
Среднее,среднее специальное	0,247	-0,224	-0,002	0,003	0,062	0,000	0,950	0,000	0,950
Высшее	0,184	0,272	-0,197	0,003	0,069	0,077	0,776	0,188	0,964
Ученая степень кандидата или доктора наук	0,004	0,814	-0,894	0,001	0,013	0,033	0,500	0,280	0,780
Руководитель (директор, президент)	0,008	1,250	-0,664	0,003	0,063	0,039	0,784	0,103	0,886
Зам.руководителя, главный специалист	0,012	0,714	-0,402	0,001	0,031	0,021	0,839	0,123	0,963
Руководитель подразделения	0,022	0,650	-0,523	0,003	0,046	0,065	0,575	0,173	0,749
Квалифицированный специалист с высшим образованием	0,068	0,319	-0,197	0,002	0,035	0,029	0,716	0,128	0,844
Служащий без высшего образования	0,047	-0,098	-0,007	0,000	0,002	0,000	0,400	0,001	0,401
Технический и обслуживающий персонал	0,040	-0,140	-0,027	0,000	0,004	0,000	0,390	0,006	0,397
Квалифицированный рабочий, мастер	0,051	-0,025	-0,187	0,001	0,000	0,019	0,012	0,313	0,325
Подсобный рабочий	0,013	-0,167	0,535	0,001	0,002	0,040	0,128	0,608	0,736
Должность - другое	0,059	-0,043	-0,053	0,001	0,001	0,002	0,038	0,028	0,066
Пенсионер по инвалидности	0,011	-0,969	-0,186	0,002	0,052	0,004	0,864	0,015	0,879
Домохозяйка/временно неработающий	0,032	-0,201	-0,142	0,001	0,006	0,007	0,421	0,097	0,518
Пенсионер по возрасту или по выслуге лет	0,048	-1,332	0,016	0,017	0,431	0,000	0,976	0,000	0,976
Зарегистрированный безработный	0,003	-1,104	0,739	0,001	0,016	0,015	0,718	0,150	0,868
Учащийся школы/ПТУ,техникума	0,059	0,592	0,850	0,008	0,105	0,468	0,501	0,480	0,982
Студент ВУЗа	0,021	0,756	0,392	0,003	0,060	0,035	0,809	0,101	0,910
Неработающие - другое	0,015	-0,094	-0,043	0,001	0,001	0,000	0,048	0,005	0,052
ВСЕГО по строкам	1,000			0,053	1,000	1,000			
Столбцы									
Выживающие	0,174	-0,698	0,051	0,018	0,429	0,005	0,957	0,002	0,959
Традиционалисты	0,102	-0,631	-0,198	0,009	0,205	0,043	0,897	0,041	0,938
Стремящиеся	0,126	-0,110	0,191	0,002	0,008	0,050	0,179	0,253	0,432
Обыватели	0,144	0,268	0,077	0,003	0,052	0,009	0,694	0,027	0,721
Беззаботные	0,058	0,270	0,386	0,002	0,021	0,095	0,354	0,337	0,691
Новаторы	0,159	0,377	0,379	0,007	0,115	0,249	0,655	0,306	0,961
Благополучные	0,118	0,245	-0,549	0,005	0,036	0,389	0,277	0,647	0,924
Достигшие успеха	0,119	0,474	-0,352	0,008	0,134	0,160	0,695	0,178	0,873
ВСЕГО по столбцам	1,000			0,053	1,000	1,000			

Глава 3, таблица 3.7: Множественный анализ соответствий (программный output SPSS)

Model Summary

Dimension	Cronbach's Alpha	Variance Accounted For: Total (Eigenvalue)	Variance Accounted For: Inertia
1	**,767**	**2,356**	**,589**
2	**,717**	**2,162**	**,541**
3	,495	1,590	,398
4	,411	1,446	,361
5	,397	1,424	,356
6	,371	1,386	,346
7	,366	1,378	,344
8	,361	1,371	,343
9	,357	1,366	,341
10	,349	1,355	,339
11	,333	1,333	,333
12	,333	1,333	,333
13	,333	1,333	,333
14	,333	1,333	,333
15	,333	1,333	,333
16	,333	1,333	,333
17	,313	1,307	,327
18	,305	1,296	,324
19	,299	1,290	,322
20	,296	1,285	,321
21	,274	1,258	,315
22	,265	1,248	,312
23	,250	1,230	,308
24	,019	1,014	,254
25	-,988	,574	,144
26	-2,498	,348	,087
27	,000	,000	,000
28	,000	,000	,000
Total		34,684	8,671
Mean	,257(a)	1,239	,310

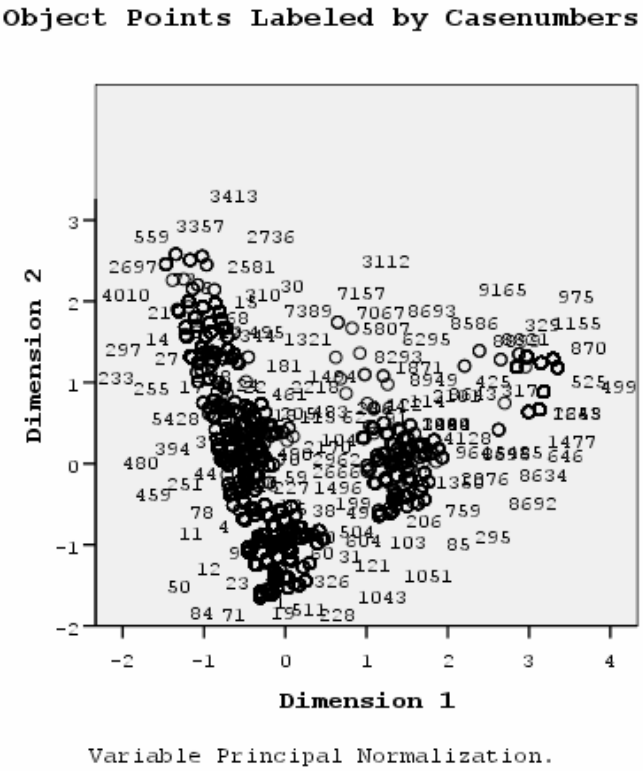
a Mean Cronbach's Alpha is based on the mean Eigenvalue.

Correlations Transformed Variables

Dimension: 1

	Демография\ Образование	Демография\ Работа\ Работа\ Должность[16+]\ Руководитель [директор, президент]	Демография\ Неработающие[16+]\ Учащийся школы, гимназии, лицея	Стиль жизни\ Психографические типы потребителей [RULS]\ Выживающие[Survivors]
Демография\ Образование[a]	1,000	-,101	,035	,083
Демография\Работа\ Работа\ Должность[16+]\ Руководитель [директор, президент][a]	-,101	1,000	,535	-,020
Демография\ Неработающие[16+]\ Учащийся школы, гимназии, лицея[a]	,035	,535	1,000	,002
Стиль жизни\ Психографические типы потребителей [RULS]\ Выживающие[Survivors]	,083	-,020	,002	1,000
Dimension	1	2	3	4
Eigenvalue	1,540	1,089	,923	,448

a. Missing values were imputed with the mode of the quantified variable.

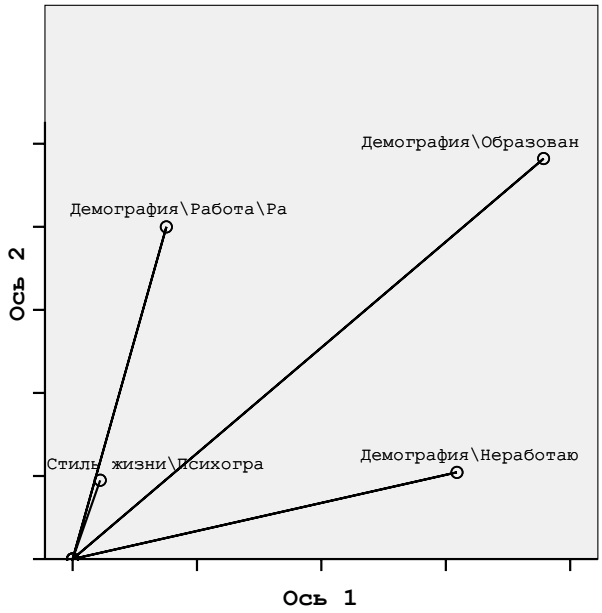


Variable Principal Normalization.

Discrimination Measures

	Dimension		Mean
	1	2	
Демография\ Образование	1,136	,964	1,050
Демография\Работа\ Работа\ Должность[16+]\ Руководитель [директор, президент]	,226	,800	,513
Демография\ Неработающие[16+]\ Учащийся школы, гимназии, лицея	,927	,209	,568
Стиль жизни\ Психографические типы потребителей [RULS]\ Выживающие[Survivors]	,067	,190	,128
Active Total	2,356	2,162	2,259

Discrimination Measures



ПРИЛОЖЕНИЕ В. АНАЛИЗ СООТВЕТСТВИЙ В SPSS: КОМАНДНЫЙ СИНТАКСИС

В SPSS простой анализ соответствий реализован в отдельном модуле *SPSS Categories,* который обычно не входит в стандартный блок. К сожалению, последний далек от совершенства. Так, в SPSS нет интерфейса между блоками «MULTIPLE RESPONSE» и «CORRESPONDENCE». В модуле анализа соответствий мы можем работать только с двумя переменными – категории одной представляются в рядах двумерной таблицы, категории другой – в колонках. Если же нам нужно включить в анализ три, четыре и более переменных, то для этого приходится прибегать к помощи syntax-файла.

Ниже приводится командный синтаксис для работы с таблицей следующего вида:

Таблица В1.
Использование различных источников информации при покупке алкогольных напитков

База: потребители алкогольных напитков ***Абсолютные частоты***	***Советы родных, друзей и знакомых***	***Радио***	***Газеты***	***Журналы***	***Телевидение***	***Листовки и брошюры в почтовом ящике***	***Тематические издания, справочники, каталоги***	***Уличная и транспортная реклама***	***Выставки, презентации***	***Интернет***	***Информация на местах продаж (оформление витрин и прилавков)***	***Консультации продавцов***
Потребляют пиво	3283	106	104	114	320	70	123	109	313	71	579	1280
Потребляют готовые слабоалкогольные коктейли	830	32	24	37	95	21	44	35	101	24	165	333
Потребляют шампанское	2449	69	72	77	199	40	104	73	242	46	452	968
Потребляют ликеры	253	21	19	28	30	12	22	16	52	20	63	111
Потребляют вино(столовое или крепленое)	2907	81	82	94	228	45	117	77	287	58	537	1140
Потребляют водку,горькие настойки	2507	68	70	79	187	49	74	83	213	43	412	961
Потребляют джин	172	16	10	13	29	5	15	10	25	6	42	80
Потребляют коньяк, бренди	724	26	18	32	63	14	40	18	108	24	144	291
Потребляют ром	54	14	12	10	23	5	7	6	12	7	19	32
Потребляют виски	116	18	15	16	25	7	15	8	27	10	37	60
Потребляют вермут	507	18	24	29	59	13	39	18	74	24	111	202

Источник: COMCON, TGI-Россия, 2004, I полугодие

```
data list free/ source type freq.

value lables
source
1 'Советы родных, друзей и знакомых  '
2 'Радио       '
3 'Газеты      '
4 'Журналы     '
5 'Телевидение '
6 'Листовки и брошюры в почтовом ящике       '
7 'Тематические издания, справочники, каталоги      '
8 'Уличная и транспортная реклама    '
9 'Выставки, презентации      '
10 'Интернет   '
11 'Информация на местах продаж      '
12 'Консультации продавцов    '
/type
1 'пиво'
2 'слабоалкогольные коктейли  '
3 'шампанское  '
4 'ликеры      '
5 'вино '
6 'водка, настойки'
7 'джин '
8 'коньяк, бренди     '
9 'ром  '
10 'виски      '
11 'вермут     '
12 'пиво - безалкогольное'
13 'пиво - легкое'
14 'пиво - обычное'
15 'пиво - крепкое'
.
exe.

begin data
1       1       3283    10      4       20      7       8       40      4       12      6
2       1       106     11      4       63      8       8       18      5       12      15
3       1       104     12      4       111     9       8       108     6       12      6
4       1       114     1       5       2907    10      8       24      7       12      5
5       1       320     2       5       81      11      8       144     8       12      7
6       1       70      3       5       82      12      8       291     9       12      14
7       1       123     4       5       94      1       9       54      10      12      4
8       1       109     5       5       228     2       9       14      11      12      22
9       1       313     6       5       45      3       9       12      12      12      24
10      1       71      7       5       117     4       9       10      1       13      496
11      1       579     8       5       77      5       9       23      2       13      19
12      1       1280    9       5       287     6       9       5       3       13      24
1       2       830     10      5       58      7       9       7       4       13      17
2       2       32      11      5       537     8       9       6       5       13      58
3       2       24      12      5       1140    9       9       12      6       13      15
4       2       37      1       6       2507    10      9       7       7       13      27
5       2       95      2       6       68      11      9       19      8       13      17
6       2       21      3       6       70      12      9       32      9       13      56
7       2       44      4       6       79      1       10      116     10      13      19
8       2       35      5       6       187     2       10      18      11      13      84
9       2       101     6       6       49      3       10      15      12      13      190
10      2       24      7       6       74      4       10      16      1       14      2300
11      2       165     8       6       83      5       10      25      2       14      68
12      2       333     9       6       213     6       10      7       3       14      56
1       3       2449    10      6       43      7       10      15      4       14      72
2       3       69      11      6       412     8       10      8       5       14      202
3       3       72      12      6       961     9       10      27      6       14      39
4       3       77      1       7       172     10      10      10      7       14      71
5       3       199     2       7       16      11      10      37      8       14      67
6       3       40      3       7       10      12      10      60      9       14      203
7       3       104     4       7       13      1       11      507     10      14      39
8       3       73      5       7       29      2       11      18      11      14      397
9       3       242     6       7       5       3       11      24      12      14      893
10      3       46      7       7       15      4       11      29      1       15      349
11      3       452     8       7       10      5       11      59      2       15      12
12      3       968     9       7       25      6       11      13      3       15      16
1       4       253     10      7       6       7       11      39      4       15      18
2       4       21      11      7       42      8       11      18      5       15      42
3       4       19      12      7       80      9       11      74      6       15      10
4       4       28      1       8       724     10      11      24      7       15      17
5       4       30      2       8       26      11      11      111     8       15      18
6       4       12      3       8       18      12      11      202     9       15      38
7       4       22      4       8       32      1       12      93      10      15      9
8       4       16      5       8       63      2       12      7       11      15      68
9       4       52      6       8       14      3       12      8       12      15      152
```

```
end data.


weight by freq.

correspondence table = source (1,12) by type (1,15)
       /dimension=2
       /supplementary type (12,13,14,15).
exe.
```

Приложение С. Описание основных психографических типов по методике RuLS

RuLS – Russian Life Style (Российский стиль жизни) – методика психографического анализа и сегментации российских потребителей.

Психографика – одна из основных исследовательских методик, позволяющая дать количественные оценки образа жизни потребителей. Психографика опирается как на личностные характеристики респондента (общительность-замкнутость, гибкость-ригидность, осторожность-склонность к риску и т.п.), так и на информацию о деятельности, интересах и мнении респондента (концепция A.I.O., разработанная Ф.Рейнолдсом и У.Дарденом). Психографика применяется в дополнение к демографической и социально-экономической сегментации потребителей, когда традиционные методы недостаточны для полноценного и четкого объяснения и предсказания потребительского поведения.

В течение 1999-2001 года проанализированы ответы 101259 респондентов в возрасте от 10 лет и старше в 60 городах России (с населением от 100 тысяч жителей и более). 258 высказываний, описывающих покупательское поведение, отношение к себе, окружающим, к работе и дому, к рекламе и средствам массовой информации оценивались респондентами по шкале Лайкерта. Кроме того, респонденты отвечали на вопросы о частоте посещения различных культурно-развлекателных мероприятий, о занятиях спортом, хобби, потреблении товаров и услуг, читательских и зрительских предпочтениях. Применение факторного анализа к многолетним данным исследования Российский Индекс целевых групп (TGI-Russia) дало возможность определить латентную зависимость между утверждениями и определить перечень из 16-ти основных и 10-ти дополнительных высказываний, имеющих наибольшую факторную нагрузку и достаточно надежно объясняющих наблюдаемые вариации. Обширная эмпирическая база TGI-Russia позволила выделить 8 непересекающихся групп респондентов, которые существенно отличаются друг от друга образом жизни, покупательским поведением и репертуаром потребляемых марок, мотивами потребления, активностью проведения досуга, информационными предпочтениями и, зачастую, политической ориентацией. Методологической основой типологии RuLS является адаптация к российским условиям известных психографических моделей: VALS, VALS-2 (SRI International, A.Митчелл, 1983), LOV (Мичиганский

университет, Л.Кале, 1984), RISC, Schwartz. Практический опыт применения типологии RuLS к анализу потребителей различных марок продуктов питания, кондитерских изделий, алкогольных и безалкогольных напитков, услуг, а также сегментация аудиторий газет и журналов, дал положительные результаты.

КРАТКОЕ ОПИСАНИЕ ПСИХОГРАФИЧЕСКИХ ТИПОВ

Выживающие (Survivors) – 17%

Главное для этой группы при выборе товаров – цена. Хронически бедные, смирившиеся и пассивные. Еле сводят «концы с концами», с трудом удовлетворяют свои повседневные нужды. Затраты на покупку продуктов питания, одежды, обуви и предметов длительного пользования (потребительская активность) - ниже среднего уровня. Главное для них при выборе товаров – цена. Они ищут товары подешевле, практически все деньг тратят на продукты питания. В хозяйстве практически отсутствует сложная бытовая техника. Набор мебели и других предметов длительного пользования ограничен старыми моделями. Активные телезрители и радиослушатели (более 3 часов в день). С раздражением относятся к рекламе, предпочитают традиционные продукты, много работают по хозяйству. Для женщин характерно шитье, вязание, ухаживание за комнатными цветами. Основные потребители дешевых продуктов, бакалеи, секонд-хэнд. Часто покупают продукты про запас. Обычно ходят в магазины, расположенные рядом с домом. Досуг ограничен чтением газет и телесериалами. В прессе предпочитают читать, наряду с местными новостями, публикации на тему медицины, огородничества, переписку с читателями. Книги покупают редко, в основном, детективы и учебники. Обеспокоены ростом цен и работой коммунальных служб. Часто грустят и волнуются. Склонны к морализаторству. Религиозны, стараются соблюдать нормы и обряды. Регулярно отмечают религиозные праздники. Образование преимущественно среднее и неполное среднее.

Традиционалисты (Traditionalists)– 9%

При выборе товаров преимущественно ориентируются на цену, но стремятся покупать знакомые товары, в качестве которых убедились на собственном опыте. Предпочитают отечественные продукты и товары, потребители местной небрендированной продукции. Покупают продукты подешевле, любят распродажи. Озабочены материальными и семейными проблемами, на решение которых тратят большую часть времени. Преимущественно домоседы. Заботятся о своем садовом участке, который существенно восполняет потребности в продуктах питания. Самые активные дачники. Приверженцы консервативных моральных ценностей, склонны к морализаторству. Стремятся высказать свое мнение, несмотря на возражения окружающих. К рекламе относятся с раздражением. Стремятся покупать товары, в качестве которых убедились на собственном опыте. Заранее планируют покупки, рассчитывают каждый рубль. Откладывают деньги для крупных покупок. Отдают свои предпочтения драматическим и оперным спектаклям. Однако, досуг не организован,

редко бывают даже в кино. Наряду с детективами предпочитают книги по ведению хозяйства, рецепты. Из публикаций в прессе специально выбирают для чтения местные городские и областные новости, темы о здоровье, медицине, кулинарии, анонсы телепрограмм. В центре внимания – последствия распада Советского Союза, положение русскоязычных в ближнем зарубежье, межнациональные и религиозные конфликты. Хотели бы, чтобы все было точно и предсказуемо.

Стремящиеся (Strivers) – 13%

При выборе товаров преимущественно ориентируются на цену и известность марки. Пытаются приспособиться к рыночным отношениям. Материальный уровень позволяет удовлетворить текущие потребности в еде и одежде, однако на покупку качественных товаров приходится откладывать средства. Постепенно обновляют бытовую технику, одежду и обувь. Неплохо ориентируются в марках продуктов и товаров. Стремятся найти лучшее соотношение цены и качества. Принимают решения в семье о покупке продуктов питания и хозяйственных товаров, лекарств, кондитерских изделий, украшений и бюжетерии. Стараются не покупать незнакомые марки товаров и продуктов. С пониманием относятся к рекламе. Впечатлительны и подвержены влиянию извне. Перед серьезными покупками стараются узнать мнение других. Спонтанны и непостоянны в поступках и оценках. Представляют из себя резерв новаторов. Декларируют любовь к классической музыке, джазу, однако, чаще ограничиваются чтением литературы, нежели походом на концерт. Медицина, здоровье, уход за детьми – это их основные темы в прессе, кроме традиционных городской хроники, кроссвордов и гороскопов. Особый интерес проявляют к публикациям о новых товарах и услугах. Отличает покупка детской литературы, поэзии, детективов и любовных романов. Озабочены проблемами здоровья, взаимоотношениями полов, межнациональными конфликтами. Садовый участок или дача –основное место проведения отпусков.

Обыватели (Mainstreamers) - 18%

Пассивное покупательское поведение без выраженных установок. Декларируют отстраненность от решения бытовых проблем. Самостоятельные покупки совершают ситуативно, чаще – списку, составленному домохозяйкой. Обычно ходят в магазины, расположенные возле дома. Практичны и самодостаточны, ориентируются, скорее на функциональное назначение товаров. Живут преимущественно сегодняшним днем, не всегда заботясь о завтрашнем. Стараются не брать деньги в долг, тратить их аккуратно. Покупают только самое необходимое. Доверяют тем маркам, в качестве которых убедились сами. Заранее планируют важные покупки. Досуг организован слабо. Летом проводят время на даче, садовом участке, которые не только существенно помогают обеспечить потребность в овощах и фруктах, но и дают дополнительный заработок от продажи выращенного. Читают редко, в основном, профессиональную литературу, фантастику, детективы. В прессе обращают внимание на местные новости, криминальную хронику, анонсы телепрограмм. Среди актуальных социально-политических проблем выделяют военные конфликты, положение в армии.

Беззаботные (Careless) – 6%

Пассивное покупательское поведение без выраженных установок. Не принимают участия в работе по дому, за покупками оправляются неохотно. Увлекаются современной музыкой, модными видами спорта. Круг интересов – компьютеры, компьютерные игры, интернет. В марках товаров ориентируются неплохо, хотя к рекламе относятся с некоторым недоверием. Несколько самоуверенны. Считают себя экспертами в аудио и видеотехнике, компьютерах и автомобилях. Мало читают периодическую прессу. Активные телезрители и радиослушатели (более 3 часов в день). Не любят выделяться, живут в «своем мире». Чаще бывают в библиотеке, чем на концерте, но не лишают себя удовольствия «потусоваться» на дискотеке или в клубе по интересам. Предпочитают фантастическую литературу, покупают словари и справочники. Занимаются коллекционированием, игрой на музыкальных инструментах. Любят анекдоты, «приколы», кроссворды, гороскопы. В центре внимания – учеба, проблемы окружающей среды, взаимоотношения в семье.

Новаторы (Innovators) – 14%

При выборе товаров преимущественно ориентируются на известность марки. Энергичны и полны энтузиазма. Активные подражатели, модники. Ищут разнообразия, склонны к риску и к необычному. Могут декларировать презрение к комфорту, но стремятся к престижу и успеху в жизни. Покупают зарубежную литературу, учебники, справочники и фантастику. Активно пользуются компьютером и интернетом. В прессе прежде всего обращают внимания на публикации, связанные с проведением досуга, компьютерными технологиями, путешествиями. Любят анекдоты и кроссворды, светские новости, гороскопы. Активные потребители импортных марок. Самостоятельны в выборе безалкогольных и алкогольных напитков, бытовой техники, косметики и предметов туалета. Значительную часть расходов составляют покупки модной одежды, посещение фаст-фудов, развлечения. Ориентированы на покупку известных марок, преимущественно импортных. Могут переплатить, но купить товар известной фирмы. Любят кино, концерты рок- и поп-музыки, выступления сатириков. С удовольствием тратят деньги, совершают спонтанные покупки. Азартны, активно принимают участие в лотереях и розыгрышах. Стремятся поддерживать себя в спортивной форме. «Пожиратели» рекламы. Заработки и курс валют, секс, учеба – наиболее актуальные для них проблемы.

Благополучные (Successful) – 10%

При выборе товаров преимущественно ориентируются на качество товара. Зрелые, удовлетворенные своим материальным уровнем. Любят комфорт, ценят порядок и ответственность. Заботятся о семье. Хорошо ориентируются в ассортименте. Стараются подбирать удобные и комфортные вещи. «Охотники за качеством», склонны к демонстративному, «вебленовскому» стилю потребления. Если выбрали марку, то стараются ее покупать. Активные покупатели художественной литературы различных жанров, профессиональной литературы. Имеют разносторонние хобби: от музицирования и дрессировки домашних животных до рисования и резьбы по дереву. Готовы

заплатить за высокое качество, как они его понимают. В меру консервативны, лояльные покупатели брендированной продукции, в том числе и отечественной. В меньшей степени влияют на принятие решений о покупках продуктов питания в семье, самостоятельны в выборе марок косметики, мужской и женской парфюмерии, автомобильных принадлежностей, компьютерной техники, строительных и отделочных материалов. Склонны отдавать другим старые, но добротные вещи. Активные телезрители и радиослушатели (более 3 часов в день). Дача – хорошее место для отдыха от городской жизни, но стремятся проводить отпуск в новых местах, в т.ч. за границей. К рекламе относятся терпимо. Предпочитают музеи, выставки, классическое искусство. Демонстрируют озабоченность общесоциальными проблемами: состояние науки, культуры и образования, обеспокоены ситуацией по поводу независимости СМИ, экологическими проблемами, борьбой со СПИДом. Активные читатели периодической прессы, «пожиратели» информации. Энергичны и целеустремленны.

Достигшие успеха (Achievers) – 13%

При выборе товаров преимущественно ориентируются на качество и известность марки. В основной массе - высокообеспеченные и преуспевающие. «Охотники» за престижем. Готовы платить любые деньги за соответствие имиджу успешного человека. Посетители дорогих магазинов, антикварных салонов, бутиков. Ведут активный образ жизни. Адаптивны и целеустремленны. Демонстрируют высокую лояльность выбранным маркам. Предпочитают переплатить, но купить товар известной фирмы. Если что-то понравилось, готовы сразу сделать покупку. Старые вещи склонны выбрасывать, либо отдавать нуждающимся. Самостоятельно принимают решения о покупке сложной бытовой техники, аудио- и видеоаппаратуры, автомобилей и аксессуаров к ним. Активно пользуются компьютером и интернетом. Влияние на покупки хозяйственных товаров, лекарств, кухонных принадлежностей незначительно. Любят концерты поп-музыки, часто ходят в кино и театры. Предпочитают энциклопедии, словари, профессиональную и классическую литературу различных жанров. Сконцентрированы на работе. В центре внимания – общеэкономические проблемы, курсы валют, взаимоотношения на работе и в семье, личная безопасность. В прессе интересуются аналитическими материалами на экономическую тему, современными технологиями, автомобилями, туризмом. Любят видео, предпочитают комедии, боевики и легкую эротику. Дача – хорошее место для отдыха от городской жизни, но стремятся проводить отпуск в новых местах, в т.ч. за границей. Ценят свою свободу, общительны. Ориентированы на жизненный успех, карьеру. Считают, что деньги-лучший показатель успеха. Восхищаются теми, кто много зарабатывает, и хотят выглядеть так же в глазах окружающих.

Библиография

Адамов С. Система анализа нечисловой информации “САНИ” // Социология: 4М. 1991. N 2. Стр.86–104.

Клишина Ю. Применение анализа соответствий в обработке нечисловой информации // Социология: 4М. 1991. N 2. Стр.105–119.

Крыштановский А. Анализ социологических данных. Москва: ГУ-ВШЭ. 2006.

Кутлалиев А., Попов А. Эффективность рекламы. Москва: ЭКСМО. 2005.

Радаев В. Экономическая социология. Москва: ГУ-ВШЭ. 2005.

Толстова Ю. Основы многомерного шкалирования. Москва: Университет. 2006.

Bendixen M. A practical guide to the use of correspondence analysis in marketing research // Marketing Research On-Line. Vol.1. 1996.

Benzecri J.-P. Philosophie thomiste et connaissance mathématique de la nature. // La Pensee Catholique, n. 118. PP.11-24. 1969.

Benzerci J.-P. Analyse des Donnes. Tome 2. L’ analyse de correspondences. Paris: Dunod. 1973.

Bishop Y., Feinberg S. and Holland P. W. Discrete Multivariate Analysis: Theory and Practice. Cambridge USA: MIT Press. 1975.

Blasius J. Correspondence Analysis in Social Science Research / Correspondence Analysis in the Social Sciences (pp.23-52). San Diego, CA: Academic Press. 1994.

Bourdieu P. Distinction. A social critique of the judgment of taste. Cambridge, M.A.: Harvard University Press. 1984.

Carroll J., Green P. and *Schaffer C.* Interpoint distance comparisons in correspondence analysis. // Journal of Marketing Research. №23. 1986.

Clausen S.-E. Applied correspondence analysis: An introduction. Sage university papers. Series: Quantitative applications in the social sciences. Vol. 121, 1998.

Codrier-Escofier B. L’analyse des correspondances. Doctoral thesis. Rennes: Université de Rennes. 1965.

Eckart C. and Young G. The approximation of one matrix byanother of lower rank. Psychometrica: 1, 211-218. 1936.

Fisher R.A. The precision of discriminant functions // Annals of Eugenics 10: 422–429. 1940.

Giegler H. and Klein H. Correspondence Analysis of Textual data from Personal Advertisements / Correspondence Analysis in the Social Sciences (pp.283-301). San Diego, CA: Academic Press. 1994.

Goodman L. A. How to ransack social mobility tables and other kinds of cross-classification tables // American Journal of Sociology, 75. PP.1-40. 1969.

Goodman L.A. New methods for analyzing the intrinsic character of qualitative variables using cross-classified data // American Journal of Sociology 93(3): 529–583. 1987.

Greenacre M. J. Correspondence Analysis and its Interpretation / Correspondence Analysis in the Social Sciences (pp.3-22). San Diego, CA: Academic Press. 1994.

Greenacre M. J., and Blasius J. (eds.) Correspondence Analysis in the Social Sciences: Recent Developments and applications. San Diego, CA: Academic Press. 1994.

Greenacre M. J., and Blasius J. Computation of Correspondence Analysis / Correspondence Analysis in the Social Sciences (pp.53-78). San Diego, CA: Academic Press. 1994.

Greenacre M. Multiple and Joint Correspondence Analysis / Correspondence Analysis in the Social Sciences (pp.141-161). San Diego, CA: Academic Press. 1994.

Greenacre M.J. Correspondence analysis in practice. London: Academic Press. 1993.

Greenacre M.J. Practical correspondence analysis / *V. Barnett (ed.)* Interpreting multivariate data. PP. 119–146. N.Y.: Wiley. 1981.

Greenacre M.J. Theory and Applications of Correspondence Analysis. New York: Academic Press. 1984.

Guttman L. The quantification of a class attributes: A theory and method of scale construction / *P. Horst et al. (eds.)* The prediction of personal adjustment. PP.319–348. N.Y.: The Social Science Research Council. 1941.

Haberman S. J. Analysis of Qualitative dada. (Vol. 1.). Chicago: Academic Press. 1978.

Heiser W. and Meulman J. Homogenity Analysis: Exploring the Distribution of Variables and Their Nonlinear Relationships / Correspondence Analysis in the Social Sciences (pp.179-209). San Diego, CA: Academic Press. 1994.

Hirschfeld H.O. A connection between correlation and contingency // Cambridge Philosophical Society Proceedings 31: 520–524. 1935.

Hoffman D., Franke G. Correspondence analysis: Graphical representation of categotial data in market research // Journal of Marketing Research. №23. 1986.

Hotelling H. Analysis of a complex of statistical variables into principal components // Journal of Educational Psychology 24: 417–441. 1933.

Le Guen M. and Jaffre C. La conjonction analyse des donnes et statistique inferentielle pour conduire a une meilleure perception visuelle. Orléans : Université of Orléans. 1988.

Lebart L. and Fénelon J.-P. Statistique et Informatique Appliquées. Paris: Dunod. 1971.

Lebart L. Complementary Use of Correspondence Analysis and Cluster Analysis / Correspondence Analysis in the Social Sciences (pp.162-178). San Diego, CA: Academic Press. 1994.

Lebart L. Morineau A., Warwick K. Multivariate Descriptive Statistical Analysis. N.Y., 1984.

Martens B. Analyzing Event History Data By Cluster Analysis and Multiple Correspondence Analysis: An example using data about work and occupations of scientists and engineers / Correspondence Analysis in the Social Sciences (pp.233-251). San Diego, CA: Academic Press. 1994.

Muller-Schneider T. The Visualization of Structural Changes by Means of Correspondence Analysis / Correspondence Analysis in the Social Sciences (pp.267-280). San Diego, CA: Academic Press. 1994.

Nishisato S. Analysis of categorical data: Dual scaling and its applications. Toronto: University of Toronto Press. 1980.

Phillips D. Correspondence analysis. Social Research Update. Issue 7. 1995. Copyright University of Surrey.

Rogers K. Correspondence analysis: The big picture // Quirk's Marketing Research Review. April, 1996.

Rouanet H. (in collaboration with Everitt B.) Comparative Study of Statistical Methods Applied to Social Science Data. Paris: ESRC-CNRS. 1988.

Rovan J. Visualizing Solutions in more than Two Dimensions / Correspondence Analysis in the Social Sciences (pp.210-230). San Diego, CA: Academic Press. 1994.

SAS Institute. SAS / STAT User's Guide. Version 6. 4th ed. (Vol.1). Cary, NC: SAS Institute, Inc. 1989.

Shiltz M.-A. A French Reanalysis of a British Survey: comparative study of statistical methods applied to social science data. CAMS, Report P. 055. Paris. 1990.

Snelders H.M.J.J. and Stokmans M. Product Perception and Preference in Consumer Decision-making / Correspondence Analysis in the Social Sciences (pp.324-349). San Diego, CA: Academic Press. 1994.

SPSS Inc. SPSS Categories. Chicago: SPSS. 1990.

StatSoft, Inc. Электронный учебник по статистике. Москва, StatSoft. 2001.
WEB: http://www.statsoft.ru/home/textbook/default.htm.

Takane Y. and Böckenholt U. Linear Constraints in Correspondence Analysis / Correspondence Analysis in the Social Sciences (pp.112-127). San Diego, CA: Academic Press. 1994.

Tenenhaus M. and Young F.W. An analysis and synthesis of multiple correspondence analysis, optimal scaling, dual scaling, homogeneity analysis, and other methods for quantifying categorical multivariate data // Psychometrica 50: 91–119. 1985.

The *BMS (Van Meter K., Schiltz M.-A., Cibois P. and Mounier L.*) A History and French Sociological Perspective / Correspondence Analysis in the Social Sciences (pp.128-138). San Diego, CA: Academic Press. 1994.

Thiessen V., Rohlinger H. and Blasius J. The 'Significance' of Minor Changes in Panel Data: a correspondence analysis of the division of households tasks / Correspondence Analysis in the Social Sciences (pp.252-266). San Diego, CA: Academic Press. 1994.

Van der Heijden P., De Leeuw J. Correspondence analysis used complementary to loglinear analysis. Psychometrica 50(4): 429–447. 1985.

Van der Heijden P., Mooijaart A. and Takane Y. Correspondence Analysis and Contingency Table Models / Correspondence Analysis in the Social Sciences (pp.79-111). San Diego, CA: Academic Press. 1994.

Weller S.C. and Romney A.K., Metric scaling: correspondence analysis. Sage University Paper series on Quantitative applications in the Social Sciences, 07-075. Thousand Oaks, CA: Sage. 1990.

Wuggening U. and Mnich P. Explorations in Social Spaces: Gender, Age, Class Fractions and Photographical Choices of Objects / Correspondence Analysis in the Social Sciences (pp.302-323). San Diego, CA: Academic Press. 1994.

Young F.W. Scaling // Annual review of psychology 35: 55–81. 1984.