Моделирование случайных перестановок

Никита Звонарев

17 марта 2020 г.

1 Перестановки

Определение 1 *Перестановка $\pi : \mathcal{X} \to \mathcal{X}$ — биекция на конечном множестве чисел $\mathcal{X} = \{1, 2, \ldots, n\}$.*

Перестановку π на множестве $\mathcal{X}$ можно записать двумя эквивалентными способами:

1. *Подстановка* — набор пар (x_i, y_i) такие, что $\pi(x_i) = y_i$, множество всех x_i, как и y_i, составляют $\mathcal{X}$.
2. *Композиция циклов* — набор из нескольких упорядоченных непересекающихся кортежей, каждый следующий элемент в кортеже получается взятием π от предыдущего, первый элемент — взятием π от последнего.

Пример одной и той же перестановки, представленной в виде подстановки и в виде композиции циклов:

$$\begin{pmatrix} 1 & 2 & 3 & 4 & 5 & 6 \\ 5 & 1 & 6 & 4 & 2 & 3 \end{pmatrix} = (1, 5, 2)(3, 6).$$

Известный факт: количество перестановок на множестве элементов размера n равно $n!$.

Задача 1 *Сгенерировать случайную перестановку длины n. То есть, научиться моделировать ξ — случайный вектор длины n с элементами из $\mathcal{X}$, где все n элементов различны, при этом вероятность получить один фиксированный вектор равна $\frac{1}{n!}$.*

1.1 Приложение

Возникает вопрос: зачем это вообще нам нужно?

Задача 2 (Разбиение набора данных на подмножества) *Дан набор данных, состоящий из N индивидов. Требуется случайным образом разбить индивидов на k групп, i-я группа имеет размер n_i, $\sum_{i=1}^{k} n_i = N$, вероятность попадания конкретного индивида в группу пропорциональна размеру группы (дополнительно: порядок в группе случаен).*

Решение данной задачи сводится к решению Задачи 1 тривиальным способом: пусть π_ξ — случайная перестановка, соответствующая вектору ξ длины N. Тогда в i-ю группу $\mathcal{G}_i$ надо взять индивидов

$$\mathcal{G}_i = \{\pi_\xi(n_1 + n_2 + \ldots + n_{i-1} + 1), \ldots, \pi_\xi(n_1 + n_2 + \ldots + n_i)\}.$$

Важное приложение: "честное" разбиение данной вам выборки на train- и test- части ($k = 2$) для последующего обучения классификатора/построения регрессии/...

1.2 Тасование Фишера-Йетса (Fisher-Yates shuffle)

Ниже приведён алгоритм, решающий Задачу 1.

1: Объявить массив $x = (x[1], \ldots, x[n])$ длины n, инициализировать его как $x[i] = i$, $i = 1, \ldots, n$.
2: **for** $i = n$, $n - 1$, ..., 2 **do**
3: Промоделировать τ_i, $1 \le \tau_i \le i$ — случайный равномерно распределённый индекс.
4: Поменять местами значения $x[i]$ и $x[\tau_i]$.
5: **end for**
6: **return** $\xi = (x[1], \ldots, x[n])^{\mathrm{T}}$.

Можно понять, что алгоритм корректен, посмотрев на j-ю итерацию: в массиве x на $j - 1$ последних позициях $(x[n - j + 2], \ldots, x[n])$ находится размещение (упорядоченный набор различных элементов из $\mathcal{X}$ фиксированного размера) из $j - 1$ элемента, а j-я итерация достраивает размещение до размера j вытаскиванием случайного элемента на позицию $x[i] = x[n+1-j]$ из множества тех элементов, которые ещё не входили в размещение.

Временная сложность алгоритма — $O(n)$.

Замечание 1 *Алгоритм 1.2 можно использовать для генерации случайных размещений длины k запуском только первых k итераций в пункте 2, и взятием последних k элементов массива.*

Замечание 2 *При повторной генерации случайной перестановки Алгоритмом 1.2 можно не выполнять заново пункт 1.*

Замечание 3 *Заменой конечного индекса при моделировании τ_i с i на $(i - 1)$ алгоритм Фишера-Йетса превращается в алгоритм Сатtоло (Sattolo) генерации случайного цикла длины n.*

2 Проверка корректности алгоритма

Реализация Алгоритма 1.2 может содержать несколько ошибок. Некоторые из них:

- Выбор случайного индекса на шаге 3 может быть реализован с ошибкой, например, можно потерять равномерность, если брать значение из генератора псевдослучайных чисел напрямую по модулю, а не использовать отбор.

- Может возникнуть путаница с индексами, например, из-за ошибки в пункте 3 алгоритм Фишера-Йетса может превратиться в алгоритм Саттоло.

Для обнаружения подобных ошибок можно использовать статистические тесты, например, ошибку с равномерностью генерации индекса можно обнаружить, если рассматривать распределение i-го элемента x_i вектора $\xi = (x_1, \ldots, x_n)^{\mathrm{T}}$. Нетрудно заметить, что x_i имеет равномерное дискретное распределение на элементах их множества $\mathcal{X} = \{1, 2, \ldots, n\}$. Можно сгенерировать выборку из перестановок некоторой фиксированной длины, и проверить распределение i-го элемента критерием χ^2.

Тем не менее, для случайного цикла длины n такое свойство тоже верно.

Поэтому давайте рассмотрим случайную перестановку π_ξ длины n в виде композиции циклов, и обозначим C_i случайную величину, равную количеству циклов длины i в перестановке π_ξ.

Предложение 1 *[1] Верно следующее:*

1. *Матожидание числа циклов длины k $\mathbf{E}C_k = \frac{1}{k}$, $k = 1, \ldots, n$.*

2. *Для фиксированного k случайная величина C_k сходится по распределению к распределению Пуассона с параметром $\frac{1}{k}$ при $n \to \infty$.*

3. *Более того, для фиксированных $1 \leq k_1 < k_2 < \ldots < k_r$ совместное распределение $(C_{k_1}, \ldots, C_{k_r})$ сходится по распределению к r независимым распределениям Пуассона с параметрами в $\frac{1}{k_1}$, $\ldots \frac{1}{k_r}$ соответственно при $n \to \infty$.*

Получаем следующий вариант проверки корректности реализации Алгоритма 1.2, использующий Предложение 1:

- Зафиксировать n — длину перестановки, и k, небольшое относительно n значение.

- Сгенерировать выборку из T перестановок (T — достаточно большое число), для каждой из них посчитать количество C_k циклов длины k

- Проверить асимптотическое соответствие распределения C_k распределению Пуассона с нужным параметром, используя критерий χ^2 (при этом не забывая про условия применимости!).

- (По желанию) проделать процедуру несколько раз, получить набор p-value (по одному значению за повтор), проверить соответствие распределения p-value равномерному распределению на отрезке $[0; 1]$ с помощью критерия Колмогорова-Смирнова.

Список литературы

[1] Richard Arratia and Simon Tavaré. The cycle structure of random permutations. *The Annals of Probability*, pages 1567–1591, 1992.