Регрессия

Т. Е. Абильдаев

Кафедра статистического моделирования
Матмех СПбГУ

Регрессия: вероятностный бэкграунд

Вспомним немного теории вероятностей для вдохновения.
Пусть X, Y – некоторые случайные величины. Как мы можем помнить, условное математическое ожидание $\mathbb{E}(Y|X)$ – это, грубо говоря, усреднение Y по σ-алгебре, порождаемой X, которое при этом измеримо относительно этой σ-алгебры. По теореме о представлении случайной величины, измеримой относительно другой случайной величины, существует такая борелевская функция f, что

$$\mathbb{E}(Y|X) = f(X).$$

Какой смысл несёт f?

Регрессия: вероятностный бэкграунд

Вспомним немного теории вероятностей для вдохновения.
Пусть X, Y – некоторые случайные величины. Как мы можем помнить, условное математическое ожидание $\mathbb{E}(Y|X)$ – это, грубо говоря, усреднение Y по σ-алгебре, порождаемой X, которое при этом измеримо относительно этой σ-алгебры. По теореме о представлении случайной величины, измеримой относительно другой случайной величины, существует такая борелевская функция f, что

$$\mathbb{E}(Y|X) = f(X).$$

Какой смысл несёт f?
Такой: если у Y конечная дисперсия, то f решает оптимизационную задачу

$$\mathbb{E}|Y - g(X)|^2 \longrightarrow \inf_{g \in \mathcal{B}(\mathbb{R})}.$$

Величину $\mathbb{E}(Y|X)$ также называют *регрессией Y на X*, а функцию $f : \mathbb{R} \to \mathbb{R}$ – *функцией регрессии*.
Что если нам интересно приближение в другом классе функций и не в смысле L_2?

Определение регрессии. Линейная регрессия

Определение

Регрессией переменной (случайной величины) Y на переменные (случайные величины) $X_1, \ldots, X_m$ мы будем называть приближение в некотором смысле величины Y величинами $X_1, \ldots, X_m$.

Упрощая, регрессия — это про нахождение функциональной зависимости между переменными.

Перейдём к конкретным моделям и начнём с самой известной из них.

Пусть X – матрица, j-ый столбец которой есть вектор из m наблюдений переменной X_j, $j \in \overline{\{1, m\}}$, а нулевой – вектор длины m из единиц. Ища оптимальную в среднеквадратическом смысле линейную зависимость Y от X, мы приходим к задаче *линейной регрессии*:

$$\| Y - X\beta \|_2^2 = \sum_{k=1}^{n} \left[Y_k - \sum_{j=0}^{m} X_{kj}\beta_j \right]^2 \longrightarrow \inf_{\beta_0, \ldots, \beta_m}.$$

При чём здесь вероятность и случайные величины?

Линейная регрессия (прод.)

При том, что задачу регрессии, конечно же, можно ставить и решать для любого класса функций и любого loss'а, но будет ли в таком произволе толк – вопрос важный.

Предположим, что $X_1, \ldots, X_m, Y$ распределены нормально. Тогда

а) класс линейных функций оправдан, так как гауссовская регрессия является линейной;

б) L_2-loss оправдан, так как по теореме Гаусса-Маркова он доставляет оценку параметров с наименьшей среди линейных несмещённых оценок дисперсией.

Линейная регрессия (прод.)

При том, что задачу регрессии, конечно же, можно ставить и решать для любого класса функций и любого loss'а, но будет ли в таком произволе толк – вопрос важный.

Предположим, что $X_1, \ldots, X_m, Y$ распределены нормально. Тогда

а) класс линейных функций оправдан, так как гауссовская регрессия является линейной;

б) L_2-loss оправдан, так как по теореме Гаусса-Маркова он доставляет оценку параметров с наименьшей среди линейных несмещённых оценок дисперсией.

Какие ещё бывают регрессии, или, вернее, как можно обобщить линейную регрессию?

Обобщённая линейная модель

В сеттинге линейной регрессии мы имеем

$$\mathbb{E}(Y|X) = X\beta.$$

Понятно, что в общем случае на линейность рассчитывать не приходится. Однако мы можем предположить, что величина $\mathbb{E}(Y|X)$ линеаризуется некоторой функцией g, то есть

$$g\big(\mathbb{E}(Y|X)\big) = X\beta.$$

Очевидное требование – g должна быть биекцией.
Как мы помним, $\mathbb{E}(Y|X)$ – это, вообще говоря, случайная величина. Так вот в сеттинге обобщённой линейной регрессии эта величина принадлежит к некоторому экспоненциальному семейству.
Давайте вспомним, что такое экспоненциальное семейство распределений.

Экспоненциальное семейство распределений

Пусть семейство $\Pi = \{f(y;\theta) \,|\, \theta \in \Theta \subset \mathbb{R}^d\}$ таково, что

$$f(y;\theta) = h(y)e^{\left\langle \eta(\theta),\, T(y)\right\rangle - B(\theta)}$$

для некоторых функций h, η, T и B (h положительная, η и T векторнозначные). Тогда Π называется экспоненциальным семейством распределений.

Чем является $T(y)$ со статистической точки зрения?

Экспоненциальное семейство распределений

Пусть семейство $\Pi = \{f(y;\theta) \,|\, \theta \in \Theta \subset \mathbb{R}^d\}$ таково, что

$$f(y;\theta) = h(y)e^{\left\langle \eta(\theta),\, T(y)\right\rangle - B(\theta)}$$

для некоторых функций h, η, T и B (h положительная, η и T векторнозначные). Тогда Π называется экспоненциальным семейством распределений.

Чем является $T(y)$ со статистической точки зрения?

$T(y)$ является *достаточной статистикой*, то есть «содержит в себе всю информацию о данных (выборке)». Что это значит на более формальном уровне?

Пусть у нас имеется выборка, то есть последовательность независимых одинаково распределённых случайных величин. Тогда совместная плотность наблюдений есть

$$f(y_1,\dots,y_n;\theta) = h_n(y_1,\dots,y_n)e^{\left\langle \eta(\theta),\, T_n(y_1,\dots,y_n)\right\rangle - B_n(\theta)},$$

где $h_n(y_1,\dots,y_n) = \prod_{k=1}^n h(y_k)$, $T_n(y_1,\dots,y_n) = \sum_{k=1}^n T(y_k)$, $B_n(\theta) = nB(\theta)$.

Таким образом, для того, чтобы оценить θ, достаточно лишь знать $T(y)$.

Примеры экспоненциальных семейств

1. Ber(p).
   Имеем
   $$f(y;p) = y^p(1-y)^{1-p} = \exp\left[\log\Big(\frac{p}{1-p}\Big)\,y - \log\Big(\frac{1}{1-p}\Big)\right],$$
   откуда $h(y) \equiv 1$, $\eta(p) = \text{logit}(p)$, $T(y) = y$, $B(p) = \log\big(1/(1-p)\big)$.
2. N(a, σ^2).
3. LogN(a, σ^2).
4. Bin(n, p) при фиксированном n.
5. Mult(n, $p_1, \ldots, p_k$) при фиксированном n.
6. Geom(p).
7. NBin(n, p) при фиксированном n. I
8. Pois(λ).
9. Exp(λ).
10. Gamma(α, λ)
11. Beta(α, β).
12. $\chi^2(n)$.

    ...

Обобщённая линейная модель (прод.)

Напомним, что пока мы имеем

$$g\big(\mathbb{E}(Y|X)\big) = X\beta, \quad \mathbb{E}(Y|X) \sim h(y)e^{\left\langle \eta(\theta),\, T(y)\right\rangle - B(\theta)}.$$

Завершающей деталью является *связь* (*link*), выражаемая тождеством

$$g\big(\mathbb{E}(Y|X)\big) = X\beta \Leftrightarrow \mu = g^{-1}(X\beta).$$

Таким образом,

$$\mathbb{E}(Y|X) \sim h(y)e^{\left\langle \eta(X\beta),\, T(y)\right\rangle - B(X\beta)},$$

или на языке наблюдений

$$Y_k \sim h(y)\exp\Big(\Big\langle \eta\Big(\sum_{j=0}^{m} X_{kj}\beta_j\Big),\ T(y)\Big\rangle - B\Big(\sum_{j=0}^{m} X_{kj}\beta_j\Big)\Big).$$

Параметры $\beta_0, \ldots, \beta_m$ оцениваются по методу максимального правдоподобия.

Примеры обобщённых линейных моделей

1. $\mathrm{N}(a, \sigma^2)$.
   Это, очевидно, обычная линейная регрессия.
2. $\mathrm{Ber}(\mathrm{p})$.
   Имеем
   $$f(y; p) = \exp\left[\log\Big(\frac{p}{1-p}\Big)\, y - \log\Big(\frac{1}{1-p}\Big)\right],$$
   откуда
   $$\log\Big(\frac{p}{1-p}\Big) = \mathrm{logit}(p) = X\beta \iff p = \sigma(X\beta) = \frac{e^{X\beta}}{1+e^{X\beta}}.$$
   Это логистическая регрессия, или лог-регрессия.
   Для того, чтобы найти β, решаем
   $$\sum_{k=1}^{n}\left[Y_k \sum_{j=0}^{m} X_{kj}\beta_j - \log\Big(1+\exp\Big(\sum_{j=0}^{m} X_{kj}\beta_j\Big)\Big)\right] \longrightarrow \sup_{\beta_0,\ldots,\beta_m}.$$

Примеры обобщённых линейных моделей (прод.)

3. Pois(λ).
   Имеем
$$f(y;p) = \frac{\lambda^y}{y!}e^{-\lambda} = \frac{1}{y!}e^{\log(\lambda)y-\lambda},$$
   откуда
$$\log(\lambda) = X\beta \iff \lambda = \exp(X\beta).$$
   Это пуассоновская регрессия, или лог-линейная регрессия.
   Для того, чтобы найти β, решаем
$$\sum_{k=1}^{n}\left[Y_k\sum_{j=1}^{m+1}X_{kj}\beta_j - \exp\Big(\sum_{j=0}^{m}X_{kj}\beta_j\Big)\right] \longrightarrow \sup_{\beta_0,\ldots,\beta_m}.$$

О выборе регрессоров

На практике зачастую переменных много. Если мы добавим в модель их все, скорее всего, произойдёт *переобучение* – модель будет отлично аппроксимировать данные, на которых она обучалась, но будет плоха на новых данных.
Какие бывают подходы к выбору регрессоров?

a) Best subsets regression.
   Идея проста. Давайте выберем метрику качества модели и сравним её значения на всевозможных подмножествах множества регрессоров. Выбираем то из них, на котором метрика наилучшая.
   Какой у этого подхода критический недостаток?

О выборе регрессоров

На практике зачастую переменных много. Если мы добавим в модель их все, скорее всего, произойдёт *переобучение* – модель будет отлично аппроксимировать данные, на которых она обучалась, но будет плоха на новых данных.
Какие бывают подходы к выбору регрессоров?

a) Best subsets regression.
   Идея проста. Давайте выберем метрику качества модели и сравним её значения на всевозможных подмножествах множества регрессоров. Выбираем то из них, на котором метрика наилучшая.
   Какой у этого подхода критический недостаток?
   Множество подмножеств растёт экспоненциально относительно числа регрессоров, поэтому прямой перебор это не самая светлая идея.

О выборе регрессоров (прод.)

б) Stepwise regression.
Давайте оставим метрику качества модели, множество подмножеств регрессоров и прикрутим к ним жадный поиск. Есть два подхода – forward selection и backward selection. В forward'е на каждом шаге добавляем переменную, приращение метрики на которой наибольшее. В backward'е начинаем с полной модели и на каждом шаге отбрасываем переменную, на которой уменьшение метрики наименьшее. Останавливаемся либо на заранее выбранном пороге метрики, либо тогда, когда приращение/уменьшение становится незначительным.

в) LASSO regression.
Аддитивная добавка к целевой функции в виде $\lambda\|\beta\|_1$, $\lambda > 0$, приводит к тому, что в результате оптимизации многие компоненты β зануляются.

г) Ridge regression.
А это уже не про выбор регрессоров, а про их контроль. Аддитивная добавка к целевой функции в виде $\lambda\|\beta\|_2$, $\lambda > 0$, уменьшает абсолютные значения компонентов β.

Об оценке качества модели

А как вообще сравнивать модели друг с другом? То есть какие метрики бывают?

- В случае линейной модели у нас есть R^2, R^2_{adj}, C_p-статистика Мэллоу. Последнее считается по формуле

$$C_p = \text{MSE} + \frac{2n(d+1)}{\widehat{\sigma}^2},$$

- В общем случае, помимо прочего, у нас есть информационные критерии. Акаике:

$$\text{AIC}(\theta) = L_\theta - d,$$

байесовский:

$$\text{BIC}(\theta) = L_\theta - \frac{\log(n)}{2} d.$$

При $n \to \infty$ выбор по BIC приводит к истинным параметрам, а выбор по AIC приводит к модели с наименьшей дисперсией ошибки.